

分类号
学校代码 10487

学号 D202280946
密级

华中科技大学

博士学位论文

(学术型 ☒ 专业型 ☐)

面向复杂开放场景的立体视觉深度估计方法及应用研究

学位申请人：程俊达

学科专业：信息与通信工程

指导教师：杨欣 教授

答辩日期：2026年3月9日

答辩委员会

	姓名	职称	单位
主席	陈少平	教授	中南民族大学电子信息工程学院
委员	曾德泽	教授	中国地质大学计算机学院（武汉）
	刘文予	教授	华中科技大学电子信息与通信学院
	尤新革	教授	华中科技大学电子信息与通信学院
	冯滨	教授	华中科技大学电子信息与通信学院

**A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Degree of Doctor of Engineering**

**Research on Stereo Vision Depth Estimation
and Applications in Complex Open-world
Scenarios**

Ph.D. Candidate : CHENG Junda

Major : Information and Communication Engineering

Supervisor : Prof. YANG Xin

Huazhong University of Science and Technology

Wuhan 430074, P. R. China

April, 2026

独创性声明

本人声明所呈交的学位论文是我个人在导师的指导下进行的研究工作及取得的成果。尽我所知，除文中已标明引用的内容外，本论文不包含任何其他人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：程俊达

日期：2026 年 3 月 9 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权华中科技大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本论文属于 ☐ 保 密，在 ____ 年解密后适用本授权书。
☒ 不保密。

(请在以上方框内打“√”)

学位论文作者签名：程俊达

日期：2026 年 3 月 9 日

指导教师签名：程俊达

日期：2026 年 3 月 9 日

摘 要

视觉深度估计是自动驾驶、无人机、机器人导航及增强现实等智能系统的核心感知环节。其中，立体视觉深度估计（含双目立体匹配与多视角立体视觉）通过多视图几何恢复绝对度量深度，已成为获取三维信息的关键手段。然而，真实开放场景中的病态区域（如反光、透射）、复杂精细结构及非理想观测引入的强噪声，对现有算法的鲁棒性与精度提出严峻挑战。为此，本文针对视觉退化场景匹配难、跨域未见场景泛化差、非理想观测下抗噪能力弱三大核心挑战展开创新，实现复杂条件下高精度、高鲁棒的深度估计，并将成果赋能于视觉里程计系统。本文的主要工作与创新如下：

针对复杂场景中视觉退化场景（如弱纹理、强反光及细微结构等病态区域）匹配难问题，本文提出了一种基于区域分治和注意力机制的特征增强立体匹配算法，旨在解决立体匹配在视觉退化场景最基础的特征表示问题。该方法依据几何特性设计区域分治策略：在边缘区域引入局部注意力机制解决边缘模糊；在平滑区域利用金字塔池化与卷积高效聚合上下文特征以消除局部匹配歧义。同时，提出视差维度的全局注意力机制克服了代价聚合的局部性缺陷，在减少计算开销的同时显著提升了病态区域的匹配精度。

针对开放场景数据分布差异大导致的未见场景泛化性能差问题，本文提出了一种基于单目先验和双分支迭代优化的高泛化立体匹配方法。该方法构建双分支互优化架构，一方面通过立体引导对齐模块，利用高置信度立体几何线索校正单目深度的尺度与偏移；另一方面通过单目引导优化模块，利用校正后的单目语义结构引导立体匹配在病态区域的优化。该方法最大化挖掘了单目先验的强结构感知优势，显著提升了模型在零样本条件下的泛化能力。

针对实际应用中非理想观测条件下立体几何约束不可靠导致系统抗噪能力弱的问题，本文提出了一种基于单目与多视角自适应融合的抗噪增强深度估计方法。在真实应用中，相机参数往往伴随噪声，导致立体几何约束失效。该方法设计了自适应融合机制，通过构建重投影一致性置信度评估几何约束可靠性。在参数准确时发挥多视角几何的高精度优势，在参数噪声大或存在动态物体时自适应切换至鲁棒的

单目深度分支。该方法克服了系统对参数精度的过度依赖，大幅增强了非理想观测下的抗噪鲁棒性。

本论文进一步将上述创新方法结合并应用到视觉里程计任务中，提出了一种基于深度先验增强与几何迭代的单目视觉里程计系统。该方法将单目度量深度与多视角几何先验引入里程计的初始化与光束法平差中，并结合提出的噪声增强训练策略与自适应深度筛选机制，解决了单目视觉里程计缺乏度量尺度及复杂场景鲁棒性差的缺陷。实验表明，该系统在剧烈运动与动态场景下仍保持稳健定位与建图，实现了深度估计向定位建图应用的价值转化。

关键词：立体匹配；多视角立体视觉；单目深度估计；视觉里程计

Abstract

Visual depth estimation is a core perception component in intelligent systems such as autonomous driving, unmanned aerial vehicles (UAVs), robot navigation, and augmented reality (AR). Among them, stereo visual depth estimation (including binocular stereo matching and multi-view stereo) recovers absolute metric depth through multi-view geometry, serving as a crucial means for acquiring 3D information. However, ill-posed regions (e.g., reflections and transparencies), complex fine structures, and strong noise introduced by non-ideal observations in real-world open scenes pose severe challenges to the robustness and accuracy of existing algorithms. Therefore, this dissertation conducts innovative research targeting three core challenges: matching difficulty in visually degraded scenes, poor generalization across unseen domains, and weak noise resistance under non-ideal observations. The ultimate goal is to achieve high-precision and highly robust depth estimation under complex conditions, and to empower visual odometry systems with these technological outcomes. The main contributions of this dissertation are as follows:

To address the matching difficulty in visually degraded scenes (e.g., ill-posed regions with weak textures, strong reflections, and fine structures) within complex environments, this dissertation proposes a feature-enhanced stereo matching algorithm based on a regional divide-and-conquer strategy and attention mechanisms. This method designs a regional divide-and-conquer strategy based on geometric characteristics: in edge regions, a local attention mechanism is introduced to resolve edge blurring; in smooth regions, pyramid pooling and convolution are utilized to efficiently aggregate context features, thereby eliminating local matching ambiguities. Meanwhile, a global attention mechanism along the disparity dimension is proposed to overcome the locality defect of cost aggregation, which significantly improves the matching accuracy in ill-posed regions while reducing computational overhead.

To address the poor generalization performance in unseen scenes caused by massive data distribution discrepancies in open environments, this dissertation proposes a highly

generalizable stereo matching method based on monocular priors and dual-branch iterative optimization. This method constructs a dual-branch mutual optimization architecture. On the one hand, a stereo-guided alignment module utilizes high-confidence stereo geometric clues to calibrate the scale and shift of the monocular depth. On the other hand, a monocular-guided optimization module employs the calibrated monocular semantic structures to guide the optimization of stereo matching in ill-posed regions. This approach maximizes the exploitation of the strong structure-awareness advantage of monocular priors, significantly enhancing the model's generalization capability under zero-shot conditions.

To address the weak noise resistance of the system caused by unreliable stereo geometric constraints under non-ideal observation conditions in practical applications, this dissertation proposes a noise-resilient enhanced depth estimation method based on the adaptive fusion of monocular and multi-view clues. In real-world applications, camera parameters are often accompanied by noise, leading to the failure of stereo geometric constraints. This method designs an adaptive fusion mechanism that evaluates the reliability of geometric constraints by constructing a reprojection consistency confidence map. It leverages the high-precision advantage of multi-view geometry when parameters are accurate, and adaptively switches to the robust monocular depth branch when parameter noise is significant or dynamic objects are present. This method overcomes the system's over-reliance on parameter accuracy, substantially enhancing the noise robustness under non-ideal observations.

Furthermore, this dissertation integrates the aforementioned innovative methods and applies them to the visual odometry task, proposing a monocular visual odometry system based on depth prior enhancement and geometric iteration. This method introduces monocular metric depth and multi-view geometric priors into the initialization and Bundle Adjustment (BA) of the odometry. Combined with the proposed noise-enhanced training strategy and adaptive depth filtering mechanism, it resolves the inherent defects of lacking metric scale and poor robustness in complex scenes typical of monocular visual odometry. Experiments demonstrate that the system maintains robust localization and mapping even under vigorous motion and dynamic scenes, successfully realizing the value transformation from depth estimation technology to localization and mapping applications.

华 中 科 技 大 学 博 士 学 位 论 文

Keywords: Stereo Matching, Multi-view Stereo, Monocular Depth Estimation, Visual Odometry

目 录

摘 要	I
Abstract	III
1 绪论	
1.1 研究背景与意义	(1)
1.2 国内外研究现状	(4)
1.3 存在的问题	(18)
1.4 研究内容与结构安排	(20)
2 视觉退化场景下区域分治的高精度立体匹配方法	
2.1 引言	(25)
2.2 基于区域分治和注意力机制的特征增强立体匹配网络	(29)
2.3 基于几何特性的区域特征提取	(31)
2.4 区域代价体构建	(35)
2.5 区域注意力聚合	(38)
2.6 视差维全局注意力融合	(40)
2.7 实验结果与分析	(43)
2.8 本章小结	(57)
3 跨域场景下单目-双目协同迭代的高泛化立体匹配方法	
3.1 引言	(58)
3.2 基于单目-双目双分支迭代优化的立体匹配网络	(62)
3.3 单目深度与立体匹配双分支构建	(64)
3.4 基于互优化的双分支迭代更新机制	(67)
3.5 实验结果与分析	(70)
3.6 本章小结	(82)

4	非理想观测下单目-多视角融合的抗噪深度估计方法	
4.1	引言	(83)
4.2	基于单目-多视角自适应融合的深度估计网络	(86)
4.3	单目与多视角深度估计分支构建	(88)
4.4	基于重投影一致性的自适应融合模块	(90)
4.5	实验结果与分析	(92)
4.6	本章小结	(105)
5	深度先验赋能的视觉里程计	
5.1	引言	(107)
5.2	基于深度先验增强与几何迭代的单目视觉里程计框架	(111)
5.3	单目深度先验初始化	(112)
5.4	基于光流的几何感知的迭代更新算子	(114)
5.5	噪声增强训练与自适应筛选策略	(117)
5.6	实验结果与分析	(119)
5.7	本章小结	(128)
6	总结与展望	
6.1	本文主要内容及结论	(130)
6.2	本文主要创新点	(134)
6.3	展望	(135)
	致 谢	(137)
	参考文献	(139)
	附录 1 答辩委员会决议	(156)
	附录 2 攻读博士学位期间取得的研究成果	(157)
	附录 3 公开发表的学术论文与博士学位论文的关系	(160)
	附录 4 攻读博士学位期间参与的科研项目	(161)
	附录 5 中英文缩写对照表	(162)

1 绪论

1.1 研究背景与意义

近年来,人工智能技术^[1]的飞速发展,催生出以无人机、自动驾驶汽车、移动机器人为代表的各类智能无人系统。这些系统旨在像人类一样,拥有对周围复杂动态环境进行全方位自主感知的能力,从而在没有人工干预的情况下安全、高效地执行各种任务。国家层面高度重视人工智能及相关产业的发展,《新一代人工智能发展规划》和《“十五五”机器人产业发展规划》等一系列重要政策文件均明确指出,要重点突破在复杂、动态、不确定场景下的环境感知、实时精确定位与地图构建^[2]等共性关键技术,以提升智能无人系统的核心竞争力和实际应用水平。在这一宏观背景下,赋予智能无人系统根据二维图像信息精确测量环境三维几何结构的能力,即视觉深度感知,显得尤为关键。它使智能无人系统不仅能看清环境的纹理和色彩,更能理解三维场景中物体之间的距离、形状、大小以及相对位置关系,从而构建起真实世界的三维数字模型。



图 1.1 视觉深度估计的典型应用场景。

如图 1.1 所示,这种能力是无人机在复杂空域进行自主避障与导航、自动驾驶汽车在城市道路实现安全行驶与路径规划、移动机器人在未知环境中进行三维重建与交互操作以及增强现实设备在虚实融合中构建环境几何约束的前提与基石。它对于

推动智能无人系统在低空经济^[3]、智慧交通^[4]、智能制造及沉浸式交互^[5]等领域的广泛应用具有极其重要的战略意义和现实价值。

基于激光雷达^[6]等主动式传感器的三维环境感知存在高成本、大体积、高功耗及数据稀疏等局限。相比而言，视觉传感器凭借其低成本、紧凑的物理形态以及提供高分辨率纹理与语义信息的显著优势，已成为实现大规模商业化部署的理想选择。在视觉深度估计的技术版图中，基于立体视觉的深度估计——涵盖双目立体匹配^[7-10]与多视角立体视觉（Multi-View Stereo, MVS）^[11-16]——占据着不可替代的核心地位。与单目深度估计^[17-25]受限于病态的尺度模糊问题不同，立体视觉深度估计方法严格遵循多视图对极几何原理。无论是传统的优化算法还是新兴的深度学习方法，这类技术路线本质上均是通过显式构建几何约束（如代价体），利用三角测量原理，在已知相机基线的情况下准确恢复场景的绝对度量深度（Metric Depth）。

尽管双目立体匹配与多视角立体视觉在输入视图数量和几何约束形式上存在差异，但基于深度学习的立体视觉深度估计方法如 PSMNet^[7], GwcNet^[26], MVSNNet^[11]等已逐渐收敛于一套标准化的四阶段流程，具体包括：

（1）特征提取：利用共享权重的深层卷积神经网络或者 Transformer^[27] 将原始图像转换为对光照和视角变化具有一定不变性的高维特征表示。

（2）匹配代价构建：基于几何约束（如极线约束或平面扫描），计算不同视图特征在不同视差/深度假设下的相似性，构建三维或四维的匹配代价体。

（3）代价聚合：利用 2D/3D 卷积^[28-30]或注意力机制^[31-34]在空间和视差/深度维度上聚合上下文信息，对噪声严重的初始代价体进行正则化和平滑，抑制局部匹配歧义。

（4）深度/视差计算：采用可微的软最小值参数估计操作，沿着视差或深度维度对聚合后的代价体进行加权求和，回归出亚像素精度的连续深度图。

虽然上述标准化的处理流程在理想环境和基准数据集（如 ETH3D^[35]、Middlebury^[36]）上取得了令人瞩目的性能，但其有效性严格建立在一系列理想化假设之上，例如场景满足光度一致性、训练数据与测试数据同分布、几何参数精确已知等。然而，在面对复杂多变的开放世界场景时，这些假设往往难以成立，导致现有的立体视觉深度估计技术仍面临着算法榜单评分高但是实际落地鲁棒性差的巨大鸿沟。这种局限性并非源于几何原理本身的错误，而是由于真实物理环境的复杂性与理想几何模型假设之间的差距导致的。如图 1.2 所示，在实际应用中，上述标准流程中的关

关键环节普遍面临以下三大核心挑战：




图 1.2 立体视觉深度估计在复杂开放场景下面临的三大核心挑战。

视觉退化场景的匹配难题：立体视觉算法的核心假设是多视角光度一致性，即空间中同一点在不同视角下的投影应具有相似的外观特征。然而，真实场景中复杂的几何与光照特性往往导致该假设失效或约束力不足。具体而言，在室内白墙、路面等弱纹理或无纹理区域，像素灰度变化平缓，缺乏具有辨识度的特征，导致匹配代价体在视差维度上呈现多峰或平坦分布，产生严重的匹配模糊问题，使得算法难以收敛到唯一正确解；在玻璃幕墙、水面等反光或高光退化场景，物体表面光照随视角变化剧烈，物理上违背了朗伯反射假设，导致同一个点在不同视角下外观差异巨大从而引发错误匹配；在栅栏、树叶等细小边缘区域，传统的卷积神经网络由于感受野内的特征平滑效应，极易造成前景与背景特征的混叠，产生边缘模糊现象并丢失几何细节。这些视觉退化场景中存在的病态问题使得单纯依赖几何匹配线索的深度估计在复杂环境中极易失效，直接威胁到智能系统的安全性。

跨域未见场景的泛化性能差难题：数据驱动的立体视觉深度估计模型高度依赖于训练数据的质量与多样性。然而，在真实物理世界中，获取高精度、稠密且覆盖多场景的深度真值成本极高。因此具有高精度且稠密的深度标签的数据极度稀缺，这迫使现有研究大量依赖合成数据集。这种对合成数据的依赖引发了严重的域偏移问题：模型容易过拟合于合成数据特定的纹理风格、光照条件以及深度分布先验，而非学习到本质的几何匹配物理规律。因此，当模型部署到未见过的真实开放场景时，面对截然不同的图像域特征，其匹配性能往往急剧下降，表现出极强的域敏感性，严重限制了算法的实际部署能力。

非理想观测条件下抗噪能力弱难题：立体视觉几何约束的成立严格依赖于相机

几何参数的精确性，这包括相机内参和外参。然而，在实际应用中，这种相机参数的精确性往往是理想化的。一方面，在无人机、机器人等移动平台的长期高动态运行中，机械振动和温度变化会导致相机内参发生微小漂移；另一方面，多视角立体视觉所依赖的实时相机位姿通常由即时定位与地图构建算法^[37-41]（Simultaneous Localization and Mapping, SLAM）或者传感器提供，不可避免地包含瞬时噪声或累积误差。现有的立体视觉算法大多缺乏对参数噪声的容忍机制，一旦对极约束不再严格成立，构建的匹配代价体将产生系统性偏差，从算法原理上的失效导致深度估计精度严重退化甚至完全崩溃，缺乏在非理想观测条件下的抗噪能力。

综上所述，虽然基于立体视觉的深度估计具备获取绝对尺度的天然优势，但在复杂开放场景的实际部署中，其精度和鲁棒性往往面临严峻挑战。如何克服病态区域等视觉退化场景的匹配失效、如何提升跨域场景的泛化能力以及如何增强对非理想观测条件下参数噪声的鲁棒性，是制约该技术落地的三大核心瓶颈。在此背景下，本文围绕立体视觉在复杂开放场景下的应用难题展开系统研究，探索特征表示增强、先验融合泛化、自适应抗噪机制等，并最终将研究成果赋能于视觉里程计应用。本文的研究不仅可以提升视觉深度估计模型在各种复杂场景下的性能，而且可以为无人系统在卫星导航拒止、弱纹理及高动态环境下的高精度定位与建图提供关键技术支撑，具有重要的基础研究价值和广泛的应用研究价值。

1.2 国内外研究现状

本论文围绕双目立体匹配、多视角立体视觉、结合结构先验的深度估计、前馈式三维重建以及视觉里程计进行探究，并重点探讨了当前方法在视觉退化场景、跨域泛化及含噪几何观测条件下的鲁棒性问题，以此明晰从纯几何算法向复杂融合系统演进的内在逻辑。

1.2.1 双目立体匹配

双目立体匹配作为三维视觉领域的基石任务，其核心目标是利用双目相机拍摄的左右视图对，通过计算像素间的对应关系，基于三角测量原理恢复场景的稠密深度信息。纵观该领域的发展历程，立体匹配算法主要经历了由手工特征驱动的传统方法^[42-44]向数据驱动的深度学习方法^[10,26,45-49]的范式转移。早期的传统方法通

常依赖于手工设计的特征描述符与全局能量优化策略，虽然奠定了立体匹配的理论基础，但在处理弱纹理、重复纹理及复杂光照等非理想场景时往往存在极大的局限性。近年来，随着深度学习技术的飞速发展，立体匹配领域引入卷积神经网络（Convolutional Neural Networks, CNN）^[28-30] 后，其深层特征表达优势显著提升了匹配的精度与鲁棒性。而随着技术迭代，又经历了从基于 CNN 代价体聚合向基于迭代优化^[9,10,45,50] 以及基于视觉转换器（Transformer）^[51-55] 的架构的范式转移。

2002 年，Scharstein 等人^[56] 系统梳理了此前约二十五年的研究成果后，建立了经典的立体匹配四步标准框架：特征提取、匹配代价构建、代价聚合、视差计算。这一时期的算法主要致力于设计对光照变化鲁棒的匹配代价（如 Census 变换^[57]、归一化互相关）以及高效的全局优化策略。然而，传统方法均高度依赖于手工设计的特征描述符^[57-59]。受限于手工特征有限的表达能力，这些方法在面对弱纹理、重复纹理及复杂光照环境时，匹配代价往往缺乏足够的辨识度，导致算法鲁棒性显著下降。

进入 21 世纪 10 年代，随着卷积神经网络的爆发，端到端深度神经网络逐渐取代传统方法成为主导范式。这一阶段的主流架构是基于 CNN 的代价体聚合范式^[7,26,60,61]，架构革新主要围绕代价体的构建与优化展开，通过提升匹配代价的表达能力以及代价聚合的鲁棒性大幅提升了立体匹配算法的性能。自 2020 年代以来，受自然语言处理^[62-64] 和光流估计领域^[9] 的启发，立体匹配领域也涌现了类似的思路—基于迭代优化的框架，展现了在精度与效率方面进一步提升的潜力，通过多尺度查找相关性并逐步修正视差，实现了细粒度的匹配，视差估计更加精细化。随着 Transformer 与视觉大模型的发展，Li 等人提出的 STTR^[51] 引入了注意力机制来捕捉长距离上下文依赖，有效解决了 CNN 在感受野上的局限性，特别是在处理无纹理区域的匹配歧义时表现出色。因此，根据网络架构的设计范式与优化策略的不同，现有的基于深度学习的立体匹配方法大致可分为三大主流类别：基于 CNN 代价体聚合的方法、基于迭代优化的方法以及基于视觉 Transformer 的架构。本节将对上述四类方法（含传统方法）的代表性工作逐一介绍，并分析其演进脉络、技术特点及局限性。

（1）传统立体匹配算法

在深度学习兴起之前，立体匹配算法的发展主要围绕鲁棒匹配代价与视差优化模型两个维度展开。针对匹配代价，传统方法通常基于光度一致性假设。然而，面对真实场景中的曝光差异与非均匀光照，简单的绝对差和等度量往往失效。因此，研

究者转向了对辐射变化更具适应性的归一化互相关及非参数统计特征^[58,59]。特别是 Census 变换^[57]，通过编码局部邻域的相对强度顺序，有效抑制了辐射畸变的影响，成为当时应用最为广泛的代价计算算子。

在代价聚合与视差优化阶段，根据平滑性约束引入方式的差异，传统立体匹配算法主要划分为局部、全局及半全局匹配三类范式。局部算法依赖局部视差一致性假设，通过在支撑窗口内累积匹配代价进行聚合，并利用赢家通吃策略确定视差。此类方法计算效率较高^[42,44,65]，但性能对窗口尺度极度敏感：小窗口难以消除弱纹理区域的匹配歧义，大窗口则易导致深度边缘过度平滑，难以兼顾匹配稳定性与几何细节的保持。全局算法通常构建马尔可夫随机场模型，将立体匹配转化为能量函数最小化问题，并利用图割或置信度传播求解全局最优^[66-68]。尽管该类方法在弱纹理及遮挡区域精度显著，但其优化过程通常涉及非确定性多项式难题求解，高昂的计算成本严重限制了其实时应用能力。Hirschmuller^[43]提出的半全局匹配（Semi-Global Matching, SGM）通过沿图像多个方向执行一维动态规划聚合，近似实现了二维全局平滑约束。SGM 有效平衡了全局方法的精度优势与局部方法的计算效率，是深度学习时代之前最具代表性的基准算法。

尽管传统算法建立了完善的几何约束体系，但其性能受限于手工设计特征^[57-59]的表达能力以及固定参数的人工正则化项。在面对弱纹理、重复纹理及镜面反射等病态区域时，传统匹配代价往往缺乏足够的判别力，且难以自适应拟合复杂的场景结构，制约了其在非受控环境下的鲁棒性。

（2）基于 CNN 代价体聚合方法

基于深度学习的立体匹配的演进历程中，代价体的构建与聚合被公认为核心环节。根据聚合网络在维度设计上的差异，现有的端到端架构主要经历了从基于 2D 卷积的探索向基于 3D 卷积的几何感知范式的确立与演进。

早期的探索以 Mayer 等人的 DispNetC^[69]为代表，采用基于 2D 卷积的相关性代价体回归视差。尽管该方法计算高效，但降维操作导致了视差维度几何结构信息的丢失，限制了复杂场景下的精度。为解决这一问题，Kendall 等人提出的 GC-Net^[70]开创性地确立了“特征提取——4D 代价体构建——3D 卷积聚合——视差回归”的端到端几何学习范式，证明了保留完整的几何上下文对于视差回归至关重要。在此范式下，后续研究致力于解决弱纹理区域的匹配歧义。Chang 等人提出的 PSMNet^[71]引入空间金字塔池化（Spatial Pyramid Pooling, SPP）^[71,72]与堆叠沙漏^[73,74]架构，通

过扩大感受野实现了多尺度特征的高效聚合。Zhang 等人的 GANet^[75] 则尝试将传统 SGM 算法可微化, 设计了半全局聚合层以捕捉细长的几何结构与遮挡信息, 进一步提升了非局部几何特征的表达能力。尽管基于 3D CNN 的方法确立了精度标杆, 但处理 4D 代价体带来的立方级计算复杂度与显存占用成为其高分辨率应用的主要瓶颈。为缓解这一矛盾, Guo 等人提出的 GwcNet^[26] 创新性地设计了分组相关策略, 在保留丰富特征语义的同时大幅压缩了通道数, 成功在速度与精度间取得了更优平衡。随后的 CascadeStereo^[14] 与 CFNet^[76] 则引入由粗到精的级联架构, 通过逐级缩小视差搜索空间, 实现了高分辨率下的高效推理。针对卷积网络在物体边界处易产生的平滑效应, 部分工作尝试引入辅助信息以施加显式约束。Yang 等人的 SegStereo^[77] 基于语义边界对应几何边界的假设, 利用语义特征约束平滑区域的视差连续性; 而 Song 等人的 EdgeStereo^[61] 则通过联合优化边缘提取分支与视差回归分支, 利用高频边缘线索引导匹配代价在梯度剧烈区域保持锐利度, 从而改善了物体几何结构。

尽管基于 CNN 代价体聚合的方法通过上述改进在各大基准数据集上取得了优异成绩, 但其核心聚合模块仍存在机理上的固有缺陷。现有的 3D CNN 聚合网络普遍采用空间共享权重的卷积核进行滤波。这种各向同性的聚合机制隐含了一个假设, 即图像中所有区域均服从相似的特征分布规律。然而, 在真实场景中, 这一假设往往导致特征混叠: 在物体边界处, 前景的几何特征被错误地平滑至背景区域, 从而在视差图中产生显著的边缘模糊现象。虽然 SegStereo 和 EdgeStereo 等方法缓解了边缘模糊问题, 但它们引入了新的瓶颈: 高度依赖带有精细标注(如语义标签、边缘真值)的外部数据集, 增加了标注和训练成本; 且辅助任务的预测误差(如错误的语义分割)会不可避免地传播至视差估计中, 产生负面影响。因此主流 CNN 代价体聚合的算法存在难以处理边缘细节的困境, 单纯依赖固定权重的卷积操作难以在保持平滑性的同时保留高频几何细节, 亟须探索一种基于图像内容的自适应聚合策略。

(3) 基于迭代优化框架方法

尽管基于 3D 卷积的代价体滤波方法在很长一段时期内确立了立体匹配的精度标杆, 但其高昂的显存占用与计算复杂度限制了算法在高分辨率图像上的应用。近年来, 受光流估计领域稠密的光流场估计^[78-80] 架构的启发, 立体匹配领域也产生了范式转移: 从基于 3D 代价体的聚合回归, 转向了基于门控循环单元(Gated Recurrent Unit, GRU)的迭代细化架构。这一新范式以其在细粒度匹配以及高分辨率处理上的显著优势, 逐渐成为了当前研究的主流方向。

与传统方法构建庞大的 4D 代价体不同，迭代细化架构的核心思想是将视差估计建模为一个序列的迭代优化过程。其基本流程通常包含三个关键组件：特征提取、多尺度相关性查找以及基于门控循环单元的更新算子。在推理阶段，网络首先初始化一个零视差场（或低分辨率视差场），然后在每一次迭代 k 中，根据当前视差 d_k 在相关性金字塔中索引匹配代价特征，并结合上下文语义特征输入到 GRU 更新模块中，预测视差的残差更新量 Δd_k 。最终的视差结果由多次迭代累加得出：

$$d_{k+1} = d_k + \Delta d_k \quad (1.1)$$

这种多轮迭代优化的策略使得网络能够逐步修正误差，特别是在处理细微几何结构时表现出极高的敏锐度。基于这一范式，学术界涌现出了一系列具有代表性的工作，主要致力于解决真实场景中的匹配难题。Lipson 等人提出的 RAFT-Stereo^[9] 是该领域的奠基之作。它将光流中的全像素对相关性引入立体匹配，利用多级相关性金字塔来捕获不同范围的视差依赖。由于摒弃了显存密集的 3D 卷积，RAFT-Stereo 能够直接在高分辨率下进行推理，显著提升了对细小物体和物体边缘的重建能力，并展现出优异的零样本泛化性能。针对真实世界中普遍存在的相机未严格校正及非刚性形变问题，Li 等人提出了 CREStereo^[81]，该方法设计了基于可变形卷积^[82] 的递归更新模块，并引入了自适应组相关性层，使得网络能够动态调整搜索范围，从而在非理想成像条件下仍能保持鲁棒的匹配精度。为了加速收敛并避免局部极值，IGEVS^[10] 提出了一种混合架构。它首先利用轻量级的 3D CNN 聚合几何编码体，为 GRU 提供一个高质量的初始几何先验，随后再进行迭代细化。这种设计巧妙地结合了代价体滤波的初始视差鲁棒性与迭代优化的局部修正能力，成为了当前性能最优的基准方法之一。尽管基于迭代细化的方法在标准基准（如 Middlebury^[36], KITTI^[83,84]）上取得了令人瞩目的成绩，但在面对更加复杂多变的开放世界场景时，仍面临对局部梯度的过度依赖与病态区域失效的挑战。迭代优化的本质是基于局部梯度下降的搜索过程，在弱纹理、重复纹理或反光区域，局部特征缺乏辨识度，导致相关性金字塔提供的梯度信息存在噪声甚至错误。在缺乏有效全局几何约束或外部先验引导的情况下，GRU 模块极易陷入局部极值，视差预测精度低。

（4）基于视觉 Transformer 的立体匹配架构

尽管基于 CNN 的方法在立体匹配领域取得了显著成效，但其本质上受限于卷积操作的局部感受野。即便是引入空洞卷积^[82,85] 或多尺度池化，CNN 在处理大面

积弱纹理或重复纹理区域时，仍难以有效捕获长距离依赖，导致仍然存在匹配歧义问题。随着视觉转换器（Vision Transformer, ViT）^[86-88] 的崛起，研究者开始利用 Transformer 强大的全局建模能力重构立体匹配流程，形成了一种从局部相关向全局注意力演进的新范式。该范式利用自注意力^[34] 和交叉注意力^[88-90] 机制显式地建模像素间的长距离依赖，显著提升了算法在病态区域的鲁棒性。

作为将 Transformer 引入立体匹配的先驱，Li 等人提出的 STTR^[51] 重新定义了匹配问题的解空间。针对标准 Transformer 全局注意力带来的 $O(N^2)$ 计算复杂度，STTR 巧妙地结合了立体视觉的对极几何约束，将注意力计算限制在对应的极线路径上。这一设计不仅将复杂度降低至线性级别，更强制网络学习遵循物理几何规律的匹配特征。此外，该方法利用交叉熵注意力同时对视差与遮挡进行联合推断，通过施加唯一性约束隐式剔除错误匹配，显著改善了物体边缘的几何完整性。受 NLP 领域 BERT^[91] 模型及视觉领域掩码自编码器^[92] 的启发，立体匹配也开始探索利用大规模无标注数据进行自监督表征学习。CroCo 系列工作^[52,93] 引入了基于 Transformer 的跨视图补全任务。通过随机掩盖参考视图并要求网络利用目标视图信息进行视差预测，CroCo 迫使模型隐式地学习场景的 3D 几何结构与视点对应关系。这种预训练范式大幅提升了模型零样本泛化能力，有效缓解了深度立体匹配对昂贵稠密真值数据的依赖。此外，随着 Swin Transformer^[86] 等分层架构的成熟，部分研究^[94,95] 通过引入移动窗口注意力，在保持计算效率的同时实现了局部细节与全局信息的交互增强。

尽管基于 Transformer 的架构在解决长距离依赖以及跨域泛化性上展现出超越 CNN 的潜力，但其在实际部署中仍面临严峻挑战。首先是计算效率瓶颈：即使采用了极线约束或窗口机制，Transformer 内部密集的矩阵乘法操作在高分辨率场景下仍会产生巨大的显存占用与推理延迟，难以满足自动驾驶等实时系统的需求。其次是数据效率问题：相比于 CNN，Transformer 缺乏平移不变性等归纳偏置，往往需要更加海量的数据驱动。在高精度立体匹配数据相对稀缺的背景下，如何设计轻量化注意力机制或高效的训练策略，仍是该流派亟待解决的关键科学问题。

1.2.2 多视角立体视觉

多视角立体视觉是深度估计的另一项关键技术。与双目立体匹配通常被限制在具有固定基线的双摄系统不同，MVS 旨在从具有重叠视场的任意数量图像序列中恢复场景的稠密三维结构。尽管两者的输入形式存在显著差异——双目立体匹配处理

的是经极线校正后的左右视图对，搜索空间主要位于水平方向上；而 MVS 处理的是相机位姿已知的一组非结构化视图，需要在三维视锥空间内进行深度假设与验证——但从本质上看，两者均基于多视图几何中的对极约束与光度一致性原理。因此，随着深度学习技术的演进，基于学习的 MVS 方法逐渐收敛于一套与立体匹配高度相似的“特征提取——代价体构建——代价聚合——深度回归”通用处理范式。

(1) 基于端到端代价体回归的架构

在深度学习引入 MVS 领域之前，传统方法主要依赖于半全局算法如 PatchMatch 算法的传播与迭代优化。虽然 SurfaceNet^[96] 和 LSM^[97] 等早期工作尝试利用体素网格进行三维重建，但受限于立方级增长的显存开销，仅能处理极低分辨率的物体。Yao 等人提出的 MVSNet^[11] 是该领域的里程碑式工作，它首次将深度立体匹配中的代价体思想迁移至视锥空间，确立了端到端多视角几何学习的基准。MVSNet 引入了基于可微单应性变换的构建策略。它将参考相机的视锥空间离散化为多个平行深度平面，利用已知的相机参数将所有源视图的特征图投影到参考相机的假设平面上。为了处理输入视图数量可变的问题，MVSNet 创新性地提出了基于方差的聚合策略，构建了方差代价体。这种设计不仅确保了对视图数量的排列不变性，还将多视角的几何一致性转化为特征空间的统计分布，最终利用 3D CNN 进行正则化回归。为了突破 MVSNet 的性能瓶颈，后续研究从特征聚合、几何约束与代价体表征形式等多个维度进行了深入探索。在特征聚合层面，P-MVSNet^[12] 引入了基于块匹配的聚合策略，以增强对各向异性表面的法向感知能力；而 UniMVSNet^[98] 则从深度估计的表征问题出发，提出了一种统一的数学表示，通过整合分类与回归的优势来提升代价体的判别能力。在几何约束层面，为了更有效地利用多视图间的极线约束，ESTDepth^[99] 提出了极线时空网络，显式地沿着极线方向捕捉时空关联；EPP-MVSNet^[13] 则设计了一种基于极线聚合的深度预测机制，通过在极线上进行特征聚合来削减冗余搜索空间，从而提升匹配效率与精度。

尽管上述方法在特定维度上优化了多视角深度估计质量，但它们在初始阶段仍依赖于构建完整的 3D/4D 代价体。这种高昂的计算与显存负担，使得单阶段方法依然无法处理高分辨率、大场景的重建任务。

(2) 基于循环正则化的高效架构

为了克服 3D CNN 处理高分辨率代价体时的显存瓶颈，学术界借鉴了自然语言处理和光流领域的序列迭代思想，通过循环迭代优化的策略重构代价体聚合过程。

Yao 等人后续提出的 R-MVSNet^[100] 创新性地利用门控循环单元沿着深度假设方向正则化匹配代价体，以此替代昂贵的 3D 卷积操作。这种设计将显存占用从立方级降低至平方级，使得在受限硬件上处理高分辨率 MVS 序列成为可能。尽管 R-MVSNet 解决了显存问题，但循环神经网络在空间维度的上下文聚合能力弱于 3D CNN，导致重建结果常常出现扭曲畸变。在此基础上，后续研究致力于进一步解决循环架构中存在的上下文丢失与计算冗余问题。针对 R-MVSNet 因循环神经网络空间聚合能力不足而产生的条纹伪影，D2HC-RMVSNet^[101] 设计了一种高密度的混合连接架构，在循环单元内部保留轻量级 3D 卷积以捕获局部几何细节，同时利用循环反馈更新全局依赖。为了进一步提升计算效率，RIAV-MVS^[102] 提出了一种基于循环索引的非对称代价体，它根据物体表面的稀疏特性动态分配计算资源，有效避免了对无纹理区域的有效重复扫描。MVS2D^[15] 则另辟蹊径，利用局部注意力机制完全替代了 3D 卷积，在保持极低显存占用的同时实现了高效的深度推断。

除了沿深度方向的序列扫描，另一类方法则借鉴了光流估计中的迭代优化思想，利用循环单元对深度图进行由粗到精的逐步微调。IterMVS^[103] 提出了基于 GRU 的迭代概率估计模块，它不再一次性回归深度，而是通过编码像素级的概率分布残差来迭代地优化深度图质量。类似地，受立体匹配领域启发，IGEV^[10] 构建了迭代几何编码体，利用多尺度 GRU 单元在更新过程中不断注入几何上下文信息，从而在处理弱纹理和细微结构时表现出更强的鲁棒性。这种迭代细化的范式在平衡显存效率的同时，显著提升了多视角深度估计的精度。

(3) 基于由粗到精的级联架构

相比于循环架构，基于金字塔结构的级联策略因其在并行推理速度与高频细节重建上的显著优势，逐渐成为了主流方案之一。此类方法的核心思想遵循由粗到精的范式：先在低分辨率下预测粗略深度，再在高分辨率下逐步细化。Yang 等人提出的 CVP-MVSNet^[104] 首先构建了基于代价体金字塔的架构，通过逐级缩小深度搜索范围来迭代提升精度。Gu 等人提出的 Cascade-MVSNet^[14] 进一步将其标准化为特征金字塔与级联代价体结构，利用上一级的预测结果动态调整下一级深度假设的范围，这种自适应采样策略显著提升了计算效率并保持了深度精度。

在此基础上，后续研究重点致力于优化级联过程中的搜索策略与几何一致性。针对固定深度范围无法覆盖真实场景深度分布的问题，UCS-Net^[105] 引入了不确定性感知机制，利用方差估计动态调整每一级的搜索区间，实现了计算资源的自适应分

配。为了进一步提升几何约束的鲁棒性，GC-MVSNet^[106]提出了一种多尺度几何一致性损失，强制不同分辨率层级的深度预测保持一致，有效抑制了级联过程中的误差累积。ETV-MVS^[107]则针对复杂场景中的遮挡问题，设计了基于极线的鲁棒可见性感知模块，将极线几何约束融入级联代价体构建中，确保了在深度细化过程中对不可见区域的有效过滤。

除了优化搜索空间，另一条研究主线在于增强级联架构中的特征表征能力。传统的卷积特征难以建模长距离依赖，为此，CT-MVSNet^[108]创新性地在线联阶段引入了跨尺度 Transformer，利用全局注意力机制捕获不同分辨率间的上下文依赖，从而在粗糙深度图中保留了更多全局语义。此外，针对特征聚合过程中的噪声干扰，^[109]提出了基于坐标注意力的自适应聚合机制，通过同时关注空间位置与通道信息，增强了网络在弱纹理区域对关键特征的提取能力，进一步提升了级联重建的完整性。

(4) 基于 Transformer 与全局上下文感知的架构

近年来，随着 ViT^[87,110] 的兴起，MVS 研究开始利用其强大的长距离建模能力来克服 CNN 局部感受野的局限性，从而解决弱纹理等病态区域的匹配歧义问题。

早期的探索主要集中在利用注意力机制增强特征匹配的鲁棒性。Ding 等人提出的 TransMVSNet^[111]创新性地设计了特征匹配 Transformer，通过自注意力聚合图像内的全局上下文，并利用交叉注意力在不同视图间聚合几何线索，大幅提升了特征的表达能力。为了在保持全局感受野的同时降低计算复杂度，Wang 等人提出的 MVSTER^[112]利用立体视觉固有的几何先验，构建了极线 Transformer，该方法将交叉注意力的搜索范围限制在极线所在的 2D 区域内，既保证了沿极线的长距离几何关联，又极大地提升了匹配效率。类似地，WT-MVSNet^[113]引入了基于窗口的注意力机制来减少冗余计算，而 Zhu 等人的 MVSTR^[114]则构建了全局视点 Transformer，直接在多视图特征之间建立稠密的长距离依赖。

除了特征层面的改进，部分研究开始尝试用 Transformer 重构代价聚合阶段。传统的 3D CNN 聚合方式虽然有效，但缺乏对代价体内部长距离上下文信息的捕捉能力。为此，CostFormer^[115]提出了一种残差深度感知代价 Transformer，直接在 3D 代价体上应用注意力机制。该方法通过在深度维度和空间维度上分别进行聚合，实现了比传统 3D 卷积更高效、更具全局视野的代价体正则化。随着视觉基础模型的快速发展，利用大规模预训练先验成为新的趋势。Cao 等人提出的 MVSFormer^[116]率先将预训练的 ViT（如 ViT-Twins^[116]）作为特征提取骨干，利用其在大规模数据上学

习得到的强语义先验来辅助几何匹配。在此基础上, MVFormer++^[117] 进一步引入了视锥位置编码与相邻视图注意力机制, 解决了 Transformer 在深度假设数量变化时的外推性难题, 并刷新了多项基准纪录。

尽管上述 MVS 方法在 DTU^[118]、Tanks and Temples^[119] 等静态基准数据集上取得了极高的重建精度, 但其在面向真实开放场景时, 仍存在显著的局限性, 主要体现在以下两个方面:

(1) 对相机位姿精度的强依赖: 现有的 MVS 算法通常建立在相机位姿精确已知的理想假设之上。然而, 在自动驾驶或无人机巡检等真实场景中, 相机位姿通常由 SLAM 前端或运动恢复结构算法提供, 不可避免地包含旋转或平移噪声。正如^[60]所指出的, 微小的位姿偏差会直接破坏光度一致性假设, 导致构建的代价体出现系统性偏差, 进而引发深度预测的严重偏差。

(2) 跨域泛化能力不足: 无论是基于 CNN 还是 Transformer, 大多数方法仍高度依赖于带有稠密真值的训练数据。当从室内场景迁移到室外大尺度场景, 或遇到动态物体干扰时, 单纯依赖多视几何约束的模型往往表现出脆弱性, 缺乏足够的鲁棒调节机制, 导致在域差异大时的泛化性能大幅下降。

1.2.3 结构先验增强的立体视觉深度估计

尽管基于深度学习的立体匹配与多视角立体视觉在标准基准上取得了显著进展, 但其本质上仍依赖于多视图间的光度一致性与几何约束。在弱纹理(如白墙)、反光(如玻璃)、透明物体或重复纹理等病态区域, 局部匹配线索往往存在歧义或者失效, 从匹配角度出发就是很难获取精确解, 导致深度预测含有噪声或严重的几何畸变。为了克服主要基于几何匹配的局限性, 学术界开始尝试引入额外的结构先验——即利用图像本身蕴含的语义、边缘或单目几何线索, 为立体匹配提供全局上下文约束。根据先验信息的模态与引入机制, 该领域的研究主要经历了以下三个发展阶段。

(1) 基于边缘与平面先验的几何约束

早期的结构增强尝试主要聚焦于利用显式的几何先验——即边缘与平面——来对视差图进行正则化, 旨在解决物体边界处的边缘模糊以及大面积弱纹理区域的匹配歧义问题。在边界约束方面, EdgeStereo^[61] 提出了一种多任务学习框架, 通过引入专门的边缘检测分支, 利用边缘图显式地指导视差梯度的平滑性。该方法证明了高质量的边缘先验能够有效保持物体轮廓的锐利度, 显著缓解了传统代价聚合导致

的边界模糊问题。为了进一步利用真实场景中隐含的几何规则属性, PL-Stereo^[120] 将约束从像素级边缘扩展至直线段, 利用线特征的连通性进一步提升了视差的一致性。在表面约束方面, 针对室内场景中普遍存在的平面结构, SPS-Stereo^[121] 与 PatchMatch Stereo^[122] 尝试利用超像素分割或倾斜支持窗口, 将逐像素的视差估计转化为局部平面参数的优化问题。这种基于分段平面的强几何假设在处理墙面、地板等大面积无纹理区域时极为有效。然而, 其局限性也显而易见: 在面对复杂曲面或非规则物体时, 强制的平面拟合往往会导致细节丢失, 表现出明显的过度平滑现象。

(2) 基于语义分割的上下文引导

随着语义分割技术的成熟, 利用高层语义信息来辅助几何匹配已成为提升重建鲁棒性的有效途径之一。语义标签不仅隐含了物体的类别属性, 还提供了强有力的物体边界与区域一致性约束。SegStereo^[77] 率先提出了一种联合语义分割与立体匹配的学习框架, 通过共享特征提取器并将语义特征嵌入深度分支, 利用语义的一致性有效缓解了匹配歧义。例如, 属于同一车辆类别的像素在深度上应当具有连续性, 而天空区域深度则应该是无穷远。

在此基础上, 后续研究致力于挖掘语义信息在特定困难场景与不同细粒度下的引导作用。SGNet^[123] 与 RTS2Net^[124] 设计了语义引导模块, 根据语义类别自适应地调整视差搜索范围与正则化权重, 利用语义边缘作为视差预测在边缘处的惩罚项, 并利用内部一致性填补空洞。针对传统匹配最难以解决的弱纹理区域问题, TSAR-MVS^[125] 进一步提出了纹理感知分割与相关性细化策略。该方法利用语义掩膜显式地定位弱纹理区域(如墙面、路面), 并引入相关性细化模块在这些区域施加更强的几何约束, 有效抑制了平面区域的噪点。

为了克服语义标签过于稀疏且难以描述物体内部细节的缺陷, MSP-MVS^[126] 创新性地引入了多粒度分割先验, 它不再局限于单一的语义类别, 而是结合了超像素与语义类别的分层约束, 在保持物体边界锐利的同时, 捕捉物体内部的细微几何变化。此外, Xu 等人^[127] 则将分割思想拓展至自监督领域, 提出了一种基于共分割的 MVS 框架。该方法利用多视图间的物体共视区域来挖掘潜在的语义一致性, 在无需昂贵语义标注的情况下, 通过数据增强与辅助任务实现了几何与语义的协同优化。尽管语义先验在物体边界与特定区域提供了有效的正则化, 但其本质上仍属于离散的类别标签。即使引入了多粒度机制, 现有的语义信息仍难以完美描述复杂的连续几何形状(如汽车引擎盖的曲率)。此外, 联合学习框架往往面临误差级联的风险,

即语义分割网络在未见场景中的预测错误, 极易误导视差估计模块, 导致重建结果反而受限于语义分割网络。

(3) 基于单目深度估计的几何辅助

相比于稀疏的边缘或离散的语义标签, 单目深度估计^[19–25, 128–134]能够提供稠密的、像素级连续的结构先验。尽管单目深度存在本质的尺度模糊问题, 但凭借其对单张图像的全局语义理解, 能够极其鲁棒地恢复场景的相对几何结构。这种特性与立体匹配在局部对应关系上的精确度量能力形成了天然的互补。为了充分利用这一互补优势, 研究者从特征增强、搜索空间优化及几何约束等多个维度探索了单向辅助的融合策略。在特征与上下文融合方面, 早期的^[135]采用简单的通道拼接策略, 将单目特征直接注入立体匹配网络以增强表征; 为了提供更精细的结构引导, CLStereo^[136]引入了独立的单目分支, 将几何上下文传输至立体匹配网络作为正则项;^[137]则通过融合单视图提取的精细局部结构与多视图的鲁棒几何线索, 显著改善了大视差与高梯度区域的匹配性能。在搜索空间优化方面, MaGNet^[138]利用单目深度作为初始假设来缩小视差搜索范围。在几何约束与细化方面, 基于上下文约束的^[139]将单目深度作为正则项, 强制双目视差的梯度方向与单目先验保持一致; LoS^[140]则利用单目深度生成局部的倾斜平面先验, 显式地指导视差的迭代细化。近期, 随着视觉基础模型的兴起, FoundationStereo^[141]利用侧调技术, 成功将 DepthAnythingV2^[25]等大模型中习得的强单目先验适配到立体匹配任务中, 进一步增强了模型的泛化能力。

尽管上述引入结构先验的方法在一定程度上提升了立体匹配的鲁棒性, 但现有的融合方案在面对开放世界场景时仍面临严峻挑战。绝大多数方法局限于单向流架构, 即仅利用单目信息单向辅助双目匹配。然而, 单目深度在未知场景中普遍存在尺度漂移与偏移误差。当通过简单的拼接或正则化进行融合时, 单目先验中错误的尺度信息往往会错误引导双目匹配的度量精度, 尤其是在纹理丰富的区域, 错误的先验反而成为噪声源。理想的融合架构应当建立一种双向互优化机制: 不仅利用单目先验指导病态区域的匹配, 更应允许立体几何的精确度量能够作为引导以校正单目深度的尺度偏差, 从而实现两者优势的动态互补与联合提升。

1.2.4 前馈式三维重建

传统的立体视觉、多视角立体视觉系统通常高度依赖于多阶段的复杂流水线。尽管这些方法在受控场景下能够取得极佳的局部几何精度, 但由于缺乏整体的几何

约束，在面对长时序以及超大场景重建时易出现重影、扭曲等多帧几何不一致性等现象。近年来，随着视觉大模型和注意力机制的发展，3D 视觉领域涌现出了一种全新的前馈式三维重建范式。该类方法旨在通过构建统一的端到端深度神经网络，在单次前馈推理中直接从任意数量的无约束图像集中联合回归出稠密几何结构（如深度图、点云）和相机位姿，彻底免去了推理时的迭代优化以及多帧点云的融合过程。

这一方向的代表性突破始于 DUST3R^[142]，其创新性地将多视角三维重建转化为点云回归问题。随后，研究界在多视角扩展和高效序列处理上取得了飞跃式进展。其中，最具代表性的是视觉几何基础 Transformer 模型 VGGT^[143]。VGGT 采用极其简化的网络架构，首先利用 DINOv2 提取图像的隐式特征，随后通过交替进行的帧内局部注意力和全局跨帧注意力模块，隐式地学习深度与遮挡线索。该模型能直接从未标定视角的图像中同时输出高精度的相机内参、外参、稠密深度图和三维点云，在多项 3D 视觉基准上超越了传统的优化类基线方法。基于此路线，后续还涌现了如解决大规模长序列扩展问题的 VGGT-long^[144] 等前沿工作。前馈式三维重建大模型证明了通过海量数据驱动的全局注意力机制，可以直接隐式地构建 3D 几何表达。然而，完全端到端的前馈模型在实际自动驾驶等边缘计算设备中，往往面临计算资源开销大、对极端未知域泛化性不可控等问题。并且其优势在于获取完整一致性的场景几何，但是对于局部深度精度是低于立体视觉方案。相比之下，立体视觉深度估计方案保留了经典立体几何约束的可解释性与轻量化优势，从而能够获取更精准的局部绝对深度，更加适用于部署在移动端并且对深度精度要求更高的下游任务。

1.2.5 视觉里程计

视觉里程计（Visual Odometry, VO）^[145-148]旨在通过分析连续图像序列，估计载体在三维空间中的六自由度的运动轨迹。作为 SLAM^[37-41]系统的前端，VO 经历了从传统几何驱动到深度学习驱动的范式演变。根据网络架构设计与几何约束引入方式的不同，现有基于深度学习的单目视觉里程计主要可分为：基于端到端位姿回归的方法、基于迭代优化的方法以及基于深度先验增强的混合方法。

（1）传统几何视觉里程计

在深度学习介入之前，视觉里程计的研究主要建立在多视图几何与非线性最小二乘优化理论之上。根据对图像信息利用方式的不同，传统方法可进一步细分为基于特征点的方法与直接法。

基于特征点的方法基本遵循“特征检测—描述子匹配—极线几何约束—光束法平差优化”的标准步骤。PTAM^[149]最早提出了并行跟踪与建图的框架，将实时位姿追踪与后端地图优化解耦。ORB-SLAM 系列^[40,150]是该流派的集大成者，它利用具有旋转与尺度不变性的 ORB 特征，构建了包含追踪、局部建图与闭环检测的三线程架构，在静态场景下展现了极高的精度与鲁棒性。然而，特征点法高度依赖于图像纹理的丰富度与角点的可重复性，在弱纹理、运动模糊或光照剧烈变化的场景下，特征追踪极易丢失，导致系统崩溃。为了克服特征点法的稀疏性缺陷，直接法直接利用图像像素的灰度信息构建光度误差进行优化。LSD-SLAM^[38]实现了半稠密直接法建图，而 DSO^[39]则通过在具有强度梯度的像素点上联合优化光度参数与几何结构，展示了在低亮度以及弱纹理环境下的优越性能。尽管如此，直接法基于严格的灰度不变性假设，对卷帘快门效应及非朗伯体反射极为敏感，且难以处理动态物体干扰。

(2) 端到端视觉里程计

为了突破传统几何方法的局限性，早期的深度 VO 探索采用了端到端回归的范式。此类方法通常利用卷积神经网络将连续帧图像直接回归出相对位姿，网络内部充当了一个隐式的几何求解器。无论是基于真值的监督训练，还是基于光度误差的自监督训练，其推理时的网络结构往往高度一致。DeepVO^[147]是该架构的开山之作，它利用 CNN 提取视觉特征，并结合循环神经网络^[62]建模时序依赖，直接回归 6 自由度的位姿。TartanVO^[151]则通过在大规模合成数据上训练通用的回归网络，证明了该架构在应对剧烈光照变化与动态干扰时的鲁棒性远超传统方法。以 SfMLearner^[152]为代表的工作，虽然采用了自监督训练范式，但其核心的位姿估计模块 PoseNet^[153]依然遵循直接回归的架构。此类方法通常联合训练一个深度网络和一个位姿网络，利用视图间的光度误差作为监督信号。直接回归架构虽然推理速度极快，但缺乏几何可解释性。网络倾向于记忆训练集的运动模式而非学习通用的几何规则，导致跨场景泛化能力较差。此外，由于推理过程中缺乏显式的几何约束（如光束法平差），长序列轨迹极易产生不可控的累积误差。

(3) 基于迭代优化的视觉里程计

为了解决直接回归位姿方法的黑盒问题，近年来，深度学习和传统算法优势相结合的混合新架构成为主流。此类方法受光流网络 RAFT^[78]的启发，将传统几何中的代价体与迭代优化操作显式地嵌入到前端网络中。DROID-SLAM^[154]是该流派的代表作。它通过构建稠密的 4D 相关性代价体来计算特征匹配关系，网络利用门控循

环单元来更新匹配，在推理过程中执行可微的稠密光束法平差层来优化位姿。这种设计使得网络能够像传统方法一样利用几何约束修正轨迹，同时保留了基于深度学习的特征匹配的鲁棒性。针对稠密代价体计算量大的问题，DPVO^[155] 引入了稀疏块匹配机制，仅在关键块结构区域构建相关性并进行迭代优化。GO-SLAM^[156] 则进一步将这种深度迭代优化的思想扩展到了全局后端。这一流派目前代表了 VO 性能的最高水平，但其核心仍依赖于图像间的纹理相关性，在极端无纹理区域仍面临挑战。

(4) 基于先验增强的视觉里程计

单目视觉里程计面临的一个本质难题是尺度不确定性。为了恢复真实的物理轨迹，利用单目深度估计网络提供的深度图作为几何先验来辅助 VO 优化，成为一种独特的架构分支。早期的 CNN-SLAM^[157] 和 DVSO^[158] 尝试将单目深度预测作为虚拟观测值引入优化方程，利用深度网络学到的先验知识来约束单目尺度。D3VO^[159] 则进一步利用深度网络预测的不确定性图，对光度误差项进行加权，从而在优化中剔除动态物体或噪声区域的影响。随着 Metric3D^[24] 等零样本绝对单目深度估计模型的发展，引入绝对尺度深度先验成为可能。然而，现有架构存在一个致命缺陷，即对先验质量的高度敏感性。当深度估计模型在域偏移较大导致严重噪声时，错误的深度先验会直接给视觉里程计后端带来极大的负优化。因此，如何设计一种能够自适应过滤噪声先验、并鲁棒地融合度量深度信息的混合架构，是实现高精度、真尺度的单目视觉里程计的关键，也是本文的研究重点。

1.3 存在的问题

尽管基于立体视觉的深度估计技术在理论层面已具备严密的数学基础，并在受控环境下取得了令人瞩目的精度，但在面向真实、开放且动态的复杂场景时，现有的基于匹配的范式仍受制于成像条件、数据分布及模型假设的局限性。具体而言，该领域目前面临以下四个深层次的技术与应用难题。

(1) 视觉退化场景匹配难题

基于立体视觉（双目立体匹配与多视角立体视觉）的核心在于对应点搜索和匹配，其前提是图像局部特征具有高度的辨识度和区分度。然而，在真实场景中，这一前提常因物理属性与算法局限而被打破，也就是视觉退化场景匹配难题。首先是光度一致性假设的失效，在弱纹理（如白墙、路面）、重复纹理（如栅栏、地砖）或

高光反射（如玻璃、金属表面）区域，图像局部梯度信息严重缺失或被噪声严重干扰。基于卷积神经网络的标准特征提取器在这些区域往往提取出区分度很小或者高噪声的特征表示，导致代价体中出现多峰分布或平坦分布，这种多种深度概率的模糊性导致无法获得正确的匹配，进而导致视差预测精度大幅度下滑，鲁棒性差。其次是几何结构与感受野的矛盾，主流的深度估计网络通常采用全局共享的参数去平等处理所有图像区域。然而，物体边缘与平滑内部具有截然不同的频率特性。在物体平滑区域，为了聚合足够的上下文信息以消除大面积的歧义，网络往往需要较大的感受野去聚合周围信息。但这种特性在物体边界处，会导致来自前景与背景的特征产生混合干扰，引发边缘模糊现象，即前景物体的轮廓向背景扩张，导致精细几何结构的丢失。这种对所有区域完全相同的处理机制会导致特征的表达能力弱，难以兼顾平滑区域的连贯性与边缘区域的锐利度。

（2）跨域未见场景泛化弱难题

深度学习模型的性能高度依赖于训练数据的分布特性，而立体视觉深度估计任务中存在着严重的合成-真实域偏差。与人类视觉能够利用语义知识和几何先验辅助预测深度不同，纯几何驱动的立体匹配网络主要学习的是局部纹理的相似性模式。当测试场景的纹理风格（如从卡通风格的 Scene Flow^[69] 到真实自动驾驶场景 KITTI^[83,84]）或光照条件发生变化时，网络提取的特征分布会产生巨大差异，导致原本有效的匹配规则失效。而在真实动态场景中获取立体几何的像素级稠密真值深度极其昂贵且困难（通常依赖激光雷达，但存在稀疏与遮挡问题，并且含有噪声）。这迫使现有模型严重依赖合成数据进行训练。然而，合成数据无法完美模拟真实世界的光学透镜畸变、传感器噪声及复杂的材质反射属性。因此，在合成域上训练收敛的模型，往往在未见过的真实场景中表现出极差的零样本泛化能力，难以满足自动驾驶等开放世界应用对通用性的苛刻要求。

（3）非理想观测条件下抗噪能力弱难题

立体视觉深度估计算法的核心基石在于极线约束，即源视图中的像素在目标视图中的对应点严格分布于由相对位姿确定的极线上。这一强几何约束的有效性建立在两个苛刻的前提之上：一是相机内参与外参的绝对精确性；二是场景必须满足静态刚体假设。然而，在实际的开放场景应用中，这两大前提往往难以同时满足。一方面，相机参数通常依赖于 SLAM 前端或机械标定提供，不可避免地伴随测量噪声，这种几何失准会导致源像素投影后的极线与真实对应点发生偏离。另一方面，真实

环境中普遍存在行人、车辆等动态物体，在此类非静态刚性区域，基于静态位姿假设构建的几何约束不仅完全失效，还会被网络误判为极大的匹配代价，导致动态物体干扰静态区域的深度估计。现有的深度估计框架往往缺乏对这种几何可靠性的自适应感知与鲁棒机制，使得系统在面对非理想观测条件（如标定漂移或动态干扰）时，极易出现匹配失效或伪影重建。

（4）单目视觉里程计的尺度模糊与累积漂移难题

视觉里程计旨在利用连续图像帧间的信息关联，通过最小化重投影误差或光度误差来求解相机的相对位姿变化。然而，在轻量化的单目视觉系统中，由于缺乏基线约束，系统存在固有的尺度模糊。单目图像仅能提供相对深度线索，无法恢复真实的物理度量。虽然深度学习模型可以从大量数据中隐式学习尺度先验，但在长序列推理过程中，这种隐式尺度极易随环境变化而发生漂移，导致构建的地图与真实世界完全不在一个尺度下。为了解决尺度问题，引入海量数据预训练的深度估计网络的预测结果作为先验是一种比较好的解决方案。然而，现有的优化后端通常假设先验信息服从高斯分布且较为准确。实际上，单目深度预测不可避免地包含由于域偏移导致的尺度和偏移误差。若缺乏有效的噪声过滤与不确定性建模机制，强行将错误的深度先验融入光束法平差（Bundle Adjustment, BA）优化，反而会破坏几何一致性，给轨迹预测带来负优化。

1.4 研究内容与结构安排

1.4.1 本文的研究内容

本文紧密围绕“面向复杂开放场景的立体视觉深度估计及应用”这一核心命题展开系统性研究。在自动驾驶、机器人导航等实际应用中，基于立体视觉（含双目立体匹配与多视角立体视觉）的深度估计技术虽然具备恢复绝对度量的理论优势，但在从受控实验室走向复杂开放世界的过程中，面对纹理特征匮乏、几何结构复杂、观测条件非理想（如相机参数噪声、不满足静态刚体假设等）以及跨域场景变换时，仍面临着鲁棒性与泛化性的严峻挑战。

针对上述瓶颈，本文遵循“基础特征表示优化（精度）→跨域泛化性能提升（泛化性）→非理想条件鲁棒增强（鲁棒性）→定位应用转化（下游应用）”的层层递进逻辑，提出了一系列创新性的网络架构与方法。本文的主要研究内容概括为以下

四个方面：

(1) 视觉退化场景下区域分治的高精度立体匹配方法

针对立体匹配任务在弱纹理、反光、透明物体等病态区域以及物体边缘处面临的视觉特征匹配难导致精度低的问题，本文提出了一种基于区域分治和注意力机制的特征增强立体匹配方法。该研究旨在解决立体匹配中最基础、最核心的特征表示难题。

- 问题剖析：现有主流方法通常采用共享权重的卷积神经网络对全图进行均一化处理。然而，物体边缘的高频信息与平滑区域的低频信息对感受野的需求截然不同。全局统一的卷积操作往往导致前景与背景特征的混合干扰，引发严重的边缘模糊现象，而局部感受野的不足又会导致弱纹理区域的匹配歧义。
- 核心贡献：本文设计了区域分治策略，根据图像梯度的分布特性将场景自适应划分为细节区域与平滑区域。在边缘等细节区域，引入局部注意力机制，利用其内容自适应特性保持特征锐利的几何结构，从根本上抑制边缘模糊；在平滑区域，利用金字塔池化模块与大核卷积高效聚合多尺度上下文信息，消除局部匹配歧义。除了对不同区域特征实行区域分治策略，针对卷积操作在代价聚合阶段只能捕获局部依赖的缺陷，本文提出了视差维度的全局注意力机制，实现了特征在视差空间的全局交互。该方法在大幅提升边缘与病态区域匹配精度的同时，有效平衡了计算效率，为后续章节的研究提供了高精度的基础匹配器。

(2) 跨域场景下单目-双目协同迭代的高泛化立体匹配方法

针对纯几何匹配算法依赖光度一致性，导致在纹理缺失区域易失效，以及在未见场景中因域偏差导致泛化性能急剧下降的瓶颈，本文提出了一种基于单目先验和双分支迭代优化的高泛化立体匹配算法。该研究致力于利用单目语义线索突破纯几何匹配的泛化边界。

- 问题剖析：单目深度估计具备强大的语义结构感知能力，对纹理依赖低，但缺乏绝对尺度；立体匹配具备精确的度量恢复能力，但对纹理依赖高。现有方法未能有效结合两者的互补性，往往导致“强强难以联合”。
- 核心贡献：本文构建了双分支互优化架构，深度挖掘单目深度（强结构、弱度量）与立体匹配（弱结构、强度量）的互补潜力。设计了立体引导对齐模块，利用高置信度的立体几何线索动态估计尺度因子与偏移量，校正单目深度的度量偏差；反之，通过单目引导优化模块，将校正后具备精确几何结构的单目特

征注入立体匹配网络，引导其在病态区域的优化收敛。该方法不仅进一步改善了病态区域的匹配难问题，更显著提升了算法在跨域条件下的零样本泛化能力，实现了从特定场景模型向通用场景模型的跨越。

(3) 非理想观测下单目-多视角融合的抗噪深度估计方法

针对立体视觉过度依赖相机参数精度，在位姿噪声、标定误差或动态物体干扰下极易出现几何约束失效的问题，本文提出了一种基于单目、多视角自适应融合的抗噪增强深度估计框架。本研究旨在突破主流立体视觉方法依赖严格几何校正的限制，将多视角立体视觉深度估计的适用范畴从理想的精确标定环境，成功拓展至参数受扰，甚至包含动态干扰的非理想观测环境。

- 问题剖析：传统 MVS 算法假设相机位姿精确已知且场景为静态刚体。在实际应用中（如 SLAM 前端提供的位姿），参数噪声不可避免，且动态物体破坏了极线约束。这会导致构建的代价体出现系统性偏差，使得深度估计结果崩溃。
- 核心贡献：本文突破了多视角立体视觉方法严重依赖精准相机参数的限制，设计了基于重投影一致性的自适应融合机制。通过构建像素级的置信度图，实时评估多视角几何约束的可靠性。系统采用动态筛选策略：在相机参数准确以及光度一致性高的区域，充分利用多视角几何的高精度优势；在参数噪声较大、存在动态干扰或遮挡的区域，自适应切换至鲁棒的单目深度分支。该方法有效解决了深度估计系统在真实复杂环境中因非理想观测条件导致的鲁棒性难题，大幅降低了对相机参数精度以及静态刚体假设的依赖。

(4) 深度先验赋能的视觉里程计

针对深度估计技术的应用赋能问题，即单目视觉里程计存在本质的尺度模糊问题，且在剧烈运动或动态场景下鲁棒性差的瓶颈，本文提出了一种基于深度先验增强与几何迭代的单目视觉里程计框架。该研究实现了从感知到定位的价值转化与系统闭环。

- 问题剖析：单目视觉里程计无法恢复真实物理尺度，且长序列运行中容易产生尺度漂移。单纯引入深度图作为先验时，若先验本身存在噪声或尺度误差，反而会破坏位姿优化的稳定性。
- 核心贡献：本文将前述章节获取的高质量度量深度和多视角几何先验，显式地引入到里程计的初始化与光束法平差优化中，赋予单目系统绝对尺度感知能力。创新性地引入了迭代光流模式，建立了深度估计与位姿解算之间的双向耦合机

制，使得深度与位姿能够通过稠密光流这一桥梁进行交替优化、互相促进。此外，提出了噪声增强训练策略和自适应深度筛选机制，使系统能够智能辨识并剔除不可靠的先验干扰。实验表明，该方法在剧烈运动及动态场景下仍能保持稳健的定位与建图，有效解决了传统单目视觉里程计的尺度漂移问题并大幅提升了系统鲁棒性，验证了本文提出的深度估计方法在实际系统中的应用价值。

1.4.2 论文组织结构

本文共分为六章，各章节之间逻辑紧密、层层递进，共同构成了一个完整的三维视觉感知与定位研究体系。图 1.3 展示了本文的章节组织结构与逻辑关系。具体章节安排如下：

第一章：绪论。本章首先阐述了课题的研究背景与意义，重点分析了高精度三维感知在智能系统中的战略地位。随后，系统综述了立体匹配、多视角立体视觉及视觉里程计的国内外研究现状，深入剖析了现有技术在视觉退化场景、跨域泛化、抗噪鲁棒性及应用转化等方面面临的主要挑战，从而引出本文的研究动机、主要研究内容及组织结构。




图 1.3 本文的组织结构。

第二章：视觉退化场景下区域分治的高精度立体匹配方法。本章重点解决基础

匹配任务中退化场景的特征表示问题。详细介绍了区域分治策略、局部/全局注意力机制的设计原理，并在 Scene Flow、KITTI 等主流数据集上验证了该方法在提升基础特征表示精度方面的有效性。本章提出的高精度匹配器是后续泛化与鲁棒性研究的坚实基础。

第三章：跨域场景下单目-双目协同迭代的高泛化立体匹配方法。本章重点解决泛化性能问题。针对第二章所述纯几何方法在弱纹理及未见场景下的局限性，本章进一步引入单目语义先验。详细阐述了双分支互优化架构、立体引导对齐与单目引导优化模块的实现细节，展示了方法在提升零样本泛化能力上的优越性，实现了模型从特定域到通用域的扩展。

第四章：非理想观测下单目-多视角融合的抗噪深度估计方法。本章重点解决非理想观测条件下的鲁棒性问题。将研究场景从理想的精准相机参数以及静态刚体假设条件下扩展至非理想的真实应用场景，包含相机参数噪声以及动态物体干扰等。详细介绍了重投影一致性评估模型与自适应融合机制，验证了系统在噪声位姿及动态场景下的抗干扰能力，确保算法在真实世界应用的鲁棒性。

第五章：深度先验赋能的视觉里程计。本章重点解决立体视觉深度估计下游应用赋能的问题。本章将前述章节获取的高质量深度信息应用于下游定位任务，详细介绍了度量深度先验的引入方式、迭代光流优化策略、噪声增强训练及自适应筛选机制。通过对比实验，验证了其在实际定位与建图任务中的效能，实现了从深度感知到空间定位的技术闭环。

第六章：总结与展望。本章对全文的研究成果与创新点进行系统总结，客观分析现有工作在多模态输入、极端环境适应性等方面存在的局限性，并结合人工智能大模型的发展趋势，对三维视觉感知的未来研究方向进行展望。

2 视觉退化场景下区域分治的高精度立体匹配方法

2.1 引言

人类对三维空间的感知源于双目视觉机制。视网膜接收的两幅具有微小视差的图像，经由视皮层解码，构建出对外部世界的深度认知，这是人类进行导航、避障及环境交互的生理基础。在计算机视觉领域，赋予机器类似的深度感知能力始终是核心研究课题。立体匹配技术作为模拟这一机制的关键手段，旨在通过解算校正后左右视图间的像素级对应关系，利用三角测量原理恢复场景的稠密深度信息。当前，随着自动驾驶、智能机器人及增强现实等技术的快速演进，高精度、高鲁棒性的三维感知已成为系统落地的关键制约。相比于激光雷达与结构光，基于被动视觉的立体匹配方案凭借其低成本、高分辨率、纹理丰富及抗干扰性强等优势，成为学术界与工业界关注的焦点。

近几十年来，立体匹配技术的发展历程见证了从手工特征到深度表征的范式转移。传统算法受制于光度一致性假设与浅层平滑先验，在弱纹理、反光及遮挡等复杂场景下难以获取可靠视差。随着深度学习的介入，基于 CNN 的解决方案彻底突破了这一瓶颈。GC-Net^[70]、PSMNet^[7] 及 GwCNet^[26] 等先驱工作，通过建立端到端的可微架构，利用海量标注数据驱动特征提取器与代价聚合网络的高效学习。这些方法成功确立了包含特征提取、代价体构建、正则化聚合及视差回归的标准化流程，在 KITTI^[83,84] 与 Scene Flow^[69] 等主流评测中展现出优异性能，使得从双目图像恢复高精度亚像素深度成为可能。尽管深度学习推动了立体匹配性能的跃升，但在真实世界的复杂视觉退化场景中，现有主流算法仍存在局限。特别是在处理细微几何结构（如树枝、栏杆）、镜面反射及大面积弱纹理区域时，如何兼顾匹配精度与计算效率，依然是亟待解决的难点。针对上述问题，本章旨在通过剖析卷积神经网络与注意力机制的互补特性，探索一种高效且精准的特征增强与匹配新范式。

深入剖析当前的主流立体匹配算法，可以发现其性能瓶颈主要源于基础算子的内在属性与图像内容分布特性之间的不匹配，主要体现在以下矛盾与局限：

(1) 卷积操作的平移不变性与边缘细节的矛盾：目前的立体匹配网络在特征提取阶段，普遍采用堆叠的卷积层作为骨干网络。卷积操作的核心特性是空间共享权

重和平移不变性。这一归纳偏置使得卷积网络能够以极高的参数效率在图像的各个位置提取相似的局部特征。




图 2.1 常规卷积与注意力机制在特征提取及匹配代价聚合阶段的信息聚合模式对比。(a) 双目立体匹配的左视图输入；(b) 常规卷积聚合模式示意图，卷积操作采用固定的全局共享权重，这种内容无关的聚合方式极易在物体边缘区域混合前景与背景的无关特征，从而导致局部匹配歧义与边缘模糊；(c) 注意力机制聚合模式示意图，该机制利用像素间的相似度得分对周围上下文信息进行加权，有效抑制了背景噪声的干扰，使物体边缘的特征更具辨识度，从而保持了精细的几何结构。

然而，这种空间共享权重的各向同性处理机制，在面对几何不连续区域时存在本质局限。首先，卷积核本质上是一个局部加权求和算子，为了能够适配深度估计任务需要充足的上下文信息和大感受野的需求，它倾向于对感受野内的特征进行平滑处理。如图 2.1 所示，当卷积核滑过物体边缘时，它会不可避免地将前景物体的特征与背景特征进行混合。这种特征层面的混合在解码阶段会导致显著的边缘模糊现象——即前景物体的轮廓向背景扩张，使得细瘦物体变粗，物体边界模糊不清。其次，为解决弱纹理区域的匹配歧义，现代架构（如 PSMNet^[7]）普遍采用空洞卷积或空间金字塔池化^[71]以扩大感受野。然而，感受野的扩大容易加剧边缘区域的特征模糊问题。在深度不连续处，来自不同深度平面的信号被强行聚合，导致网络难以精确界定物体的几何边界。因此，单纯依赖空间共享权重的卷积网络，在原理上难以兼顾平滑区域的一致性与边缘区域的锐利度。

(2) 全局注意力机制的计算冗余与高分辨率推理的矛盾：为突破卷积算子在感受野与权重固定性上的局限，近期研究开始将注意力机制或 Transformer 架构引入立

体匹配。凭借内容自适应的建模能力，Transformer 能够有效捕捉像素间的长程依赖。例如，STTR^[51] 通过在极线及邻域内执行全局搜索，显著增强了弱纹理区域的匹配鲁棒性。然而，全局注意力机制的引入伴随着难以承受的计算开销。标准自注意力运算的复杂度随输入序列长度呈二次方增长。考虑到立体匹配通常处理高分辨率图像（例如 KITTI^[83,84] 数据集为 1242×375 ，甚至更高），全图范围的像素级交互将导致显存占用与推理延迟的激增。更为关键的是，这种全局计算存在显著的空间冗余。图像中占据主导的平滑背景（如路面、天空）属于低频区域，仅需局部卷积即可有效编码。在这些区域盲目应用高复杂度的注意力机制，不仅造成算力浪费，更可能引入无关的远距离噪声，反而破坏了局部特征的连贯性。

(3) 卷积聚合的局部感受野与全局判别的矛盾：除了特征提取阶段的局限外，在代价聚合阶段，主流方法广泛采用 3D 卷积神经网络对 4D 代价体进行正则化。3D 卷积通过在空间维度（高度、宽度）和视差维度上同时滑动，有效地利用了上下文信息来平滑代价体。然而，受限于 3D 卷积核的物理尺寸（通常为 $3 \times 3 \times 3$ ），其在视差维度上的感受野是非常有限的。这意味着网络只能感知到当前视差候选值及其邻域内的匹配代价值。在面对重复纹理或周期性结构时，代价体在视差维度上往往呈现出多峰分布。由于缺乏视差维度的全局视野，3D 卷积难以在相距较远的多个峰值之间进行有效的全局判别与抑制，从而导致错误的视差估计。虽然堆叠多层 3D 卷积可以理论上扩大感受野，但这会显著增加网络深度和参数量，且难以直接捕捉长距离的视差竞争关系。

基于上述对现有技术局限性的深刻剖析，本章的研究动机源于对自然图像特性的重新思考。可以观察到，自然图像在统计特征上呈现出显著的二元分布特性。平滑区域占据了图像的绝大部分面积。在这些区域，深度变化连续，纹理特征相对单一或具有规律性。对于此类区域，卷积神经网络凭借其平移不变性和高效的并行计算能力，是处理信息的最佳选择。而边缘与细节区域虽然像素占比极低，但包含了场景中最关键的几何结构信息（如物体轮廓）。在这些区域，特征发生剧烈突变，且极易受背景干扰。对于此类区域，需要一种能够感知内容变化、动态调整聚合范围并保持高频细节的机制，而注意力机制正是理想之选。

图像不同区域在纹理与几何属性上存在本质差异，这决定了使用单一算子（纯卷积或纯注意力）处理全图并非最优策略。这种同质化的处理方式难以兼顾计算效率与局部细节的保持。为此，本文从感受野范围、处理模式及计算开销三个维度，对

表 2.1 卷积与注意力机制的特性对比分析。

算子类型	感受野范围	处理模式	计算开销
标准卷积	局部	内容无关	低
局部注意力	局部	内容自适应	低
全局自注意力	全局	内容自适应	高

主流算子进行了系统性分析，这三个特性基本决定了所提取特征的性质以及算法开销，如表格 2.1 所示，分析表明，卷积与注意力机制在处理不同图像属性时呈现出显著的互补特性。因此，构建一种能够因地制宜的混合架构，是提高特征表达能力并保持高效性的关键途径。如果能将卷积的高效性与注意力的灵活性有机结合，针对不同区域实施分而治之的策略，不仅有望解决边缘模糊问题，还能在保证精度的同时大幅降低计算成本。基于这一核心思想，本章提出了一种基于区域分治和注意力机制的特征增强立体匹配方法（CoAtRSNet）。本文的基本假设是：立体匹配网络应当具备自适应感知图像区域属性的能力，并在特征提取阶段动态切换处理模式——在平滑区域利用卷积高效聚合上下文，在边缘区域利用局部注意力精细化特征表示。此外，针对代价聚合阶段的视差维局部性问题，本文进一步探索了在视差维度引入全局注意力机制的可能性，以增强全局判别能力。

为了实现上述研究目标，本章围绕区域分治这一核心理念，设计了一套完整的端到端立体匹配网络架构。本章的主要研究内容及贡献概括如下：

- 1) **基于梯度的自适应区域分治策略：**为了实现特征的分治处理，首要任务是高效且精准地从背景中分离出边缘与细节区域。不同于依赖昂贵语义标注的监督分割方法，本章提出了一种基于图像梯度的解耦策略。具体而言，本文利用空间梯度算子直接提取图像的高频特征。基于梯度的幅值统计分布，设计了一种自适应阈值分割机制，以此生成区分边缘与平滑区域的二值掩模。该过程无需任何外部监督信号，完全依赖图像自身的纹理属性，为后续区域分治策略奠定了基础。
- 2) **卷积与注意力协同的混合特征提取网络：**基于生成的区域掩模，本章设计了一个并行双分支混合特征提取模块，旨在充分发挥卷积与注意力的互补优势。
 - 1) 卷积分支：针对平滑区域，设计了包含空间金字塔池化的卷积分支。该分支通过多尺度池化操作，能够以极低的计算代价聚合大范围的上下文信息，

确保弱纹理区域的特征具有足够的区分度。2) 注意力分支：面向边缘区域，引入基于局部注意力的特征增强模块。该机制将相关性计算限制于局部邻域，在保留内容自适应动态权重的同时，大幅降低了全局注意力的计算开销。通过相似度分数动态抑制邻域内的背景噪声，该分支有效提升了物体边缘的特征锐度。这种架构设计既在平滑区域保持了卷积的高效性，又在边缘区域发挥了注意力的细节捕捉优势，从而在提升特征表达能力的同时避免了高额计算开销。

- 3) **视差维全局注意力机制**：针对 3D 卷积在视差维度感受野受限的问题，本章提出了视差维全局注意力模块。不同于主流的空间注意力机制，该模块将计算重心转移至视差域。通过在视差维度构建全局依赖，模型实现了对单个像素位置上所有候选视差的全局上下文感知。这种机制使得网络能够直接捕获视差假设之间的全局竞争关系，从而有效抑制由重复纹理导致的多峰分布和虚假匹配。此外，受益于视差搜索范围在数量级上远小于空间分辨率的特性，该模块以微小的计算代价，显著赋予了代价聚合网络沿视差方向的全局判别力。
- 4) **卓越的深度估计性能**：本章在 Scene Flow^[69]、KITTI 2012^[83] 和 KITTI 2015^[84] 等权威立体匹配数据集上进行了广泛的实验验证。实验结果表明 CoAtRSNet 在各项评估指标上均优于包括 GwCNet^[26]、GA-Net^[75] 在内的多个最佳方法，特别是在物体边缘和细微结构的精度上取得了显著提升。并且得益于区域分治策略，相较于全图使用注意力机制的方法，CoAtRSNet 大幅降低了显存占用和推理时间。除此以外，消融实验证实，混合特征提取架构具有更强的鲁棒性，能够有效应对不同场景下的纹理变化，具有极强的泛化性能。

综上所述，本章工作通过引入区域分治思想，构建了一种兼顾精度与效率、平衡平滑与细节的新型匹配范式。这不仅解决了特征表示中的关键难题，也为后续章节中关于跨域泛化与鲁棒性的研究奠定了坚实的特征基础。

2.2 基于区域分治和注意力机制的特征增强立体匹配网络

本节将阐述本文提出的基于区域分治和注意力机制的特征增强立体匹配网络 (CoAtRSNet) 的整体架构设计。该任务旨在从一对经过极线校正的双目图像中恢复稠密的深度信息。给定参考图像 (通常为左视图) $I_L \in \mathbb{R}^{H \times W \times 3}$ 和目标图像 (右视

图) $I_R \in \mathbb{R}^{H \times W \times 3}$, 其中 H 和 W 分别表示图像的高度和宽度。网络的目标是预测稠密的视差图 $\hat{D} \in \mathbb{R}^{H \times W}$, 对于左图中的每一个有效像素坐标 $p = (u, v)$, 视差 $d(p)$ 定义为该点在左右视图对应水平坐标的差值, 即右图对应点为 $(u - d(p), v)$ 。根据三角测量原理, 深度 Z 可由 $Z = \frac{f \cdot B}{d}$ 计算得出, 其中 f 为相机焦距, B 为双目基线距离。然而, 正如引言所述, 标准卷积算子所具备的平移不变性和空间共享权重特性, 使其在处理图像不同区域时缺乏适应性: 在平滑区域, 金字塔池化层足以高效捕获上下文; 但在边缘及高频细节区域, 固定权重的卷积核极易导致前景与背景特征的混合, 导致边缘模糊。另一方面, 全局注意力机制虽然能提供内容自适应的特征聚合, 但其 $O((HW)^2)$ 的计算复杂度限制了其在高分辨率输入下的应用。针对上述核心矛盾, CoAtRSNet 的设计哲学在于分而治之: 即根据图像内容的局部几何与纹理属性, 自适应地对不同区域使用最合适的算子。如图 2.2 所示, CoAtRSNet 的整体架构包含以下四个关键组件:




图 2.2 本文提出的 CoAtRSNet 网络架构总览。该架构主要由四个核心处理阶段组成: ① 区域特征提取; ② 区域代价体构建 (RVC); ③ 区域注意力聚合 (RAA); ④ 视差维全局注意力融合 (DAF)。

- 1) **区域特征提取:** 针对图像内容的非均匀性, 本阶段并不直接对全图进行均一化处理, 而是首先采用区域分组策略将输入场景解耦为边缘特征与平滑特征

两类表示。随后,针对不同组别的物理属性,采用差异化的信息聚合模式:对于平滑区域,利用卷积网络高效捕获全局上下文信息以消除纹理歧义;对于边缘区域,利用注意力机制捕获显著的几何细节。这种分治提取策略在特征编码源头即实现了低频语义与高频细节的有效分离。

- 2) **区域代价体构建:** 在特征匹配阶段,为了避免不同频域特征的过早混合与干扰,本阶段提出了一种基于通道维度的分组构建策略。不同于传统方法将所有特征直接拼接,区域代价体构建模块 (Regional Volume Construction, RVC) 在构建 4D 代价体时,在通道维度上对边缘特征代价与平滑特征代价进行物理隔离。这种设计确保了在后续的聚合过程中,高频的边缘几何线索不会被低频的背景噪声所淹没,从而维持了代价体的纯净度与判别力。
- 3) **区域注意力聚合:** 为了解决 3D 卷积在代价正则化过程中容易导致边缘模糊的问题,本阶段提出了区域注意力聚合 (Regional Attention Aggregation, RAA)。该机制在 3D 空间中显式地引导代价聚合的方向:在边缘区域,利用局部注意力动态调整聚合权重,使其沿物体表面而非跨越边界进行传播,从而进一步增强了边缘细节的保留;在平滑区域,则继续利用 3D 卷积的平滑特性。通过区域监督信号的约束,网络能够自适应地学习最优的聚合路径。
- 4) **视差维全局注意力融合:** 在代价聚合的最终阶段,需要将分离处理的区域代价信息进行融合。针对代价体在视差维度可能存在的多峰分布与虚假匹配,本阶段引入了视差维全局注意力融合模块 (D-Global Attention Fusion, DAF)。该模块并不局限于局部视差感受野,而是在整个视差维度上应用全局滤波,通过分析视差候选值的全局竞争关系,实现不同区域代价信息的高效融合与去噪,最终生成具有全局一致性且边缘锐利的视差预测。

2.3 基于几何特性的区域特征提取

为了在立体匹配中同时兼顾平滑区域的全局上下文信息与边缘区域的高频细节,本文提出了一种基于几何特性进行区域分治的特征提取网络。传统的卷积神经网络对全图采用空间共享的卷积核,这种处理方式往往导致平滑区域的感受野不足,或边缘区域的高频细节被模糊。因此,本文通过显式的区域解耦与差异化聚合策略,实现对不同图像区域的最优特征表达。

2.3.1 基于梯度感知的自适应区域分治策略



图 2.3 通过自适应阈值获得的区域掩码，白色像素表示对应的区域掩码。

图像梯度是区分物体边界与平滑背景最显著的物理线索。然而，在实际的非受控场景中，环境光照的剧烈波动、相机曝光参数的差异以及成像噪声的干扰，使得基于固定绝对阈值的边缘检测方法难以鲁棒地工作。为了克服这一限制，本文提出了一种基于梯度统计特性的自适应百分位阈值策略。具体而言，给定一对矫正后的立体图像，本文首先计算图像域 Ω 内所有像素点的梯度幅值 $\nabla I(p)$ 。基于自然图像梯度的稀疏性先验，本文并不设定一个硬性的梯度截断值，而是依据梯度幅值在整幅图像中的统计分布来进行区域划分。算法流程如下：首先，将全图所有像素的梯度值按降序排列。随后，根据预设的比例超参数 α ，选取排名在前 $\alpha\%$ 的像素集合定义为边缘区域，其余 $(1 - \alpha)\%$ 的像素定义为平滑区域。形式化地，对于图像中的任意像素 p ，其对应的二值区域掩模 $M(p)$ 定义为：

$$M^{edge}(p) = \begin{cases} 1, & \text{if } \text{rank}(\nabla I(p)) \leq \alpha\% \cdot |\Omega| \\ 0, & \text{otherwise} \end{cases}, M^{smooth}(p) = 1 - M^{edge}(p) \quad (2.1)$$

在本文的实验设置中，经过在多个数据集上大量实验验证 α 设定为 20 时效果最佳。如图 2.3 所示，这种基于动态百分位阈值策略具有极强的自适应性：无论图像整体是昏暗还是过曝，网络始终能够通过梯度的相对强弱，精准地捕捉到图像中信息量最丰富的前 20% 的几何结构作为边缘区域，从而有效规避了光照变化对区域划分带来的不稳定性。

2.3.2 区域特征提取网络

特征提取是立体匹配的基础，CoAtRSNet 的核心创新在于打破了主流算法对全图采用单一算子的限制。在获取区域掩模后，为了在同一网络框架内独立维护并处

理两类截然不同的特征，本文设计了一种“共享-分离-差异化聚合”的特征提取架构。具体而言，本文首先设计了一种基于分组卷积的并行特征提取架构，以实现特征通道的物理隔离，用于独立并且高效地提取不同区域的基础特征。然后通过设计并行的卷积分支和注意力分支来增强各个区域特征的几何特性，并通过自适应融合模块实现区域融合互补。

(1) 通用浅层特征编码与区域隔离

输入图像首先通过一个共享的特征编码主干网络。该部分包含 3 个卷积层（卷积核大小为 3×3 ，步长分别为 2, 1, 1）用于初步下采样，随后连接 19 个标准的残差层进行深层特征抽取。这一阶段旨在提取分辨率为原图 $1/4$ 的通用浅层语义特征，为后续的区域特定处理提供统一的基础特征。

为了实现特征的物理隔离，本文创造性地将特征提取网络的最后 6 个残差层替换为分组卷积模块。具体而言，本文将特征沿通道划分为 2 个独立的分组：

- 边缘组：专门负责聚合由 M^{edge} 索引的边缘区域特征；
- 平滑组：专门负责聚合由 M^{smooth} 索引的平滑区域特征。

通过这种设计，两类特征在通道维度上实现了严格的物理隔离，互不干扰。此外，由于分组卷积切断了组间的连接，该模块的参数量相比标准卷积减少了 50%，在实现特征解耦的同时显著降低了模型的计算复杂度。针对解耦后的两类特征，本文根据其各自的几何特性设计了定制化的增强模块，对应的是并行的卷积分支和注意力分支，也就是平滑区域的高效上下文聚合模块和边缘区域的内容自适应增强模块。

(2) 平滑区域的高效上下文聚合

平滑区域（如路面、墙面、天空）通常具有低频纹理特征。对于这些区域，匹配的主要困难不在于精细结构的保持，而在于由于缺乏显著的纹理线索，存在固有的匹配歧义，必须依赖大范围的全局上下文信息来辅助推断。虽然非局部注意力可以捕获长距离依赖，但其计算复杂度随分辨率呈二次方增长，开销过大。卷积神经网络凭借其平移不变性和层次化感受野，同样能够高效提取平滑区域特征。

为增强弱纹理区域的特征判别力，本文在卷积分支中引入了 SPP 模块，以突破固定卷积核的感受野局限。具体而言，记输入特征张量为 $F_{in} \in \mathbb{R}^{C \times H \times W}$ ，SPP 模块通过四个并行的平均池化分支捕获多尺度上下文信息。设 $\mathcal{P}_k(\cdot)$ 为核尺寸为 $k \times k$ 的平均池化算子，其中 $k \in \{64, 32, 16, 8\}$ 。各分支的输出特征经由 1×1 卷积降维及双线性插值上采样后，与原始输入特征在通道维度进行级联。该过程可形式化地表示

为:

$$F_{spp} = \mathcal{C}(Fin, \mathcal{U}(\phi(\mathcal{P}64(Fin))), \dots, \mathcal{U}(\phi(\mathcal{P}8(Fin)))) \quad (2.2)$$

其中, $\mathcal{C}(\cdot)$ 表示沿通道维度的级联操作, $\mathcal{U}(\cdot)$ 表示双线性插值上采样操作, $\phi(\cdot)$ 表示用于通道降维的 1×1 卷积变换。融合后的多尺度特征 F_{spp} 随后输入至两个堆叠的 3×3 残差卷积块 $\mathcal{R}(\cdot)$ 中进行特征融合与精炼, 最终得到平滑区域的特征表示 $F_{smooth} = \mathcal{R}(F_{spp})$ 。通过引入 SPP 模块, 网络能够在大范围语义线索的约束下, 有效抑制弱纹理区域的局部匹配歧义。

(3) 边缘区域的内容自适应增强

边缘及细节区域（如树枝、栏杆、车辆轮廓）虽然像素占比低, 但承载了最重要的几何信息。在这些区域, 传统的卷积操作由于权重共享, 会将前景物体的特征与背景特征进行加权平均, 导致特征层面的边缘模糊。为了解决这一问题, 注意力分支引入了局部注意力机制。与卷积操作不同, 注意力机制通过动态计算像素间的特征相似度来生成聚合权重, 从而实现了内容自适应的特征增强。

给定输入特征张量 $F_{in} \in \mathbb{R}^{C \times H \times W}$, 对于任意查询像素位置 i , 本文在其定义的 $K \times K$ 局部邻域窗口 $\mathcal{N}_i$ 内构建上下文依赖。首先, 通过引入三个可学习的线性投影矩阵 $W_Q, W_K, W_V \in \mathbb{R}^{d_k \times C}$, 将位置 i 及其邻域 $\mathcal{N}_i$ 内的输入特征向量 $x \in \mathbb{R}^C$ 映射至查询 (Query)、键 (Key) 及值 (Value) 子空间:

$$q_i = W_Q x_i, \quad k_j = W_K x_j, \quad v_j = W_V x_j, \quad \forall j \in \mathcal{N}_i \quad (2.3)$$

其中, d_k 表示投影后的特征通道维度。为捕获局部窗口内的空间几何结构, 本文引入了可学习的相对位置编码向量 $p_{i-j} \in \mathbb{R}^{d_k}$, 用于编码查询像素 i 与邻域像素 j 之间的相对空间偏移, 将相对位置信息显式地注入到特征聚合过程中。注意力权重 $\alpha_{i,j}$ 基于缩放点积机制计算, 公式如下:

$$\alpha_{i,j} = \text{Softmax}_{j \in \mathcal{N}_i} \left(\frac{q_i^\top k_j + q_i^\top p_{i-j}}{\sqrt{d_k}} \right) \quad (2.4)$$

其中, $\sqrt{d_k}$ 为缩放因子, 旨在对点积结果进行归一化以缓解 Softmax 函数在反向传播中的梯度消失问题; 项 $q_i^\top p_{i-j}$ 显式地建模了基于内容的查询特征与相对位置信息的交互。最终, 中心像素 i 处的增强特征 $F_{edge}(i)$ 由邻域内的值向量 v_j 根据计算出

的注意力权重加权聚合得到：

$$F_{edge}(i) = \sum_{j \in \mathcal{N}_i} \alpha_{i,j} v_j \quad (2.5)$$

该机制的有效性可以通过分析其在深度不连续区域的行为来解释。假设像素 i 位于前景物体的边缘，其局部窗口 $\mathcal{N}_i$ 同时覆盖了前景区域与背景区域：

- 同质性聚合：对于同属前景的邻域像素 j ，由于其与中心像素 i 具有相似的纹理与语义特征，查询向量 q_i 与键向量 k_j 的点积响应较大，注意力权重 $\alpha_{i,j}$ 更大使得网络倾向于聚合这些包含有效几何信息的特征。
- 异质性抑制：对于属于背景的邻域像素 j ，由于其与前景像素存在显著的特征差异， $q_i^T k_j$ 的响应值将被抑制，导致对应的聚合权重 $\alpha_{i,j}$ 趋近于零，网络倾向于抑制这些非相关信息的特征。

这种基于内容相似度的加权机制赋予了网络自动过滤背景噪声干扰的能力。通过仅聚合具有高度相关性的同类像素特征，局部注意力模块在特征提取阶段即实现了显著的边缘锐化，从根本上缓解了传统卷积网络中普遍存在的边缘模糊问题，为后续的高精度代价计算奠定了坚实的特征基础。

2.4 区域代价体构建

现有的主流方法（如 GwcNet^[26]、CFNet^[76]）通常采用空间共享的构建策略，即对所有图像区域采用统一的分组相关与特征拼接的组合方式。这种策略忽略了不同图像区域在匹配机理上的本质差异，在代价聚合阶段也会出现特征表达能力不足的现象。为了解决上述问题，并充分利用所提取的区域特征，本节提出了区域代价体构建模块。如图 2.4 所示，核心思想是在代价体构建阶段延续分而治之的策略，通过通道维度的物理隔离，分别构建专用于边缘区域和平滑区域的混合代价体，最终将其融合为包含丰富特征信息的全区域代价体。

在进入代价体构建模块之前，左右视图已经经过了基于区域分治的特征提取网络（见上一章节）。设左图特征为 $F_L \in \mathbb{R}^{C \times H/4 \times W/4}$ ，右图特征为 $F_R \in \mathbb{R}^{C \times H/4 \times W/4}$ 。得益于特征提取阶段的分组卷积设计，特征图在通道维度上已经形成了物理上的区域特征解耦。具体而言，特征张量的前 $C/2$ 个通道主要编码了由局部注意力机制增强的边缘区域特征，而后 $C/2$ 个通道则聚合了由金字塔池化模块提取的平滑区域特




图 2.4 区域代价体构建模块示意图。该模块接收左右视图的解耦特征作为输入，利用通道分组机制将特征划分为边缘与平滑两组。针对每一组特征分别计算相关体与拼接体。最终，通过在通道维度拼接两类区域的子代价体，生成最终的区域代价体。图中黄色数据流代表边缘代价体操作，蓝色数据流代表平滑代价体操作。

征。基于此，本文在代价体构建的入口处首先执行显式的通道分组操作：

$$\begin{aligned} F_L^{edge} &= F_L[0 : C/2, :, :], & F_R^{edge} &= F_R[0 : C/2, :, :] \\ F_L^{smooth} &= F_L[C/2 : C, :, :], & F_R^{smooth} &= F_R[C/2 : C, :, :] \end{aligned} \quad (2.6)$$

其中 $[:]$ 表示张量的切片操作。通过这种基于通道的显式分组，本文保证了匹配代价的计算仅在具有相似属性的特征之间执行。这种设计从物理上消除了特征串扰，既阻断了平滑区域的噪声对边缘区域的负面影响，又保持了平滑区域语义的连贯性，实现了对不同区域结构的互不干扰建模。

为了兼顾匹配的精度与鲁棒性，本研究沿用了 GwcNet^[26] 提出的分组相关与特征拼接的混合代价体范式，并将其创新性地扩展为区域独立的双流架构。对于每一类区域（边缘/平滑），本文分别构建两部分子代价体：区域相关体与区域拼接体。为了在保留特征通道信息的同时降低计算复杂度，本文将边缘特征 F^{edge} 进一步划分为 N_g 个子组，并计算左右特征在不同视差水平 d 下的组内相关性。设第 g 个子组的特征向量为 $f_{L,g}^{edge}$ 和 $f_{R,g}^{edge}$ ，则在视差 d 处的匹配代价计算如下：

$$V_{gwc}^{edge}(d, x, y, g) = \frac{1}{C_{sub}} \langle f_{L,g}^{edge}(x, y), f_{R,g}^{edge}(x - d, y) \rangle \quad (2.7)$$

其中 $\langle \cdot, \cdot \rangle$ 表示向量内积， C_{sub} 为子组通道数。该操作生成了维度为 $N_g \times D_{max}/4 \times$

$H/4 \times W/4$ 的边缘相关体，它能够为边缘匹配提供鲁棒的几何相似度度量。

尽管相关体提供了显式的相似度分数，但它丢失了原始的语义特征信息。为了补充上下文信息，本文将左图的边缘特征 F_L^{edge} 与右图平移后的特征 F_R^{edge} 进行通道维度的直接拼接，形成维度为 $C \times D_{max}/4 \times H/4 \times W/4$ 的边缘拼接体：

$$V_{cat}^{edge}(d, x, y) = [F_L^{edge}(x, y) \oplus F_R^{edge}(x - d, y)] \quad (2.8)$$

$\oplus$ 代表沿着通道进行拼接，最终边缘区域的代价体 V^{edge} 由两代价体拼接得到：

$$V^{edge} = V_{gwc}^{edge} \oplus V_{cat}^{edge} \quad (2.9)$$

如图 2.4 上半部分的黄色数据流所示，这一设计确保了边缘区域不仅拥有高精度的几何匹配线索，还保留了必要的局部语义特征用于后续的正则化。

平滑区域代价体采用与边缘区域相同的构建方式，但在处理对象上替换为平滑特征 F^{smooth} 。如图 2.4 的蓝色数据流所示：

- 构建平滑相关体 V_{gwc}^{smooth} ：利用平滑特征计算组间相关性。尽管平滑区域纹理较弱，但通过大感受野（金字塔池化）聚合后的特征在宏观尺度上仍具备一定的相关性判别力。
- 构建平滑拼接体 V_{cat}^{smooth} ：这是平滑区域匹配的关键。拼接体直接保留了包含全局上下文的高维语义向量，使得网络能够通过学习语义一致性来推断视差。

最终生成的平滑区域代价体 V^{smooth} 同样由相关体与拼接体组合而成：

$$V^{smooth} = V_{gwc}^{smooth} \oplus V_{cat}^{smooth} \quad (2.10)$$

经过上述并行的双流处理，本文获得了两个在物理意义上互补的代价体： V^{edge} 专注于刻画高频细节的几何对应关系，而 V^{smooth} 专注于描述低频区域的语义一致性。为了构建一个能够输入到后续 3D 聚合网络的统一表示，本文将两者在通道维度进行最终的融合：

$$V_{final} = V^{edge} \oplus V^{smooth} \quad (2.11)$$

最终得到的区域代价体 V_{final} 具有 $2C \times D_{max}/4 \times H/4 \times W/4$ 的维度。这一构建过程不仅实现了匹配相似度的度量，更重要的是它将区域分治的思想显式地构建进了代价体的结构中。区域代价体构建模块是连接特征提取与代价聚合的桥梁，它

通过结构化的通道分组设计，成功地将 2D 图像空间的区域先验转化为 4D 代价体空间的结构先验，为后续的高精度视差回归奠定了坚实的相似度度量基础。

2.5 区域注意力聚合

代价聚合是立体匹配流程中至关重要的一环，旨在通过融合邻域上下文信息来校正匹配代价中的噪声与不一致性。在深度学习时代，这一过程通常由堆叠的 3D 卷积神经网络来实现，这就存在和特征提取阶段相似的困境，单一算子无法同时兼顾全图的代价聚合。为了克服这一瓶颈，并延续前文所述的区域分治的设计理念，本节提出了一种区域注意力聚合模块。不同于传统方法将所有信息混合处理，RAA 模块通过区域分组聚合与 3D 局部注意力机制，实现了对边缘与平滑区域的差异化正则化，并引入显式的区域监督策略以强化网络学习出更适合各自区域的聚合权重。

2.5.1 区域分组聚合机制

承接上一节构建的区域代价体 $V_{final} \in \mathbb{R}^{2C \times D_{max}/4 \times H/4 \times W/4}$ ，该代价体在通道维度上已经包含了区域属性的划分。为了在聚合阶段维持这种物理隔离，防止平滑区域的噪声污染边缘区域的高频信息，本文摒弃了标准的 3D 卷积，转而采用 3D 分组卷积作为聚合网络的基础单元。

具体而言，本文将聚合网络中的 3D 卷积层配置为分组形式（Group=2）。第一组通道专门负责处理边缘区域的代价体，第二组通道专门负责处理平滑区域的代价体。这种设计带来了双重优势：

- 信息隔离与互不干扰：边缘代价体与平滑代价体在聚合过程中保持独立，网络可以为平滑区域学习大感受野的卷积核权重，同时为边缘区域学习保持边缘细节的卷积核权重，从而根本上解决了不同区域在参数共享下的优化冲突。
- 计算效率提升：3D 卷积是立体匹配网络中计算开销最大的组件。通过采用分组卷积降低参数量，使得模型在提升精度的同时保持了极高的推理效率。

2.5.2 面向边缘保持的 3D 局部注意力

尽管分组卷积实现了通道隔离，但固定权重的卷积核同样无法处理几何结构最为复杂的边缘区域。为了进一步提升边缘区域的匹配精度，本文在边缘聚合分支中引入了 3D 局部注意力机制。与特征提取阶段的 2D 注意力机制不同，这里的注意力

操作是在 4D 代价体空间 ($C \times D \times H \times W$) 中进行的。其核心思想是：在进行代价聚合时，聚合权重不应是固定的全局参数，而应动态取决于像素点在特征空间与几何空间的相似性。设输入代价体张量为 $X \in \mathbb{R}^{C \times D \times H \times W}$ ，输出聚合特征为 Y 。对于代价体中的任意目标像素坐标 $p = (d, h, w)$ ，本文定义其 3D 局部邻域为 Ω_p 。聚合过程被形式化为邻域内像素特征的加权和：

$$Y(p) = \sum_{q \in \Omega_p} \alpha(p, q) \cdot X(q) \quad (2.12)$$

其中， $q \in \Omega_p$ 表示邻域内的像素坐标， $\alpha(p, q)$ 为动态聚合权重。该权重由外观相似性与几何位置先验共同约束，并通过 Softmax 函数在邻域内进行归一化：

$$\alpha(p, q) = \text{Softmax}_{q \in \Omega_p} \left(\frac{\mathcal{S}_{app}(p, q) + \mathcal{P}_{geo}(p - q)}{\sqrt{C}} \right) \quad (2.13)$$

1. 外观相似性项 $\mathcal{S}_{app}$ ：该项旨在度量目标像素与邻域像素在特征空间的一致性。本文通过可学习的线性投影建立依赖关系：

$$\mathcal{S}_{app}(p, q) = [\phi(X(p))]^\top \cdot \psi(X(q)) \quad (2.14)$$

其中， $\phi(\cdot)$ 和 $\psi(\cdot)$ 表示通过 $1 \times 1 \times 1$ 卷积实现的线性变换矩阵，用于将输入特征投影至嵌入子空间； $[\cdot]^\top$ 表示转置操作。若像素对 (p, q) 属于同一物体（即特征相关性高），点积操作将产生较大的响应值，从而赋予其更高的聚合权重。

2. 几何位置先验项 $\mathcal{P}_{geo}$ ：仅依赖外观相似性容易导致空间结构的离散化。为此，本文引入几何位置编码来注入空间归纳偏置，确保聚合过程遵循空间邻近原则。该项由相对位置坐标 $\Delta p = p - q$ 经由位置编码函数 $\delta(\cdot)$ 映射得到：

$$\mathcal{P}_{geo}(\Delta p) = W_{pos} \cdot \delta(\Delta p) \quad (2.15)$$

其中， $\delta(\cdot)$ 为相对位置编码查找表， W_{pos} 为用于维度对齐的可学习线性变换。

通过引入 3D 局部注意力机制，边缘区域的代价聚合不再是各向同性的低通滤波，而是具备了敏锐的边界感知能力：在深度不连续处，注意力权重会自动截断，仅聚合视差一致的同侧信息，从而有效地保留了锐利的几何边缘。

2.5.3 区域解耦的监督学习策略

为了迫使网络真正习得针对不同区域的差异化聚合模式，仅仅在结构上进行分组是不够的，还需要在损失函数层面施加显式的约束。本文提出了一种区域监督策

略。

在 RAA 模块的训练过程中, 本文利用 3D 分组卷积分别输出针对边缘区域的预测视差图 d_{pred}^{edge} 和针对平滑区域的预测视差图 d_{pred}^{smooth} 。随后, 利用前文生成的二值掩模 M^{edge} 和 M^{smooth} , 分别计算各区域的回归损失。

总的区域聚合损失 L_{RAA} 定义为边缘损失与平滑损失的加权和:

$$L_{RAA} = L_{edge} + L_{smooth} \quad (2.16)$$

其中, 各分项损失采用 Smooth L1 Loss 计算:

$$\begin{aligned} L_{edge} &= \lambda^{edge} \cdot \frac{1}{N_{edge}} \sum_p M^{edge}(p) \cdot \text{Smooth}_{L1}(d_{pred}^{edge}(p) - d_{gt}(p)) \\ L_{smooth} &= \lambda^{smooth} \cdot \frac{1}{N_{smooth}} \sum_p M^{smooth}(p) \cdot \text{Smooth}_{L1}(d_{pred}^{smooth}(p) - d_{gt}(p)) \end{aligned} \quad (2.17)$$

式中, d_{gt} 为真实视差图, λ^{edge} 和 λ^{smooth} 为平衡系数 (实验中分别设为 0.5 和 0.7)。

这种监督策略的物理意义在于: L_{edge} 迫使边缘分支的卷积核专注于高频梯度的拟合, 容忍一定的噪声但必须保证边界准确; 而 L_{smooth} 引导平滑分支的卷积核学习来得到更大的感受野, 以消除弱纹理区域的匹配歧义。通过这种反向传播机制, 网络自适应地形成了两套互补且独立的参数体系, 实现了真正意义上的区域分治。

综上所述, 区域注意力聚合模块通过结构上的分组卷积、机制上的 3D 局部注意力以及优化上的区域监督, 构建了一个全方位解耦的代价聚合体系。它不仅大幅降低了计算复杂度, 更重要的是, 它改善了立体匹配中长期存在的特征表达能力不足的问题, 为生成高精度的深度图提供了可靠的几何约束。

2.6 视差维全局注意力融合

经过前述的区域注意力聚合模块处理后, 网络在边缘与平滑区域分别获得了各自区域正则化后的区域代价体。然而, 仅依赖 3D 卷积或者局部注意力机制进行代价聚合在本质上仍受限于其有限的感受野。在 4D 代价体空间 ($C \times D \times H \times W$) 中, 传统的 3D 卷积核虽然能够在空间维度上通过堆叠扩大感受野, 但在视差维度 (D) 上通常仅能覆盖极小的局部范围 (如 $3 \times 3 \times 3$ 的卷积核在视差轴上仅能感知相邻的 3 个视差假设)。这种视差维度的局部性会导致严重的多峰分布问题: 即在存在重复纹理、弱纹理或反光干扰的区域, 代价体沿视差方向的概率密度函数可能在真实视

差值之外出现多个错误的局部极大值。由于卷积核无法感知整个视差范围内的全局上下文，网络难以通过比较全局概率分布来抑制这些显著的噪声峰值。此外，前序步骤中边缘与平滑区域的独立处理虽然实现了特征解耦，但也可能导致两个分支输出的代价分布在数值尺度与分布形态上存在差异，这种分布差异进一步加剧了回归最优视差的难度。

为了解决上述问题，本节提出了一种视差维全局注意力融合（Disparity Attention Fusion, DAF）模块。不同于传统的空间注意力机制（关注 $H \times W$ 维度的像素关联），视差维全局注意力融合模块创新性地将注意力机制应用于视差维度（ D 轴），通过构建全视差范围的依赖关系，实现对代价体的全局视差滤波。

2.6.1 视差全局注意力模块

DAF 的核心是视差全局注意力模块，其核心思想是利用全局视差上下文来重新校准每一个视差假设的置信度。本文不再孤立地看待某个视差假设 d 的匹配代价，而是将其置于所有可能的视差假设集合 $\{0, 1, \dots, D_{max} - 1\}$ 中进行加权评估。




图 2.5 视差全局注意力模块示意图。

如图 2.5 所示，视差全局注意力模块旨在捕获视差维度的长距离依赖。设输入代价体特征为 $X \in \mathbb{R}^{C \times D \times H \times W}$ 。首先，本文通过三个独立的 $1 \times 1 \times 1$ 卷积层对 X 进行线性投影。为了在视差维度上构建全局交互，本文将空间维度 H 和 W 展平为单一维度 $N = H \times W$ ，并对张量进行维度重塑与转置，生成查询（Query）、键（Key）和值（Value）矩阵如下：

$$Q \in \mathbb{R}^{N \times D \times C}, \quad K \in \mathbb{R}^{N \times C \times D}, \quad V \in \mathbb{R}^{N \times D \times C} \quad (2.18)$$

其中， Q 和 V 保持了 $[N, D, C]$ 的形状，而 K 经过转置变为 $[N, C, D]$ 以适配后续的

矩阵乘法。在此基础上，本文通过计算 Q 与 K 的点积来衡量不同视差假设之间的特征相似性，并利用 Softmax 函数生成视差注意力图 $A \in \mathbb{R}^{N \times D \times D}$ ：

$$A(i, j) = \frac{\exp(Q_i \cdot K_j)}{\sum_{k=1}^D \exp(Q_i \cdot K_k)} \quad (2.19)$$

其中， $A(i, j)$ 明确量化了在空间位置 n 处，第 j 个视差层级对第 i 个视差层级的贡献权重。这一过程在视差域内建立了一个全局竞争机制，使得网络能够通过对比所有候选视差的特征相关性来抑制错误匹配。

最终，利用生成的注意力图 A 对值矩阵 V 进行加权聚合。通过矩阵乘法 $A \cdot V$ 将全局视差信息注入特征，并通过逆变换 $\mathcal{R}^{-1}$ （转置和维度重塑）将结果恢复至原始的 4D 结构：

$$Y = \mathcal{R}^{-1}(A \cdot V) \in \mathbb{R}^{C \times D \times H \times W} \quad (2.20)$$

通过这种视差维重加权机制，视差全局注意力模块有效地执行了全局滤波：如果某个视差级是虚假峰值，它与其他真实视差级的相关性较弱，其权重会被全局上下文抑制；反之，真实的视差峰值会得到增强。这与仅在特征通道或空间维度进行聚合的方法（如 STTR^[51]）有着本质区别，后者无法直接修正沿视差轴的概率分布缺陷。

2.6.2 多级融合与全局约束优化

在网络架构层面，DAF 模块被设计为一个多级细化结构。如图 2.2 所示，输入代价体首先经过堆叠的 3D 卷积层，随后接入视差全局注意力模块进行全局修正。为了确保网络能够从粗到细地学习视差分布，本文采用了深层次的多级监督策略。DAF 模块在不同阶段输出多个中间视差预测结果 $\{d_1, d_2, d_3\}$ ，并均施加全局约束损失。与 RAA 模块的分区域监督不同，DAF 旨在融合，因此其损失函数 L_{DAF} 定义为全图范围内的平滑 L1 损失（Smooth L1 Loss）的加权和：

$$L_{DAF} = \sum_{k=1}^3 \lambda_k \cdot \text{Smooth}_{L1}(d_k - d_{gt}) \quad (2.21)$$

其中 λ_k 为第 k 个输出阶段的平衡系数（实验中通常设置为 $\lambda_1 = 0.5, \lambda_2 = 0.7, \lambda_3 = 1.0$ ）。这种全局监督与视差维全局注意力机制相结合，迫使网络在训练过程中不断修正代价体的概率分布形态，使其从混乱的多峰分布逐渐收敛为以真实视差为中心

的单峰分布。这不仅解决了边缘与平滑区域特征融合时的分布对齐问题，更显著提升了算法在弱纹理、反光及遮挡区域的鲁棒性。

综上所述，视差维全局注意力融合模块（DAF）通过引入视差维度的全局上下文约束，弥补了卷积神经网络在视差维度感知能力的短板。它是连接区域分治策略与最终高精度视差输出的关键枢纽，确保了整个 CoAtRSNet 框架在保持细节锐度的同时，具备极强的全局几何一致性。

2.6.3 视差回归

为了获得亚像素精度的视差估计，并保证整个网络的可微性，CoAtRSNet 采用了 Soft-argmin 机制。具体而言，记 RAA 和 DAF 模块输出的正则化代价体为 $C_{out} \in \mathbb{R}^{D \times H \times W}$ ，其中 D 代表视差维度。首先，利用 Softmax 函数沿视差维度将代价体转化为概率分布。对于每一个离散的视差候选索引 $k \in \{0, 1, \dots, D_{max} - 1\}$ ，其对应的匹配概率 $P(k)$ 计算如下：

$$P(k) = \sigma(-C_{out}(k)) = \frac{\exp(-C_{out}(k))}{\sum_{j=0}^{D_{max}-1} \exp(-C_{out}(j))} \quad (2.22)$$

其中， D_{max} 表示预设的最大视差搜索范围（本文设定为 192）， $C_{out}(k)$ 表示在视差索引 k 处的匹配代价值，取负号是为了将最小化代价转换为最大化概率。在此基础上，最终的预测视差 $\hat{d}$ 通过计算视差候选索引 k 的数学期望得到：

$$\hat{d} = \sum_{k=0}^{D_{max}-1} k \cdot P(k) \quad (2.23)$$

该回归方式本质上是对所有离散视差假设进行概率加权求和。这不仅使得模型能够输出连续的亚像素结果，还通过概率分布隐式地建模了匹配的不确定性，从而提升了训练过程的稳定性。

2.7 实验结果与分析

为了全面地评估本章提出的 CoAtRSNet 及其核心组件——区域分治策略、区域特征提取网络、区域注意力聚合模块（RAA）及视差维全局注意力融合模块（DAF）的有效性与先进性，本节将在五个国际主流的立体匹配基准数据集上进行广泛且深入的实验验证。

本节的组织结构安排如下：首先，2.7.1 和 2.7.2 节详细介绍所使用的数据集特性及定量评估指标；2.7.3 节阐述实验的具体实施细节、参数设置及训练策略；2.7.4 节基于大规模合成数据集 Scene Flow 进行详尽的消融实验，深入剖析各个模块对整体性能的贡献及内在物理机理；2.7.5 节将本文提出的 CoAtRS 策略应用于现有的最先进（SOTA）网络中，验证其作为通用算法框架的普适性；最后，2.7.6 节将 CoAtRSNet 与当前国内外主流算法进行横向对比，展示其在精度、泛化能力及计算效率上的综合优势。

2.7.1 数据集

为了保证实验结论的可靠性与广泛性，本文选取了涵盖合成场景、真实自动驾驶场景、高动态范围室内场景及高分辨率复杂几何场景的五个权威数据集：Scene Flow^[69]、KITTI 2012^[83]、KITTI 2015^[84]、Middlebury 2014^[36] 以及 ETH3D^[35]。

(1) Scene Flow^[69] 数据集：Scene Flow 是一个大规模的合成立体数据集，包含 FlyingThings3D、Driving 和 Monkaa 三个子集。该数据集提供了 35 454 对训练图像和 4 370 对测试图像，分辨率为 960×540 。由于其数据量巨大且提供像素级稠密的视差真值（Ground Truth），主要用于深度网络的预训练以及消融实验的基准测试。

(2) KITTI 2012^[83] & KITTI 2015^[84] 数据集：KITTI 系列数据集采集自真实世界的自动驾驶场景，包含复杂的城市街道、高速公路及乡村道路。

- KITTI 2012：主要针对静态场景，包含 194 对训练图和 195 对测试图，分辨率约为 1226×370 。其视差真值由激光雷达（LiDAR）稀疏采集获得。
- KITTI 2015：相比 2012 版，增加了大量动态车辆场景，极具挑战性。它包含 200 对训练图和 200 对测试图，分辨率约为 1242×375 。该数据集不仅测试算法的匹配精度，还考验算法对动态物体的鲁棒性。

(3) ETH3D^[35] 数据集：ETH3D 是一个高精度的灰度立体数据集，涵盖了室内和室外场景。它仅包含 27 对训练图和 20 对测试图，视差范围较小（0-64 像素）。尽管数据规模小，但其场景包含了低纹理墙面、强光照变化及复杂的细微结构，对算法在微小视差下的亚像素精度提出了极高要求。

(4) Middlebury 2014^[36] 数据集：Middlebury 是立体匹配领域最经典的数据集，以其极高的图像分辨率（高达 $3\,000 \times 2\,000$ ）和复杂的几何结构著称。它包含 28 对训练图和 15 对测试图（涵盖室内复杂物体堆叠、强反光表面等）。由于分辨率极高，

本文实验中使用其半分辨率版本，但即便如此，其视差范围仍高达 0-400 像素，主要用于评估算法在大视差范围下的搜索能力。

2.7.2 评估指标

为了定量评估算法的匹配精度，本文针对不同数据集的特性，采用了以下几类标准的评价指标：

(1) 端点误差 (End-Point Error, EPE): EPE 是最通用的评估指标，用于衡量预测视差与真值之间的平均欧氏距离。定义如下：

$$EPE = \frac{1}{N} \sum_{p \in \Omega} |d_{pred}(p) - d_{gt}(p)| \quad (2.24)$$

其中， Ω 为有效像素集合， N 为有效像素总数， d_{pred} 为预测视差， d_{gt} 为视差真值。EPE 指标被广泛应用于 Scene Flow、KITTI 及 Middlebury 数据集的评估中。

(2) 异常值百分比 (Percentage of Outliers, D1 / $>\theta$ px): 该指标用于衡量视差误差超过特定阈值的像素比例，反映了算法的鲁棒性。

- D1: 定义为误差大于 3 像素且大于真实视差值 5

$$D1 = \frac{1}{N} \sum_{p \in \Omega} \mathbb{I}(|d_{pred}(p) - d_{gt}(p)| > \max(3px, 0.05 \cdot d_{gt}(p))) \quad (2.25)$$

在 KITTI 2015 中，该指标进一步细分为背景区域误差 (D1-bg)、前景区域误差 (D1-fg) 和全图误差 (D1-all)。

- $>\theta$ px: 定义为绝对误差大于 θ 像素的比例。

(3) 均方根误差 (Root-Mean-Square Error, RMSE): RMSE 对大误差更加敏感，常用于 ETH3D 和 Middlebury 的评估：

$$RMSE = \sqrt{\frac{1}{N} \sum_{p \in \Omega} (d_{pred}(p) - d_{gt}(p))^2} \quad (2.26)$$

(4) 遮挡与非遮挡指标 (Noc vs All): 针对 KITTI 数据集，评估指标通常分为两类：Noc（仅计算非遮挡区域的像素）和 All（计算包括遮挡区域在内的所有有效像素），这有助于区分算法在可见区域的匹配精度与在遮挡区域的推断能力。

2.7.3 主要训练设置

本文提出的 CoAtRSNet 基于 PyTorch 深度学习框架实现。所有实验均在搭载 NVIDIA RTX 3090 GPU 的高性能工作站上完成。网络训练采用 Adam^[160] 优化器，动量参数设置为 $\beta_1 = 0.9, \beta_2 = 0.999$ 。CoAtRSNet 采用了区域与全局相结合的多阶段监督策略。对于区域注意力聚合模块，不同区域的损失权重设置为 $\lambda^{edge} = 0.5$ 和 $\lambda^{smooth} = 0.7$ 。对于视差维全局融合模块，三个输出阶段（由粗到精）的权重分别设置为 $\lambda_0 = 0.5, \lambda_1 = 0.7, \lambda_2 = 1.0$ ，以引导网络逐步细化视差预测。为了确保模型充分收敛并具备良好的泛化性，本文采用了大规模预训练和场景微调的分阶段训练策略：

- **Scene Flow 预训练：**首先在 Scene Flow 数据集上从头训练网络，共进行 32 个 Epoch。初始学习率设为 0.001，并在第 15, 20, 24, 27, 30 个 Epoch 后衰减一半。Batch Size 设为 16，训练时随机裁剪图像至 512×256 ，最大视差 D_{max} 设为 192。
- **KITTI 微调：**对于 KITTI 数据集，本文采用混合训练策略。将 KITTI 2012 和 2015 的训练集合并，首先对预训练模型进行 500 Epoch 的混合微调，随后再针对特定的 2012 或 2015 数据集进行 500 Epoch 的专项微调。初始学习率为 0.001，在 300 Epoch 后降至 0.0005。
- **ETH3D 与 Middlebury 微调：**同样基于 Scene Flow 预训练模型，进行 500 Epoch 的微调。学习率策略调整为：初始 0.001，在 300 Epoch 后衰减 10 倍。

这种分阶段的训练策略有效地解决了真实场景数据量不足的问题，使模型能够从合成数据中学习几何先验，并迅速适应真实场景的域分布。

2.7.4 消融实验与分析

为了深入探究 CoAtRSNet 中各个创新模块的有效性，本文在 Scene Flow 数据集上进行了详尽的消融实验。鉴于 CoAtRSNet 采用了 GwcNet^[26] 的骨干架构，本文将原始 GwcNet 设为基准模型。具体而言，基准模型采用标准 2D 卷积替代本文的区域混合特征提取，采用标准 3D 卷积替代 RAA 中的区域聚合与局部注意力，并移除了视差维全局注意力模块。

(1) 区域分组与监督的有效性验证

首先，本文验证最核心的区域分治思想是否有效。为此，基于基准模型构建了 Base-RG。该模型仅引入了区域分组策略和区域监督损失，但在特征提取和代价聚合中仍使用标准的组卷积，未引入注意力机制。实验结果如表格 2.2 的前两行所示。

表 2.2 特征提取阶段的消融性实验。

方法	区域分组 & 区域监督	特征提取策略			D1 (%)	EPE (像素)	参数量 (M)	浮点运算次数 (G)
		全区域	边缘	平滑				
Baseline ^[26]					2.59	0.736	6.91	260.38
Base-RG	✓				2.15	0.625	5.71	216.20
Base-RG-LA(A)	✓	LA			2.07	0.600	5.72	216.29
Base-RG-LA(E)	✓		LA		1.96	0.571	5.71	216.22
Base-RG-SPP(A)	✓	SPP			2.12	0.615	5.72	216.27
Base-RG-SPP(S)	✓			SPP	2.01	0.583	5.72	216.25
Base-RG-NLA(S)	✓			NLA	2.08	0.603	5.72	269.81
Base-RG-LA(E)-SPP(S)	✓		LA	SPP	1.90	0.557	5.72	216.26

与 Baseline 相比，仅通过区域分组和监督，Base-RG 模型的 EPE 误差从 0.736 像素降至 0.625 像素（降低 15.1%），D1 错误率从 2.59% 降至 2.15%（降低 17.0%）。这一显著提升表明，通过自适应梯度阈值将图像解耦为平滑与边缘区域，并施加独立的监督信号，能够迫使网络在不同的特征通道中分别学习适应这两类区域的参数。此外，得益于分组卷积的参数高效性，Base-RG 在提升精度的同时，参数量和计算量均降低了约 17%，这有力地证明了区域分治策略的高效性与合理性。

（2）不同区域特征提取策略分析

如表格 2.2 所示，在 Base-RG 的基础上，本文进一步探索了不同算子（卷积 vs. 注意力）在不同区域（平滑 vs. 边缘）的最佳组合方式。本文构建了六种变体模型进行对比分析：

- 1) Base-RG-LA(A)：在所有区域均使用局部注意力（Local Attention, LA）。
- 2) Base-RG-LA(E)：仅在边缘区域使用局部注意力。
- 3) Base-RG-SPP(A)：在所有区域均使用金字塔池化模块（Spatial Pyramid Pooling, SPP）。
- 4) Base-RG-SPP(S)：仅在平滑区域使用 SPP。
- 5) Base-RG-NLA(S)：在平滑区域使用非局部注意力（Non-local Attention, NLA）。
- 6) Base-RG-LA(E)-SPP(S)：本文提出的最终方案，即边缘区域使用局部注意力，平滑区域使用 SPP。

边缘区域的最佳算子：比较 Base-RG-LA(E) 与 Base-RG-LA(A)，前者在边缘区域的表现反而更优（EPE 降低 4.8%）。这说明在平滑区域强行使用局部注意力不仅增加了计算量，还可能因为引入了不必要的局部高频噪声而损害性能。相反，仅在边缘区域应用注意力，能够精准地捕捉几何细节，同时避免资源浪费。

平滑区域的最佳算子：比较 Base-RG-SPP(S) 与 Base-RG-SPP(A)，仅在平滑区域使用 SPP 取得了更好的效果。这验证了本文的假设：平滑区域需要大的感受野（SPP 模块更加擅长）来消除歧义，而边缘区域需要保留高频信息，过大的感受野会导致边缘细节丢失。

SPP 与 Non-local 的对比：对比 Base-RG-NLA(S) 与 Base-RG-SPP(S)，虽然全局注意力机制也能捕获全局上下文，但其计算开销巨大（计算量增加约 25%）。SPP 凭借其高效的池化操作，在精度上略优于 Non-local 的同时，大幅降低了计算负担（计算量降低 19.8%）。

最佳组合：本文提出的 Base-RG-LA(E)-SPP(S) 方案集合了各种算子的优势，实现了最低的 EPE (0.557 像素) 和 D1 (1.90%)，相比 Baseline 提升显著。这充分证明了区域分治的特征提取策略是解决立体匹配特征表示难题的更优解。

表 2.3 代价聚合阶段的消融性实验。

方法	3D 局部注意力		视差全局注意力	D1	EPE	参数量	浮点运算次数
	全区域	边缘区域					
Baseline ^[26]				2.59	0.736	6.91	260.38
Base-ours				1.90	0.557	5.72	216.26
Base-ours-3DLA(A)	✓			1.88	0.551	5.72	216.78
Base-ours-3DLA(E)		✓		1.81	0.536	5.72	216.42
Base-ours-3DLA(E)-Dg (CoAtRSNet)		✓	✓	1.67	0.497	5.72	216.79

(3) 区域 3D 局部注意力聚合的验证

接下来，本文验证在代价聚合阶段引入区域 3D 局部注意力的必要性。基于上述最佳特征提取模型（记为 Base-ours），本文构建了 Base-ours-3DLA(E)，即仅在边缘代价体的聚合过程中引入 3D 局部注意力。

实验结果如表 2.3 所示。引入该模块后，EPE 进一步从 0.557 像素降至 0.536 像

素，D1 降至 1.81%。传统的 3D 卷积采用共享权重的滑动窗口，容易造成代价体在物体边界处的模糊。而在边缘区域引入 3D 局部注意力，实际上是在 3D 空间中引入了内容自适应的各向异性扩散，使得聚合过程沿着物体表面进行，而非跨越边界，从而显著增强了边缘的几何锐度。

(4) 视差维全局注意力的验证

最后，本文验证视差维全局注意力模块对视差维全局滤波的作用。在 Base-ours-3DLA(E) 的基础上加入视差维全局注意力模块，即构成了完整的 CoAtRSNet。如表格 2.3 所示，加入该模块后，EPE 显著降低至 0.497 像素（降低 7.3%），D1 降至 1.67%。这一改进主要源于视差维全局注意力模块改善了多峰分布问题。局部 3D 卷积受限于感受野，无法区分真实的视差峰值与由重复纹理引起的虚假峰值。全局视差机制允许视差候选值在全局范围内进行竞争，从而大幅提升了弱纹理及重复纹理区域的匹配精度。综上所述，相比于原始 Baseline，完整的 CoAtRSNet 在 Scene Flow 上实现了 EPE 降低 32.5%，D1 降低 35.5% 的同时计算量减少 16.7% 的卓越性能。




图 2.6 在 KITTI 2012、KITTI 2015 以及 Scene Flow 数据集上关于梯度阈值的消融性实验。

(5) 梯度阈值 α 的参数敏感性分析

梯度阈值 α 是决定区域划分的关键超参数。为了探究其对性能的影响，本文设置了不同的 α 值（10, 20, 30, 40）并在三个数据集上进行了实验。如图 2.6 所示：

- 当 α 过小（如 10）时，部分弱边缘被误分为平滑区域，导致细节丢失，EPE 较

高。

- 当 α 过大（如 40）时，大量平滑区域被误分为边缘区域，不仅增加了计算量（注意力计算），还引入了不必要的噪声，导致精度下降。
- 当 $\alpha = 20$ 时，模型在所有数据集上均取得了最佳的平衡点。因此，本文后续实验均固定 $\alpha = 20$ 。这表明自然图像中显著边缘的像素占比在统计上具有一定的稳定性。

表 2.4 Scene Flow 数据集上的算法普适性实验结果。

方法	>1px (%)	>2px (%)	>3px (%)	D1 (%)	EPE (px)	参数量 (M)	浮点运算次数 (G)
PSMNet ^[7]	14.00	7.30	5.30	4.40	1.279	5.22	256.51
PSM-CoAtRS	7.65	4.28	3.19	2.66	0.798	4.14	208.12
CFNet ^[76]	10.01	6.55	5.16	4.51	0.970	22.24	169.25
CF-CoAtRS	8.52	5.76	4.58	3.84	0.826	22.07	148.85
GwcNet ^[26]	7.70	4.29	3.16	2.59	0.736	6.91	260.38
Gwc-CoAtRS	5.23	2.88	2.11	1.67	0.497	5.72	216.79

2.7.5 算法普适性分析

本文提出的 CoAtRS 并非仅仅是一个特定的网络，而是一种通用的立体匹配增强框架。为了验证其普适性，本文将 CoAtRS 方法应用于三种现有的 SOTA 网络：GwcNet^[26]、PSMNet^[7] 和 CFNet^[76]，分别构建了 Gwc-CoAtRS、PSM-CoAtRS 和 CF-CoAtRS。本文在两个标准 Benchmark 上都进行了消融，验证本文算法的通用性。

（1）Scene Flow 上的提升

如表 2.4 所示，本文提出的算法在三个基准网络上均有一致的显著提升：

- PSMNet^[7]：原始 D1 为 4.40%，改进后降至 2.66%（提升 39.6%），且计算量降低了 18.9%。
- CFNet^[76]：作为级联网络的代表，原始 D1 为 4.51%，改进后降至 3.84%（提升 14.9%），计算量降低 12.1%。
- GwcNet^[26]：提升同样显著，D1 降低 35.5%，FLOPs 降低 16.7%。

这一结果有力地证明了，无论基准网络是基于 3D 卷积堆叠（PSMNet 和 GwcNet）还

是级联结构（CFNet），CoAtRS 算法都能在显著提升精度的同时，通过高效的区域分治策略降低计算复杂度。

表 2.5 KITTI 2012 基准数据集上的算法普适性实验结果。

方法	KITTI 2012 ^[83]				
	>3px (%)		>4px (%)		榜单排名
	Noc	All	Noc	All	
PSMNet ^[7]	1.49	1.89	1.12	1.42	71
PSM-CoAtRS	1.28	1.67	0.95	1.26	35
CFNet ^[76]	1.23	1.58	0.92	1.18	33
CF-CoAtRS	1.17	1.57	0.89	1.18	12
GwcNet ^[26]	1.32	1.70	0.99	1.27	53
Gwc-CoAtRS	1.15	1.53	0.89	1.17	9

表 2.6 KITTI 2015 基准数据集上的算法普适性实验结果。

方法	KITTI 2015 ^[84]						榜单排名
	All (%)			Noc (%)			
	D1-bg	D1-fg	D1-all	D1-bg	D1-fg	D1-all	
PSMNet ^[7]	1.86	4.62	2.32	1.71	4.31	2.14	134
PSM-CoAtRS	1.44	3.44	1.77	1.31	3.13	1.61	22
CFNet ^[76]	1.54	3.56	1.88	1.43	3.25	1.73	61
CF-CoAtRS	1.41	3.31	1.73	1.30	2.93	1.57	14
GwcNet ^[26]	1.74	3.93	2.11	1.61	3.49	1.92	99
Gwc-CoAtRS	1.39	3.25	1.70	1.27	2.89	1.54	7

（2）KITTI 基准数据集上的提升

为了进一步验证算法的泛化性能与鲁棒性，本文在 KITTI 2012 和 KITTI 2015 官方评测榜单上进行了在线评测。本文将 CoAtRS 模块集成至三个主流基线模型（PSMNet、CFNet、GwcNet）中，并将测试结果提交至 KITTI 官方评测服务器。如表

表 2.7 基准数据集 KITTI 上的结果。

方法	KITTI 2012 ^[83]				KITTI 2015 ^[84]			
	>2px Noc	>2px All	EPE Noc	EPE All	D1-bg Noc	D1-bg All	D1-all Noc	D1-all All
SGM-Net ^[161]	3.60	5.15	0.7	0.9	2.23	2.66	3.09	3.66
GC-Net ^[70]	2.71	3.46	0.6	0.7	2.02	2.21	2.61	2.87
PSMNet ^[7]	2.44	3.01	0.5	0.6	1.71	1.86	2.14	2.32
EdgeStereo ^[61]	2.32	2.88	0.4	0.5	1.69	1.84	1.89	2.08
AA-Net ^[162]	2.90	3.60	0.5	0.6	1.80	1.99	2.32	2.55
GANet ^[75]	1.89	2.50	0.4	0.5	1.34	1.48	1.63	1.81
CFNet ^[76]	1.90	2.43	0.4	0.5	1.43	1.54	1.73	1.88
LEAStereo ^[163]	1.90	2.39	0.5	0.5	1.29	1.40	1.51	1.65
HITNet ^[164]	2.00	2.65	0.4	0.5	1.54	1.74	1.74	1.98
GwcNet ^[26]	2.16	2.71	0.5	0.5	1.61	1.74	1.92	2.11
CoAtRSNet	1.83	2.37	0.4	0.5	1.27	1.39	1.54	1.70

2.5 和表 2.6 所示，改进后的模型在各项关键指标上均实现了显著的性能跃升：

- KITTI 2012: 如表 2.5 所示，在衡量离群值的 $> 3px$ (Noc) 指标上，PSM-CoAtRS 将误差率从原始的 1.49% 降低至 1.28%，相对误差缩减了 14.1%；Gwc-CoAtRS 同样表现出色，将误差率从 1.32% 压低至 1.15%，相对提升达 12.9%。这表明 CoAtRS 高效且普遍性地提升了基线方案的精度。
- KITTI 2015: 相较于 KITTI 2012，KITTI 2015 数据集包含更多动态物体与复杂背景，挑战性更高。如表 2.6 所示，在此基准上，CoAtRS 带来了更为显著的收益：PSM-CoAtRS 在最具代表性的 D1-all (All) 指标上，将误匹配率从 2.32% 大幅降至 1.77%，相对性能提升高达 23.7%，这一改进直接使其排名从第 134 位飙升至第 22 位。Gwc-CoAtRS 在背景区域 (D1-bg) 展现了极强的鲁棒性，以 1.39% 的低误差率大幅优于原始模型的 1.74%，该指标在榜单中高居第 7 位。此外，针对通常难以处理的前景区域 (D1-fg)，PSM-CoAtRS 亦将误差从 4.62% 降至 3.44%。

这种跨模型、跨数据集的一致性提升，充分证明了 CoAtRS 并非仅针对特定架构的




图 2.7 KITTI 2012 和 KITTI 2015 测试集的可视化对比。黑框突出了本文的方法所取得的明显改进。

微调方案，而是一种通用的、能够显著提升精度的高效算法，能够无缝集成到现有的 3D 卷积神经网络架构中并高效提升其性能。

2.7.6 基准数据集性能对比与定性分析

最后，本文将最终的 CoAtRSNet 与当前国际上最先进的立体匹配算法进行了全方位的横向对比。

(1) KITTI 基准测试

如表 2.7 所示，在 KITTI 2012 和 2015 榜单上，CoAtRSNet 表现优异。相比于同样采用注意力机制的 GA-Net^[75]，CoAtRSNet 在 KITTI 2015 的全区域 D1-all 指标上更优（1.70% vs 1.81%），且在背景区域 D1-bg (Noc) 上以误差率 1.27% 取得了最佳性能。相比于当下的最佳方案 CFNet^[76]，CoAtRSNet 同时在 KITTI 2012 和 KITTI 2015 上均取得显著优势，尤其是在 KITTI 2015 上，前景区域 D1-bg (Noc) 指标提升 11.2%。从定性结果来看，如图 2.7 所示，在处理边缘区域（如路牌杆、树干边缘）时，GwcNet^[26] 和 CFNet^[76] 往往会出现模糊现象，而 CoAtRSNet 生成的视差图边缘锐利、连续。这直接归功于边缘区域的局部注意力增强。在弱纹理区域，CoAtRSNet 也表现出更强的平滑性和鲁棒性，这得益于视差维全局注意力模块的全局约束。

(2) Scene Flow 基准测试

表 2.8 在 Scene Flow, ETH3D 和 Middlebury 基准数据集上的性能对比。

Model	Scene Flow		ETH3D				Middlebury		
	EPE (px)	>0.5px (%)	>1px (%)	>2px (%)	EPE (px)	RMSE (px)	>2px (%)	EPE (px)	RMSE (px)
PSMNet ^[7]	1.09	16.90	5.02	1.09	0.33	0.66	42.1	6.68	19.4
EdgeStereo ^[61]	1.11	18.75	6.76	1.94	0.39	0.81	18.7	2.68	9.84
GANet ^[75]	0.84	25.41	6.56	1.10	0.40	0.75	18.9	12.2	35.4
CFNet ^[76]	0.97	9.87	3.31	0.77	0.24	0.51	10.1	3.49	15.4
LEAStereo ^[163]	0.78	-	-	-	-	-	7.15	1.43	8.11
HITNet ^[164]	0.43	7.83	2.79	0.80	0.20	0.46	6.46	1.71	9.97
GwcNet ^[26]	0.76	12.04	3.66	1.09	0.29	0.67	-	-	-
CoAtRSNet	0.49	5.54	2.02	0.42	0.17	0.38	6.50	1.42	7.94

如表格 2.8 所示, 在 Scene Flow 测试集上, CoAtRSNet 取得了 0.49 像素的极低 EPE, 远优于 LEAStereo^[163] (0.78 像素) 和 GwcNet (0.76 像素)。这表明在相同的数据驱动下, CoAtRSNet 能够更好地拟合复杂的几何结构。如图 2.8 所示, CoAtRSNet 在边缘细节和无纹理区域均有显著提升。

(3) ETH3D 基准测试

ETH3D^[35] 是对细节要求最苛刻的数据集, 如表格 2.8 所示, CoAtRSNet 在此榜单上大幅度超越了最先进的方案。在 >0.5px 指标上, CoAtRSNet 达到了 5.54%, 显著优于 HITNet^[164] (7.83%) 和 CFNet^[76] (9.87%)。在提交时, CoAtRSNet 在 ETH3D 官网公布的所有指标中均排名前三, 其中 >1px 和 >2px 指标排名第一。从定性结果来看, 如图 2.9 所示, 尽管 ETH3D 的训练数据极其稀缺 (仅 27 对), CoAtRSNet 依然展现出了卓越的泛化能力和鲁棒性。这种在极少样本下依然能保持边缘锐利、平面平滑的特性, 充分证明了本文提出的区域分治与注意力机制特征提取与聚合策略具有极强的特征表征能力与泛化潜力。

(4) Middlebury 基准测试

Middlebury 2014^[36] 是立体匹配领域公认难度较高的基准数据集, 以其高达 3000×2000 的高图像分辨率、高达 400 像素的超大视差搜索范围以及复杂的室内几何结构而著称。该数据集包含了大量非朗伯体表面 (如镜面反射、金属光泽) 及




图 2.8 Scene Flow 测试集上的可视化对比。黑框突出了本文的方法所取得的明显改进。




图 2.9 在 ETH3D 基准上的可视化对比。黄框突出了本文的方法所取得的明显改进。




图 2.10 Middlebury 测试集的可视化对比。可视化结果表明，本文的方法在保留边缘细节的能力上有了显著地提高。

复杂的物体遮挡关系，是检验算法在病态区域和细小结构等极端条件下鲁棒性的最佳基准数据集。在此基准上，CoAtRSNet 再次证明了其作为当前最先进立体匹配算法的卓越性能。如表格 2.8 所示，CoAtRSNet 在各项关键指标上均排名前二。特别是对于大误差极其敏感的均方根误差指标（RMSE），本文的方法取得了排名第一的优异成绩，同时在平均误差指标上也位列第一。RMSE 指标的领先充分说明了

CoAtRSNet 不仅在整体匹配上保持了高精度，更极大地减少了严重错误匹配的产生，具有极高的可靠性。

从定性结果来看，如图 2.10 的可视化结果所示，Middlebury 场景中充满了极具挑战性的物体堆叠与遮挡以及大面积无纹理区域。基线方法（如 GwcNet）往往因特征平滑而导致视差图在物体边界处产生模糊，在无纹理的区域（白色桌面）产生严重空洞现象。相比之下，CoAtRSNet 得益于强大的特征表达能力，能够生成锐利且连续的深度边界，完美复原了场景的几何结构。

2.8 本章小结

本章针对现有立体匹配网络存在的特征表示矛盾（即卷积在平滑区域的高效性与在边缘区域的模糊效应冲突）及全局注意力的高计算成本问题，提出了一种基于区域分治的卷积与注意力协同立体匹配网络（CoAtRSNet）。其核心思想是通过自适应的区域分治策略，将图像解耦为物理属性截然不同的边缘与平滑区域，并分别采用异构算子进行处理，从而大幅提升立体匹配在视觉退化场景下的精度。具体而言，本章构建了基于梯度的区域分治模块，并设计了异构的特征提取与代价聚合机制：在平滑区域，利用卷积与金字塔池化高效聚合大范围上下文以消除匹配歧义；在边缘区域，则引入局部注意力与 3D 局部聚合机制，利用其内容自适应特性显著抑制边缘模糊，实现几何细节的锐利重建。此外，针对 3D 卷积在视差维度感受野受限导致的局部性缺陷，本章创新性地提出了视差维全局注意力融合机制，大幅增强了算法在弱纹理及重复纹理区域的鲁棒性。

在 Scene Flow^[69]、KITTI^[83,84]、ETH3D^[35] 及 Middlebury^[36] 等基准数据集上的广泛实验全面验证了该方法的先进性。消融实验证实，区域分治与混合架构的设计有效化解了特征表示矛盾，实现了精度与计算效率的双赢。此外，将 CoAtRS 策略无缝嵌入 GwcNet^[26]、PSMNet^[7] 等经典模型均取得了显著的性能增益，展现出作为通用增强框架的巨大潜力。整体对比表明，CoAtRSNet 在多个权威榜单名列前茅，特别是在 ETH3D 和 Middlebury 等极具挑战性的复杂开放场景中表现卓越。综上所述，本章突破了传统单一算子的局限，不仅为立体匹配提供了全新的高效范式，更为后续章节在跨域泛化与非理想观测条件下的深度估计研究奠定了坚实的特征基础。

3 跨域场景下单目-双目协同迭代的高泛化立体匹配方法

3.1 引言

在上一章中,针对立体匹配中普遍存在的视觉退化场景匹配难问题,提出了基于区域分治思想的 CoAtRSNet^[165]。通过显式地解耦边缘与平滑区域特征,并将卷积和注意力模块进行优势互补,CoAtRSNet 在标准的测试基准上显著提升了深度估计的精细度与准确性。上述改进主要集中在域内性能的提升,即假设测试场景与训练数据服从近似的数据分布。因此在面向开放世界的多样化场景的实际部署中,其鲁棒性和泛化能力仍面临着严峻的挑战。这一瓶颈的根源在于当前的立体匹配范式受制于两个核心维度的缺陷——真实训练数据的规模局限性与物理假设的场景局限性。

(1) 高昂的数据获取成本导致了严重的跨域泛化难题: 与二维图像任务不同,获取像素级致密的双目视差真值极其困难且昂贵。通常需要依赖高精度的激光雷达或结构光设备,且需要在严格控制的参数环境下进行数据采集。在复杂的室外动态场景中,LiDAR 采集的真值往往是稀疏的,且难以覆盖玻璃及远距离物体等。这种高昂的标注成本导致现有的真实世界立体匹配数据集规模小,远远无法满足深度神经网络对数据多样性的需求。因此,主流网络不得不严重依赖于大规模合成数据集(如 Scene Flow^[69])进行预训练。然而,合成数据与真实世界在光照模型、材质属性及纹理分布上存在显著的域差异。由于缺乏足够多样的真实样本进行监督,基于匹配的网络极易对合成数据的特定纹理分布产生过拟合,导致模型在迁移到未见过的真实场景时,不仅在反光和弱纹理等病态场景失效,在常规区域的精度也会大幅下降,表现出较差的零样本泛化能力。

(2) 光度一致性假设失效: 光度一致性假设在现实复杂场景中极易失效,这种匹配病态问题进一步加剧了泛化性难题。无论是基于代价体滤波还是迭代优化的方法,其算法内核本质上仍是从特征匹配出发。即使引入注意力机制或 Transformer 来增强特征的全局表达能力,或者引入边缘检测和语义分割作为辅助信息,这些改进大多停留在特征增强层面,并未改变算法对匹配线索的强依赖。因此,在面对弱纹理与重复纹理区域、非朗伯体表面(玻璃、镜面或金属表面等)、细微结构与远距离目标等病态区域时,现有方法依然难以获得高精度的深度预测,在跨域泛化时这一

问题会更加显著。

为了突破上述数据规模与物理假设的双重瓶颈，学术界开始探索引入单目深度估计作为先验信息来辅助立体匹配。这一思路的动机主要基于单目深度估计的两个独特优势：1) 天然的结构鲁棒性：单目估计不依赖于多视图间的几何对应，而是通过学习纹理梯度、透视关系及物体语义等单目线索来推断深度。这使得其在弱纹理、反光区域依然能保持结构的完整性；2) 海量训练数据的泛化优势：单目深度估计任务不需要严格的双目视差真值，可以通过利用互联网上数以亿计的图像数据进行大规模的无监督训练（如近期的 Depth Anything^[129], MiDaS^[23], Depth PRO^[132] 等基础模型），再结合少量有标签的单目数据即可达到极其优异的性能。这些模型在涵盖了极其丰富场景的海量数据上进行训练后，获得了极强的语义理解能力和对复杂场景结构的高泛化性能。




图 3.1 KITTI 数据集上单目深度（Depth Anything）转化的视差与真值视差之间的差距。(a)：没有任何对齐。(b)：使用全局尺度和全局位移值将深度与 GT 对齐（所有像素相同）。(c)：本文提出的双分支迭代优化策略，逐像素优化偏移的结果。即使与 GT 全局对齐，SOTA 单目深度模型仍然表现出严重的噪声。本文提出的方法有效地解决了这一问题，通过逐像素偏移来细化单目深度，充分释放了单目深度先验在立体匹配中的作用。

然而，单目深度先验无法通过简单的融合手段直接嵌入到立体匹配框架中。目前的融合策略仍面临着核心的尺度与偏移模糊及特征冲突等问题，具体挑战如下：

(1) **单目深度的尺度与偏移缺失**：单目深度估计本质上恢复的是相对深度，而非

绝对的度量深度。由于缺乏绝对尺度的参考，单目模型输出的深度图往往存在未知的缩放因子和偏移量。如图 3.1 (a) 所示，直接对比现有的 SOTA 单目模型^[25]输出与真实视差，可以看出两者之间存在巨大的数值鸿沟。即使是最先进的单目深度估计模型在和视差真值进行全局的尺度和偏移对齐之后，仍存在严重的偏移噪声，这是由于真实场景中对于所有像素来说无法共享一个全局的尺度和偏移，例如曲面和斜面，单目深度就很难准确的估计其连续深度。

(2) 简单的融合策略难以处理噪声：早期的尝试如 CLStereo^[136]等一些简单的多模态融合方法，试图通过直接拼接单目特征或深度图来引导立体匹配。然而，由于单目深度不仅存在全局的尺度偏移，还存在局部的非线性畸变，这种粗糙的融合往往会引入严重的噪声。特别是当单目预测在某些区域不准确时，简单的特征融合反而会破坏立体匹配在纹理丰富区域原本的高精度优势，导致融合单目深度反而带来负优化。

综上所述，当前的立体匹配领域面临着一个两难的局面：一方面，纯双目方法受限于训练数据稀缺和物理假设失效，在病态区域精度低且跨域泛化能力差；另一方面，引入单目先验虽然能带来丰富的结构信息和泛化潜力，但受困于尺度漂移和噪声导致融合效率低。如何设计一种机制，既能保留立体匹配在良性区域的绝对深度精度，又能自适应地恢复单目先验的尺度与偏移，从而充分结合单目深度估计在病态区域的结构鲁棒性以及卓越的零样本泛化优势，是本章研究的核心切入点。

针对前文所述的双目训练数据稀缺导致的泛化瓶颈以及物理假设失效加剧病态区域匹配难题，本章提出了一种全新的立体匹配范式。该范式旨在通过双分支迭代互优化机制，将单目深度估计模型在海量数据中习得的强大泛化性结构先验，高效充分的嵌入进立体匹配的度量空间中。本章的核心思想基于以下两个深刻的观察与推论。

第一，立体匹配任务可被重构为具备强泛化性的单目结构的绝对深度度量化过程。鉴于单目基础模型（如 Depth Anything 系列^[25,129]）是在亿级规模的多样数据上训练得到的，它们对开放世界中的复杂结构（如透明物体、反光表面、细微结构）具备极强的语义理解与零样本泛化能力，能够提供极佳的相对几何关系。相比之下，立体匹配模型虽然受限于数据规模导致泛化性差，但其在纹理丰富区域能够提供精确的绝对度量约束。因此，本文不应让立体匹配模型在病态区域强行回归视差，而应重新定义其角色，即利用图像中置信度高的双目匹配点去解算单目深度的未知尺

度和偏移参数。通过这种方式，本文将单目深度的泛化优势与立体匹配的绝对度量优势相结合，在保留单目完整结构信息的同时赋予其实际绝对深度的物理意义。这不仅降低了立体匹配的计算绝对深度的复杂性，更从本质上大幅改善了双目网络在跨域迁移时泛化性能差的问题。

第二，单目与双目信息在特征空间与物理空间均具有互补性，且这种互补性可通过迭代机制被显著放大。双目方法在强纹理区域精度高，但在弱纹理及光度不一致的区域性能弱；单目方法在结构上鲁棒，对光度因素不敏感，但在数值上存在尺度漂移。一个理想的系统应当构建双向互优化的交互闭环。首先，利用双目分支在丰富纹理区域计算出的高置信度视差，可以动态地、逐像素地校正单目分支的尺度和偏移预测，使其从相对深度逼近真实物理深度。其次，经过尺度校正后的单目深度图，携带了来自海量数据的强泛化先验。它可以作为一种强有力的几何引导，保证双目分支在反光、遮挡或弱纹理区域的正确结构，并且修正其在合成数据到真实数据迁移过程中产生的匹配错误，大幅提升其面对跨域未知场景的泛化性能。这种互补性可以通过循环神经网络进行多阶段的迭代演进，使得两个分支在优化过程中交替促进，最终收敛到一个既具备双目绝对尺度、又具备单目泛化结构完整性的最优解。

基于以上思想，本章提出了一种名为 **MonSter** 的新型立体匹配算法框架。该框架摒弃了传统方法仅将单目网络作为一个固定先验的简单融合策略，而是构建了一个并行的双分支互优化架构：单目深度分支负责生成具备抗干扰能力和跨域泛化能力的初始相对深度。立体匹配分支负责提供物理尺度约束下的高精度绝对深度。为了实现两者的有机结合，本章设计了两个关键的交互模块：1) 立体引导对齐 (**Stereo Guided Alignment, SGA**) 模块：利用双目匹配的置信度图作为判断依据，自适应地筛选出可靠的立体匹配结果（即剔除因域差异或病态区域产生的噪声），以此为基准来更新单目深度的逐像素偏移。这一设计巧妙地规避了将双目分支中的噪声传导给单目分支的风险，确保了单目先验在引入度量信息的同时保持其结构的稳定性；2) 单目引导微调 (**Mono Guided Refinement, MGR**) 模块：将对齐后的单目深度图作为几何先验注入到立体匹配的迭代优化单元中。在反光、弱纹理等双目立体匹配易失效区域，网络会根据置信度图来判断是否依赖输入的单目深度来生成视差，从而显著修复病态区域的缺陷并提升了模型在未见场景中的表现。

此外，为了最大化泛化收益，本章利用大规模预训练的单目深度大模型 **Depth Anything V2**^[25] 作为基础编码器，通过特征迁移网络将其强大的语义和结构特征共

享给立体匹配分支。这不仅减少了训练开销，更直接赋予了 MonSter 卓越的零样本泛化能力。本章提出的 MonSter 算法有效解决了双目立体匹配因训练数据稀缺导致的泛化性差以及物理假设失效导致的病态区域匹配难的问题。主要贡献总结如下：

- 1) **提出了一种解耦式的立体匹配新范式：**本章将复杂的立体匹配任务解耦为利用单目大模型获取几何结构与利用双目线索恢复逐像素尺度-偏移的两个子任务。通过这种范式转换，算法不再过度依赖于有限的双目训练数据来学习匹配，而是转而利用单目基础模型的数据优势，显著提升了立体匹配的泛化能力。
- 2) **设计了双分支迭代互优化网络架构：**提出了一种单目与双目双分支迭代互优化的网络结构，并设计了立体引导对齐与单目引导微调两个核心模块。SGA 模块利用置信度引导的自适应机制，解决了单目深度向视差转换时的尺度漂移与噪声干扰问题；MGR 模块则实现了充分且高效地将单目先验嵌入立体匹配过程，使得二者在迭代过程中交替优化，实现了协同增强的效果。
- 3) **实现了卓越的综合性能与零样本泛化能力：**MonSter 在五个国际权威基准数据集（Scene Flow^[69], KITTI 2012^[83], KITTI 2015^[84], Middlebury^[36], ETH3D^[35]）上均取得了排名第一的优异成绩。特别是在对细节和纹理要求极高的 ETH3D 基准上，MonSter 将坏点率指标相对最先进的方法提升了显著的 49.5%。更重要的是，在仅使用合成数据（Scene Flow）训练的情况下，MonSter 在真实世界数据集上的零样本泛化性能大幅领先于现有算法，证明了其作为立体匹配基础模型的巨大潜力。
- 4) **验证了单目大模型在立体匹配中的应用价值：**本章探索了如何高效利用现有的单目深度估计模型来赋能立体匹配。实验表明，通过特征共享和互优化机制，MonSter 能够有效克服双目数据规模小的短板。即便是面对极其困难的反光区域和细微结构，算法也能重构出完整、锐利的几何形态，弥补了主流匹配方法的短板。

3.2 基于单目-双目双分支迭代优化的立体匹配网络

本节将阐述本文提出的基于单目-双目双分支迭代优化的立体匹配网络的整体架构设计。针对前文所述的立体匹配在病态区域面临的匹配线索匮乏以及双目训练数




图 3.2 MonSter 网络框架总览。MonSter 由单目深度估计分支、立体匹配分支和双分支迭代优化模块组成。该方法利用先验对双分支进行迭代改进，有效地解决了立体匹配中的泛化性弱以及病态区域难题。

据稀缺导致的泛化性瓶颈，本章提出了一种名为 MonSter 的新型双分支迭代互优化立体匹配网络。如图 3.2 所示，MonSter 的整体架构打破了传统立体匹配算法主要依赖匹配代价体的单一范式，通过引入单目深度估计分支，构建了一个迭代互优化的系统。

MonSter 框架主要由三个核心组件构成：

- 1) **单目深度估计分支**：利用在大规模异构数据上预训练的基础模型，提取具备强泛化能力的场景语义特征与初始结构信息。该分支主要负责提供鲁棒的结构性先验，即初始相对深度。
- 2) **立体匹配分支**：通过构建几何编码体并通过 GRU 获得初始双目视差，负责从双目图像对中提取高精度的绝对尺度下的双目视差。该分支主要负责提供绝对度量信息，以修正单目预测的尺度与偏移。
- 3) **双分支迭代优化模块**：这是本章方法的核心创新点。该模块包含立体引导对齐与单目引导微调两个子模块，通过两个不共享参数的独立 GRU 模块分别进行时序更新，在多次迭代中实现单目结构与双目度量的深度融合。

在推理过程中，双分支首先分别生成初始的单目相对深度图与双目视差图。随后，两者进入互优化阶段：全局尺度-偏移对齐模块首先将单目深度转换至视差空间并进行粗略对齐；接着，SGA 模块利用双目匹配的置信度信息动态校正单目视差的逐像素偏移；对称地，MGR 模块利用校正后的单目几何先验引导双目视差在病态区域的优化。这种设计确保了系统既能充分挖掘单目模型的丰富深度先验，又能保持双目匹配的精准度量。

3.3 单目深度与立体匹配双分支构建

MonSter 框架的核心思想在于构建一个优势互补的双分支架构，旨在将单目深度估计的强泛化能力与立体匹配的高精度度量能力进行充分融合。本节将详细阐述基于大模型的单目分支构建、立体匹配分支构建以及特征迁移机制。

3.3.1 基于基础大模型的单目深度估计分支

单目深度分支是整个系统应对跨域场景与病态区域的鲁棒性基石。为了充分利用海量无标签数据中蕴含的通用视觉先验，本章并未采用从零训练的策略，而是通过引入目前最先进的单目深度估计基础模型 Depth Anything V2^[25] 作为单目深度估计分支。具体而言，该分支主要由特征编码器与深度解码器两部分组成。

本文采用 Depth Anything V2 的 ViT-Large 版本作为骨干网络。该编码器继承了 DINOv2^[166] 的架构优势，通过掩码图像建模与自监督学习范式，在数以亿计的互联网图像上习得了具有极强泛化性的视觉表征。与传统的卷积神经网络相比，基于 Transformer 的 ViT 架构具备全局感受野，能够通过多头自注意力机制捕捉图像中的长距离语义依赖。这使得模型在面对缺乏局部纹理线索的区域或非朗伯体表面时，能够依据全局场景上下文推断出合理的相对深度结构。解码端沿用了 DPT^[19] 架构。DPT 通过一系列特征重组与融合模块，将 ViT 输出的序列化词元逐步恢复为高分辨率的空间特征图，最终回归出单目相对深度图 D_M^{raw} 。需要强调的是， D_M^{raw} 仅反映场景中像素点的相对远近关系，存在未知的缩放因子与偏移量。

在 MonSter 的联合训练过程中，本文对单目编码器实施了严格的参数冻结。这一设计基于两点核心考量：其一，立体匹配任务通常依赖规模较小的合成数据集进行训练，若对大模型进行全参数微调，极易导致灾难性遗忘现象，破坏其在海量数据上习得的通用特征分布，进而削弱零样本泛化能力；其二，冻结庞大的网络参数显著降低了训练过程中的显存占用与反向传播的计算开销，使得在有限算力下更高效的进行训练优化。

3.3.2 特征迁移网络

立体匹配分支的任务是从双视图中恢复绝对物理尺度。为了与单目分支形成高效协同并避免参数冗余，本章对经典的迭代立体匹配网络 IGEV^[10] 的特征提取网络进行了重构，核心在于设计了一个高效的特征迁移网络，能够复用单目深度估计分

支的特征提取器并且进行特征映射，获得更加适用于立体匹配任务的匹配特征。在 MonSter 中，为了实现特征复用，立体分支共享单目分支冻结的 ViT 编码器特征。然而，ViT 输出的是单一分辨率的图像切块特征，而主流立体匹配算法大多需要多尺度特征（1/4, 1/8, 1/16, 1/32）来构建不同分辨率的代价体并指导由粗到精的优化。

为此，本章设计了一个轻量级的特征迁移网络。该模块由一系列级联的 2D 卷积层、上采样及下采样操作组成。它充当了适配器的角色，将 ViT 输出的特征 F_{ViT} 映射为一组包含丰富细节与语义的多分辨率特征集合 $\mathcal{F} = \{f_1, f_2, f_3, f_4\}$ ，其中 f_k 的分辨率为原图的 $1/2^{6-k}$ 。这一设计通过共享基础特征提取器不仅大幅减少了模型的总参数量，更重要的是，它将 ViT 强大的高层语义理解能力注入了立体匹配流程，增强了泛化性。

3.3.3 立体匹配分支

为了从特征迁移网络提取的多尺度金字塔特征 $\mathcal{F}$ 中恢复精确的视差图，本章采用了 IGEV^[10] 的核心架构，构建了一个包含全局几何感知能力与局部匹配细节的立体匹配分支。该分支主要由组合几何编码体构建模块与基于卷积 GRU 的循环迭代更新模块组成。

(1) 组合几何编码体的构建

传统的立体匹配方法通常仅依赖单一类型的代价体（如全相关体或分组相关体），难以同时兼顾非局部的几何结构信息与局部的纹理匹配细节。为了解决这一矛盾，本章构建了一种混合代价体结构，融合了分组相关体经过 3D 正则化后的几何信息与全像素对相关体的高频细节。

给定从图像 I_l 和 I_r 中提取的左视图特征 $f_{l,4}$ 和右视图特征 $f_{r,4}$ ，本文构建了一个分组相关代价体。具体而言，将特征沿通道维度划分为 N_g 个组（ $N_g = 8$ ），并逐组计算相关性图：

$$C_{corr}(g, d, x, y) = \frac{1}{N_c/N_g} \langle f_{l,4}^g(x, y), f_{r,4}^g(x - d, y) \rangle \quad (3.1)$$

其中， $\langle \cdot, \cdot \rangle$ 表示内积操作， d 为视差索引， N_c 表示特征通道总数。仅基于特征相关性的代价体 C_{corr} 难以捕捉全局几何结构。为解决这一问题，本文进一步采用轻量级 3D 正则化网络 R 对 C_{corr} 进行处理，以获取几何编码体 C_G ：

$$C_G = R(C_{corr}) \quad (3.2)$$

该 3D 正则化网络 R 基于轻量级 3D U-Net 架构，包含三个下采样模块与三个上采样模块。每个下采样模块由两个 $3 \times 3 \times 3$ 的 3D 卷积构成。三个下采样阶段的通道数分别为 16、32 和 48。每个上采样模块则包含一个 $4 \times 4 \times 4$ 的 3D 转置卷积和两个 $3 \times 3 \times 3$ 的 3D 卷积。本文利用从左视图特征计算得到的权重来激励代价聚合过程中的代价体通道。对于代价聚合中尺寸为 $\frac{D}{i} \times \frac{H}{i} \times \frac{W}{i}$ 的代价体 C_i （其中 $i = 4, 8, 16, 32$ ），引导代价体激励表示为：

$$C'_i = \sigma(f_{l,i}) \odot C_i \quad (3.3)$$

其中， σ 为 Sigmoid 激活函数， $\odot$ 表示哈达玛积。嵌入了引导代价体激励操作的 3D 正则化网络能够有效地推断并传播场景几何信息，从而生成几何编码体。此外，本文还计算了对应左右特征之间的全对相关性，以获取局部特征相关性。为了扩大感受野，本文在视差维度上利用核大小和步长均为 2 的 1 维平均池化，构建了两级的 C_G 金字塔和全对相关体 C_A 金字塔。最终，本文将 C_G 金字塔与 C_A 金字塔相结合，形成了组合几何编码体 C_c 。

(2) 基于卷积 GRU 的循环迭代更新

在获得组合几何编码体后，立体匹配分支采用循环神经网络架构进行视差的逐级细化。不同于 RAFT-Stereo^[9] 将初始视差设为 0，这会导致迭代收敛缓慢，本章利用经过正则化的组合几何编码体 C_c 直接回归一个高质量的初始视差 D_S^{init} 。通过沿视差维度应用 Soft-argmin 操作（即 Softmax 加权求和），可以得到概率期望视差：

$$D_S^{init} = \sum_{k=0}^{D_{max}-1} k \cdot \text{Softmax}(C_c(k)) \quad (3.4)$$

这一设计为后续的卷积 GRU 迭代提供了一个比较精准的视差初值，显著加速了优化的收敛过程。迭代更新的核心单元由三层级联的卷积 GRU 组成。在第 k 次迭代中，网络利用当前的预测视差 d_k 从组合几何编码体 C_c 中检索几何特征。具体而言，采用线性插值机制，以 d_k 为中心，在索引半径 r 的范围内从 C_G 和 C_A 及其金字塔层级中采样，构建几何特征向量 G_f ：

$$G_f = \sum_{i=-r}^r \text{Concat} \left\{ C_G(d_k + i), C_A(d_k + i), C_G^{pool}(\frac{d_k}{2} + i), C_A^{pool}(\frac{d_k}{2} + i) \right\} \quad (3.5)$$

该特征向量 G_f 融合了当前视差附近的几何分布概率与局部匹配相似度。随后， G_f

与当前视差 d_k 经过编码后输入 ConvGRU 单元，更新隐状态 h_k ：

$$\begin{aligned} z_k &= \sigma(\text{Conv}([h_{k-1}, x_k], W_z)), \quad r_k = \sigma(\text{Conv}([h_{k-1}, x_k], W_r)) \\ \tilde{h}_k &= \tanh(\text{Conv}([r_k \odot h_{k-1}, x_k], W_h)), \quad h_k = (1 - z_k) \odot h_{k-1} + z_k \odot \tilde{h}_k \end{aligned} \quad (3.6)$$

其中输入 $x_k = [\text{Enc}(G_f), \text{Enc}(d_k), d_k]$ ，Enc 代表两层堆叠的卷积编码器，Conv 代表一层卷积操作。最终，通过两个卷积层从隐状态 h_k 中解码出视差残差 Δd_k ，更新当前视差： $d_{k+1} = d_k + \Delta d_k$ 。经过 N_1 次迭代（本章设置 $N_1 = 2$ 以保持高效），输出立体匹配分支的初始视差图，作为后续双分支互优化的输入。

3.4 基于互优化的双分支迭代更新机制

在获得初始的单目相对深度 D_M^{raw} 和初始立体视差 D_S^0 后，MonSter 进入其核心阶段——双分支迭代互优化。这一阶段通过耦合两个对称的交互模块，旨在同时解决单目深度的尺度/偏移模糊问题以及立体匹配在病态区域的歧义问题。

3.4.1 全局尺度-偏移对齐

单目分支输出的是逆深度，其在数学形式上与视差呈线性关系，但缺失了绝对尺度与偏移。在进行像素级融合之前，必须首先将单目深度映射到与立体视差尺度上大致相同的度量空间。本文采用全局最小二乘法进行粗对齐。假设 $D_M^{\text{raw}}(i)$ 为第 i 个像素的原始单目逆深度， $D_S^0(i)$ 为对应的初始立体视差。本文的目标是求解全局最优的缩放因子 s_G 和偏移量 t_G ，使得二者在有效区域内的平方误差最小化：

$$s_G, t_G = \arg \min_{s_G, t_G} \sum_{i \in \Omega} (s_G D_M^{\text{raw}}(i) + t_G - D_S^0(i))^2 \quad (3.7)$$

其中， Ω 为采样掩码。为了剔除立体匹配中的离群噪声（如天空、遮挡区或极远处的错误匹配），本文采用了自适应百分位滤波策略：仅选取立体视差值排序在 20% ~ 90% 区间的像素参与参数估计。通过全局变换，本文得到粗对齐后的单目视差：

$$D_M^0 = s_G D_M^{\text{raw}} + t_G \quad (3.8)$$

这一步将相对深度转换为了具有近似物理度量的视差，为后续的 SGA 和 MGR 模块提供了统一的数值基准。

3.4.2 立体引导的单目对齐模块 (SGA)

尽管全局对齐修正了整体的尺度分布,但由于真实场景中存在复杂的几何结构,全局单一的仿射变换参数 (s_G, t_G) 无法拟合所有像素的深度变换关系,导致局部区域仍存在显著的误差。SGA 模块的核心任务是利用立体匹配提供的度量线索,迭代地估计单目的逐像素偏移。

(1) 置信度引导的视差残差机制

直接利用立体视差来校正单目视差存在风险:如果立体匹配本身在反光或无纹理区域失效,错误的度量信息会传播并破坏单目分支正确的结构。因此,SGA 引入了基于视差残差的置信度门控机制。

在第 j 次迭代更新中,利用当前的立体视差预测值 d_S^j 对右视图特征 f_r 进行逆向变换操作。通过计算变换后的右图特征与左图特征 f_l 之间的 L_1 距离,构建视差残差图 R_S^j :

$$R_S^j(x, y) = \|f_l(x, y) - f_r(x - d_S^j(x, y), y)\|_1 \quad (3.9)$$

该残差图直观地量化了立体匹配的可靠性: R_S^j 的数值越小,表明左右视图在当前视差假设下的特征一致性越高,双目分支的结果越可信;反之,较大的残差通常对应于遮挡、误匹配或非朗伯反射区域,指示网络应降低对该区域立体匹配结果的依赖。

(2) 条件引导的卷积 GRU

SGA 采用条件引导的卷积 GRU 架构来更新单目分支的隐状态 h_M 。其输入条件特征 x_S^j 是一个包含多模态信息的高维张量:

$$x_S^j = [\text{Enc}([G_S^j, R_S^j, D_S^j]), \text{Enc}(D_S^j), D_S^j] \quad (3.10)$$

Enc 代表该条件向量的设计蕴含了深刻的物理意义:

- G_S^j (几何特征): 从立体几何编码体中索引得到的特征,包含了局部匹配代价与多峰分布信息,指导网络判断当前位置是否存在更优的匹配峰值。
- R_S^j (置信度): 上述视差残差,作为置信度门控信号调节 GRU 对立体匹配分支视差的依赖程度。
- D_S^j (当前状态): 提供当前迭代轮次的双目分支的视差度量信息。

GRU 的内部更新过程遵循标准的门控机制,通过遗忘门 z^j 和重置门 r^j 动态融

合历史信息与当前观测：

$$\begin{aligned}
 z^j &= \sigma(\text{Conv}([h_M^{j-1}, x_S^j], W_z) + c_z) \\
 r^j &= \sigma(\text{Conv}([h_M^{j-1}, x_S^j], W_r) + c_r) \\
 \tilde{h}_M^j &= \tanh(\text{Conv}([r^j \odot h_M^{j-1}, x_S^j], W_h) + c_h) \\
 h_M^j &= (1 - z^j) \odot h_M^{j-1} + z^j \odot \tilde{h}_M^j
 \end{aligned} \tag{3.11}$$

最终，通过解码头从更新后的隐状态 h_M^j 中回归出残差偏移 Δt ，并更新单目视差： $D_M^{j+1} = D_M^j + \Delta t$ 。这一机制使得单目视差能够自适应地向高置信度的立体视差靠拢，同时在低置信度区域保持自身的结构平滑性。

3.4.3 单目引导的立体微调模块（MGR）

与 SGA 对称，MGR 模块旨在利用经过对齐的高质量单目视差，反向修复立体匹配在病态区域的缺陷。MGR 同样采用了相同但参数独立的条件引导的卷积 GRU，但其更新对象是立体分支的隐状态 h_S ，且输入条件 x_M^j 来源于单目分支：

$$x_M^j = [\text{Enc}([G_M^j, R_M^j, D_M^j]), \text{Enc}(D_M^j), D_M^j] \tag{3.12}$$

这里的关键区别在于 G_M^j 的交叉索引机制。通常，立体匹配网络利用自身的视差 D_S 去索引几何编码体。而在 MGR 中，则利用单目视差 D_M^j 去索引立体分支的几何编码体。这一设计的物理直觉在于：在弱纹理或反光区域，立体匹配可能陷入局部极值，导致 D_S 索引到的代价特征质量极差。然而，单目分支凭借强大的语义先验，往往能预测出更符合场景结构的 D_M 。用单目分支的 D_M 去索引几何编码体，相当于在代价体中用更接近真实视差的值去索引匹配代价特征。将这一特征作为条件输入给立体分支的卷积 GRU，能够有效地将立体匹配分支视差从错误的局部极值引导向正确的视差附近。

通过 N_2 次 SGA 与 MGR 的交替迭代，双分支实现了深度互补与纠错，最终输出兼具单目结构完整性与立体度量准确性的高质量视差图。

3.4.4 损失函数设计

MonSter 采用了端到端的全监督训练方式，利用 Smooth L1 距离作为损失函数。为了强化迭代优化过程的收敛性并避免梯度消失，本文采用了序列监督策略，即对

立体匹配分支和单目分支在每一次迭代中的输出都进行监督。

记立体匹配分支在前 N_1 次初始迭代及后续 N_2 次互优化迭代中的输出序列为 $\{D_S^i\}_{i=0}^{N_1+N_2-1}$ ，单目分支在互优化阶段的输出序列为 $\{D_M^k\}_{k=0}^{N_2-1}$ 。总损失函数 $\mathcal{L}_{Total}$ 定义为双分支损失的加权和：

$$\mathcal{L}_{Total} = \mathcal{L}_{Stereo} + \mathcal{L}_{Mono} \quad (3.13)$$

其中，立体分支损失 $\mathcal{L}_{Stereo}$ 包含了所有迭代阶段的误差：

$$\mathcal{L}_{Stereo} = \sum_{i=0}^{N_1+N_2-1} \gamma^{N_1+N_2-1-i} \|D_S^i - d_{gt}\|_1 \quad (3.14)$$

单目分支损失 $\mathcal{L}_{Mono}$ 仅在互优化阶段计算：

$$\mathcal{L}_{Mono} = \sum_{k=0}^{N_2-1} \gamma^{N_2-1-k} \|D_M^k - d_{gt}\|_1 \quad (3.15)$$

上式中， d_{gt} 为视差真值， γ 为指数衰减系数，实验中依据经验设置为 $\gamma = 0.9$ 。这种随着迭代次数增加而权重递增的策略，迫使网络更加关注后续精细化阶段的输出质量，确保最终的输出足够高精度且收敛。通过这种强监督约束，单目分支在迭代过程中不断逼近真实的度量深度，从而为立体分支提供更准确的几何引导。而双目立体匹配分支的最终输出则为 MonSter 的最终视差预测。

3.5 实验结果与分析

为了全面、客观地评估本章提出的 MonSter 算法在应对立体匹配中病态区域性能瓶颈及泛化能力不足等关键问题上的有效性，本节将在五个主流国际立体匹配基准数据集上开展系统的定量与定性实验。实验旨在验证以下核心假设与改进效果：（1）引入单目深度先验并结合双分支互优化机制，对于弱纹理、反光及细微结构等病态区域匹配精度的提升作用；（2）MonSter 在未见场景下的跨域泛化能力；（3）立体引导对齐（SGA）与单目引导微调（MGR）模块在特征交互中的互补增强效应。

本节的组织结构如下：3.5.1 节详细介绍所使用的数据集特性及评估指标；3.5.2 节阐述实验的具体实施细节与训练策略；3.5.3 节在五大基准数据集上与当前最先进（SOTA）的方法进行横向对比分析；3.5.4 节针对反光、边缘及远距离背景等典型病

态区域进行深度性能剖析；3.5.5 节重点评估模型的跨域零样本泛化能力；3.5.6 节通过详尽的消融实验验证各个组件的有效性以及高效性分析。

3.5.1 数据集与评估指标

为了保证实验结论的可靠性与广泛性，本文选取了涵盖合成场景、真实自动驾驶场景、高精度室内外场景及高分辨率复杂几何场景的五个权威数据集：Scene Flow^[69]、KITTI 2012^[83]、KITTI 2015^[84]、ETH3D^[35] 以及 Middlebury 2014^[36]。

(1) Scene Flow^[69] 数据集：Scene Flow 是包含许多复杂精细结构的合成立体匹配数据集，包含 FlyingThings3D、Driving 和 Monkaa 三个子集，共计 35 454 对训练图像和 4 370 对测试图像，分辨率为 960×540 。该数据集提供像素级致密的视差真值。评估指标采用端点误差（End-Point Error, EPE）和 1 像素误差率（ $> 1\text{px}$ ）作为主要指标。EPE 衡量预测视差与真值的平均欧氏距离， $> 1\text{px}$ 衡量误差超过 1 像素的异常值比例。

(2) KITTI 2012^[83] & KITTI 2015^[84] 数据集：KITTI 系列数据集采集自真实世界的自动驾驶场景，包含复杂的街道、车辆及光照变化，视差真值由激光雷达稀疏采集获得。KITTI 2012 包含 194 对训练图和 195 对测试图，主要针对静态场景。评估指标包括非遮挡区域（Noc）和所有区域（All）的 2 像素（ $> 2\text{px}$ ）及 3 像素（ $> 3\text{px}$ ）误差率。KITTI 2015 包含 200 对训练图和 200 对测试图，增加了大量动态车辆场景。评估指标重点关注 D1-all（异常值比例），并细分为背景区域（D1-bg）、前景区域（D1-fg）和全图（D1-all）。

(3) ETH3D^[35] 数据集：ETH3D 是一个包含室内外场景的高精度灰度立体数据集，具有低纹理、强光照变化及小基线等特点。该数据集规模较小，仅包含 27 对训练图和 20 对测试图，但对算法在微小视差下的精度要求极高。评估指标采用 $> 1\text{px}$ （误差大于 1.0 像素的比例）和均方根误差（RMSE）作为核心指标。该数据集是检验算法细节保持能力的重要基准。

(4) Middlebury 2014^[36] 数据集：Middlebury 是以高分辨率（高达 3000×2000 ）和复杂几何结构著称的经典数据集，包含 28 对训练图和 15 对测试图（涵盖室内物体堆叠、强反光表面等）。评估指标采用 $> 2\text{px}$ （误差大于 2.0 像素的比例）和 RMSE。该数据集主要考验算法在大视差范围下的鲁棒性。

(4) DrivingStereo^[167] 数据集：DrivingStereo 是一个大规模且极具挑战性的真实

场景自动驾驶双目基准数据集，涵盖了丰富多样的城市街道与复杂路况。该数据集的显著特点是提供了按真实天气条件严格划分的测试子集，包含了晴天、多云、雨天和雾天等不同光照与极端天气工况。评估指标主要采用 $> 3\text{px}$ （误差大于 3.0 像素的比例）。引入该数据集主要用于重点检验算法在暴雨、大雾等局部匹配特征严重退化的非理想观测条件下，模型的零样本泛化能力与鲁棒性。

3.5.2 实验细节

（1）软硬件环境与优化策略：本章提出的 MonSter 基于 PyTorch 深度学习框架实现，所有实验均在搭载 NVIDIA RTX 3090 GPU 的高性能工作站上完成。本文采用了 AdamW^[168] 优化器，并参照基准模型 IGEV^[10] 的设置，将梯度裁剪范围设为 $[-1, 1]$ 。训练过程中采用 One-Cycle 学习率调整策略，最大学习率设为 2×10^{-4} 。

（2）单目分支设置：对于单目深度估计分支，本文选用了 Depth Anything V2 的 ViT-Large 版本作为基础模型。为了防止立体匹配任务破坏单目大模型在海量数据上习得的强泛化特征表示，本文在训练全过程中冻结了单目编码器及解码器的参数。这一策略不仅保证了泛化性，也显著降低了训练显存开销。

（3）训练流程与数据集配置：为了确保模型充分收敛并适应不同领域的特征分布，本文采用了分阶段的训练策略：预训练阶段遵循标准设定，首先在 Scene Flow 数据集上进行预训练，批次大小设为 8，共训练 200k 次迭代。微调阶段针对 KITTI 数据集，本文在 KITTI 2012 和 2015 的混合数据集上微调 50k 次迭代。针对 ETH3D 和 Middlebury 数据集，为了获得更强的鲁棒性，本文构建了一个基础训练集（Basic Training Set, BTS）。BTS 由 Scene Flow^[69]、CREStereo^[81]、TartanAir^[169]、Sintel Stereo^[170]、Falling Things^[171] 和 InStereo2k^[172] 等多个公开数据集混合而成。本文在 BTS 与目标数据集（ETH3D^[35] 和 Middlebury^[36]）的组合数据上进行微调，以实现最佳性能。

3.5.3 基准性能对比分析

为了验证 MonSter 的综合性能，本文将其与当前国际上最先进的立体匹配算法进行了全方位的对比，包括基于代价滤波的方法（如 GwcNet^[26]、ACVNet^[8]）和基于迭代优化的方法（如 RAFT-Stereo^[9]、CREStereo^[81]、IGEV^[10]、Selective-IGEV^[50]）。

（1）Scene Flow 数据集

表 3.1 Scene Flow 测试集的定量评价。**最好的结果加粗。**

方法	GwcNet ^[26]	LEAStereo ^[163]	ACVNet ^[8]	IGEV ^[10]	Selective-IGEV ^[50]	MonSter
EPE (px)↓	0.76	0.78	0.48	0.47	0.44	0.37

在 Scene Flow 测试集上的定量评估结果如表格 3.1 所示。MonSter 取得了 0.37px 的端点误差，大幅超越了该数据集的最佳精度。相比于基准模型 IGEV^[10]（EPE 误差为 0.47 像素），MonSter 将误差降低了 21.28%；相比于专门针对频率选择优化的最新方法 Selective-IGEV^[50]（EPE 误差为 0.44 像素），性能提升了 15.91%。这表明，即便在纹理丰富的合成数据集中，引入单目结构先验也能有效修正局部匹配误差，提升整体精度。

表 3.2 ETH3D 和 Middlebury 基准测试结果。除了 RMSE 单位为像素以外，其余所有指标单位都为百分比。“Noc”表示无遮挡区域，“All”表示所有像素。

方法	ETH3D ^[35]			Middlebury ^[36]		
	> 1px	> 1px	RMSE	> 2px	> 2px	RMSE
	Noc	All	Noc	Noc	All	Noc
GwcNet ^[26]	6.42	6.95	0.69	-	-	-
GANet ^[75]	6.22	6.86	0.75	-	-	-
LEAStereo ^[163]	-	-	-	7.15	12.10	8.11
ACVNet ^[8]	2.58	2.86	0.45	13.70	19.50	32.2
RAFT-Stereo ^[9]	2.44	2.60	0.36	4.74	9.37	8.41
CREStereo ^[81]	0.98	1.09	0.28	3.71	8.13	7.70
IGEV ^[10]	1.12	1.51	0.34	4.83	8.16	12.80
CroCo-Stereo ^[93]	0.99	1.14	0.30	7.29	11.11	8.91
DLNR ^[173]	-	-	-	3.20	6.98	7.78
Selective-IGEV ^[50]	1.23	1.56	0.29	2.51	6.04	7.26
LoS ^[140]	0.91	1.03	0.31	4.20	8.03	6.99
NMRF-Stereo ^[174]	-	-	-	-	-	-
MonSter(Ours)	0.46	0.72	0.20	2.64	6.14	6.71

(2) ETH3D 基准数据集

ETH3D 基准数据集榜单的结果如表格 3.2 所示，MonSter 在该榜单上大幅超越了之前最好的方法，在所有已发布的指标上均位列第一名。在核心指标 > 2px (Noc)




图 3.3 ETH3D 的定性结果。MonSter 在具有强反射，精细结构等挑战性的区域中均优于基线方法 IGEV。

上，MonSter 将错误率从此前最佳方法 LoS^[140] 的 0.91% 降低至 0.46%，相对提升幅度高达 46.9%。相比于基准 IGEV^[10]，MonSter 在 $> 1\text{px}$ (Noc)、 $> 1\text{px}$ (All) 和 RMSE (Noc) 三项指标上分别取得了 58.9%、52.3% 和 41.2% 的惊人提升。

如图 3.3 所示，在 ETH3D 典型的室内弱纹理墙面和室外复杂光照场景中，相比基线方法 IGEV，MonSter 在反光区域和精细结构等具有挑战性的场景中的性能提升显著，结构锐利。这充分证明了单目先验在填补匹配线索缺失方面的巨大价值。

(3) Middlebury 基准数据集

在 Middlebury^[36] 高分辨率数据集上，MonSter 同样表现优异。表格 3.2 所示，在 RMSE 指标上，MonSter 取得了全榜单第一的成绩 (6.71)，优于 CREStereo^[81] (7.70) 和 LoS^[140] (6.99)。在 $> 2\text{px}$ (Noc) 指标上，相比 IGEV 提升了 45.3%。这表明 MonSter 在处理大视差范围和复杂物体堆叠场景时具有极高的鲁棒性。

(4) KITTI 2012 & KITTI 2015 基准数据集

表格 3.3 所示，在真实自动驾驶场景中，MonSter 同样占据了榜首位置。为了公平的对比所有方法，本文将测试结果提交至 KITTI 官方评测榜，MonSter 在 KITTI 2012 和 KITTI 2015 官方排行榜上双榜第一。KITTI 2015 榜单上，针对全图区域的 D1-all 指标，MonSter 达到了 1.41%，相比 CREStereo^[81] (1.69%) 和 Selective-IGEV^[50]

表 3.3 KITTI 2015 和 KITTI 2012 基准榜单的结果。

方法	KITTI 2015 ^[84]				KITTI 2012 ^[83]			
	D1-bg	D1-all	D1-bg	D1-all	> 2px	> 2px	> 3px	> 3px
	Noc	Noc	All	All	Noc	All	Noc	All
GwcNet ^[26]	1.61	1.92	1.74	2.11	2.16	2.71	1.32	1.70
GANet ^[75]	1.40	1.73	1.55	1.93	1.89	2.50	1.19	1.60
LEAStereo ^[163]	1.29	1.51	1.40	1.65	1.90	2.39	1.13	1.45
ACVNet ^[8]	1.26	1.52	1.37	1.65	1.83	2.35	1.13	1.47
RAFT-Stereo ^[9]	1.44	1.69	1.58	1.82	1.92	2.42	1.30	1.66
CREStereo ^[81]	1.33	1.54	1.45	1.69	1.72	2.18	1.14	1.46
IGEV ^[10]	1.27	1.49	1.38	1.59	1.71	2.17	1.12	1.44
CroCo-Stereo ^[93]	1.30	1.51	1.38	1.59	-	-	-	-
DLNR ^[173]	1.42	1.61	1.60	1.76	-	-	-	-
Selective-IGEV ^[50]	1.22	1.44	1.33	1.55	1.59	2.05	1.07	1.38
LoS ^[140]	1.29	1.52	1.42	1.65	1.69	2.12	1.10	1.38
NMRF-Stereo ^[174]	1.18	1.46	1.28	1.57	1.59	2.07	1.01	1.35
MonSter(Ours)	1.05	1.33	1.13	1.41	1.36	1.75	0.84	1.09

(1.55%) 分别提升了 16.6% 和 9.0%。而对于 KITTI 2012 榜单，针对 > 3px (All) 指标，MonSter 将错误率降至 1.09%，相比此前最高精度的 NMRF-Stereo^[174] (1.35%) 和 Selective-IGEV^[50] (1.38%) 分别提升了 19.3% 和 21.0%。这些结果有力地证明了 MonSter 在处理室外动态场景、车辆遮挡及远距离目标时的卓越能力。

3.5.4 病态区域性能分析

MonSter 的核心设计动机之一是利用单目先验解决立体匹配在病态区域的失效问题。为了验证这一设计的有效性，本文针对反光区域、边缘/非边缘区域以及远距离背景进行了专项评估。

(1) 反光区域

反光表面（如车窗、金属车身）违反了光度一致性假设，是立体匹配算法十分棘手的痛点。本文在 KITTI 2012 的反光区域上进行了测试。如表格 3.4 所示，MonSter 在所有误差率 (> 2px, > 3px, > 4px) 下均取得了第一名。具体而言，在 > 4px (All) 指标上，MonSter 相比 Selective-IGEV^[50] 和 LoS^[140] 分别提升了 30.2% 和 29.2%。更值

表 3.4 KITTI 2012 反光区域榜单结果。

方法	KITTI 2012 ^[83] 反光区域结果					
	> 2px		> 3px		> 4px	
	Noc	All	Noc	All	Noc	All
ACVNet ^[8]	11.42	13.53	7.03	8.67	5.18	6.48
CREStereo ^[81]	9.71	11.26	6.27	7.27	4.93	5.55
IGEV ^[10]	7.57	8.80	4.35	5.00	3.16	3.57
Selective-IGEV ^[50]	6.73	<u>7.84</u>	3.79	<u>4.38</u>	2.66	3.05
LoS ^[140]	<u>6.31</u>	<u>7.84</u>	<u>3.47</u>	4.45	<u>2.41</u>	<u>3.01</u>
NMRF-Stereo ^[174]	10.02	12.34	6.35	8.11	4.80	6.09
MonSter(Ours)	5.66	6.81	2.75	3.38	1.73	2.13

表 3.5 SceneFlow 测试集不同区域的结果比较。

方法	边缘区域		平滑区域	
	EPE	>1 px	EPE	>1 px
IGEV ^[10]	2.23	20.42	0.41	4.58
Selective-IGEV ^[50]	2.18	20.01	0.38	4.35
MonSter(Ours)	1.91	18.59	0.31	3.57

得注意的是，相比于专门针对反光问题设计的 SOTA 方法 NMRF-Stereo^[174]，MonSter 实现了 65.02% 的性能飞跃。这得益于单目分支在反光区域依然能保持稳定的几何结构预测，并通过 MGR 模块有效纠正了双目分支的错误匹配。

(2) 边缘与平滑区域

本文将 Scene Flow^[69] 测试集通过 Canny 算子划分为边缘区域和平滑区域。如表格 3.5 所示，MonSter 在两类区域均表现出色。在边缘区域，在 EPE 指标上，MonSter 相比基准 IGEV 提升了 14.3%；在平滑区域，提升更为显著，相比基线方法 IGEV 在 EPE 指标上提升幅度高达 24.4%。即便与专门优化边缘性能的 Selective-IGEV^[50] 相比，在 EPE 误差指标上 MonSter 依然保持了 12% 以上的优势。这说明 MonSter 的单目-双目双分支迭代互优化的架构在边缘区域和平滑区域均性能提升显著。

(3) 远距离区域

立体匹配在背景等远距离区域由于像素占比少导致匹配困难，往往精度下降严

重。在 KITTI 2015^[84] 中，D1-bg 指标专门反映背景区域（通常包含大量远距离物体）的异常值比例。如表格 3.3，MonSter 在 D1-bg 指标上相比基准模型提升了 18.12%。这得益于单目大模型不是从匹配去获取深度，而是对远距离场景（如天空、远山、建筑）具有天然的结构预测能力，不受像素占比的限制，更适合预测细微结构。

表 3.6 跨场景泛化性能比较。顶部部分显示了仅在 Scene Flow 上训练的模型的泛化结果，而底部部分显示了在混合数据集上训练的模型的泛化结果。

方法	KITTI-12 > 3px (%)	KITTI-15 > 3px (%)	Middlebury > 2px (%)	ETH3D > 1px (%)
训练数据集: <i>Scene Flow</i>				
CFNet ^[76]	4.72	5.81	9.80	5.80
RAFT-Stereo ^[9]	5.12	5.74	9.36	3.28
CREStereo ^[81]	5.03	5.79	12.88	8.98
Selective-IGEV ^[50]	5.64	6.05	12.04	5.40
NMRF-Stereo ^[174]	4.23	5.10	7.54	3.82
IGEV ^[10]	4.84	5.51	6.23	3.62
MonSter(Ours)	3.62	3.97	5.17	2.03
训练数据集: <i>Scene Flow + CREStereo + Tartan Air</i>				
IGEV ^[10]	3.95	4.30	5.56	2.38
MonSter(Ours)	2.95	3.23	2.94	1.21




图 3.4 零样本泛化可视化对比：所有模型都在 Scene Flow 上进行训练，并直接在 KITTI 上进行测试。与基线 IGEV 相比，本文的方法 MonSter 在具有挑战性的区域（如反射表面、无纹理）以及精细的结构和远距离物体中显示出显著的改进。

3.5.5 零样本泛化能力评估

除了在同分布数据集上的精度，跨域泛化能力是衡量立体匹配算法实用性的关键，也是设计 MonSter 最重要的目的。本文采用了最严格的零样本评估方案：模型仅在合成数据集上训练，直接在未见过的真实场景数据集上进行测试。

(1) 仅使用 Scene Flow 训练

如表格 3.6 上半部分所示，在仅使用 Scene Flow 训练的情况下，MonSter 在 KITTI 2012^[83]、KITTI 2015^[84]、Middlebury^[36]、ETH3D^[35] 四个真实数据集上的泛化性能均大幅领先于所有对比方法。值得一提的是，MonSter 的泛化性能甚至超越了专门为跨域泛化设计的 CFNet^[76] 和 CREStereo^[81]。例如在 ETH3D 上，MonSter 的 $> 1\text{px}$ 误差仅为 2.03%，而 CREStereo 高达 8.98%。为了更直观地展示模型的零样本泛化能力，图 3.4 展示了仅在 Scene Flow 上训练的模型直接迁移到真实 KITTI 场景下的可视化对比结果。相比于基准模型 IGEV^[10]，MonSter 在面临域差异巨大的挑战性区域时表现出了显著的鲁棒性。具体而言，在反光表面（如车窗玻璃）、弱纹理区域（如平滑墙壁）、细微结构（如远处的杆状物）以及远距离目标上，基准模型往往会出现大面积的视差缺失或严重的错误估计。相反，MonSter 得益于单目大模型提供的强结构先验，能够准确地恢复出这些区域的几何形态，生成完整且锐利的视差图。这种强大的跨域适应能力，充分证明了 MonSter 在未见真实场景中卓越的泛化潜力。

(2) 混合数据集训练

由于 Scene Flow 数据集中富含的是虚拟合成的物体，且堆叠混乱，和真实世界场景域差异过大。为了进一步挖掘潜力，本文在训练集中加入了 CREStereo^[81]（虚拟数据）和 TartanAir^[169] 数据集（虚拟数据，但更接近真实世界分布），来进一步考察 MonSter 的域迁移能力。如表格 3.6 下半部分所示，通过增加训练数据的多样性后，MonSter 的泛化能力进一步提升。在 Middlebury 和 ETH3D 上，相比同样设置的 IGEV^[10] 基准，MonSter 分别实现了 47.1% 和 49.2% 的性能提升。图 3.5 展示了零样本测试的可视化结果。在从未见过的真实场景中，MonSter 依然能准确恢复出纤细的树枝、反光的玻璃和无纹理的墙面，而基准模型则出现了大面积的失效。这充分证明了利用单目大模型的先验知识是解决立体匹配泛化难题的有效途径。

(3) 极端天气泛化性能评估

为了进一步验证模型在真实非理想观测条件下的鲁棒性，本文在包含了多种复




图 3.5 在本文采集的真实世界数据的零泛化可视化对比。MonSter 在无纹理区域、反射区域和精细结构等方面明显优于 IGEV。

杂天气情况的 DrivingStereo^[167] 数据集上进行了零样本泛化性能评估。常规的跨域测试主要集中在光照良好、视野清晰的场景，而在暴雨、大雾等极端天气下，图像的局部光度一致性和高频纹理特征会被严重破坏，导致传统立体匹配算法极易产生严重的匹配歧义。

表 3.7 展示了各类先进方法在晴天、多云、雨天和雾天四种真实场景子集上的定量评估结果（评估指标为 $> 3\text{px}$ 的误差百分比，数值越低越好）。从表中数据可以明显观察到，在光照条件较好的晴天和多云场景下，各方法的性能表现差异相对较小；然而，在极具挑战的雨天场景中，由于雨滴遮挡、路面镜面反射及整体能见度下降，纯粹依赖多视角局部特征进行匹配的方法（如 ZeroStereo^[175] 和 FoundationStereo^[141]）性能出现了严重的退化，其误差率直接飙升至 11% 以上。相比之下，本文提出的 MonSter 展现出了极其卓越的鲁棒性，在雨天场景下的误差率仅为 3.08%，大幅超越了其他先进基线模型。这一显著的性能保持能力，充分验证了本文单目-双目互优化架构的前瞻性：在极端天气导致双目局部特征严重失效的病

态区域，单目深度估计分支凭借其在大规模预训练中获取的全局语义先验与空间上下文结构能力，能够为立体匹配提供极其稳健的深度兜底作用，有效纠正了匹配错误。总体而言，MonSter 在四种极端天气条件下的平均误差率达到了最低的 2.69%，强有力地证明了利用单目先验解决非理想观测条件下鲁棒性瓶颈的有效性，为其在全天候开放场景中的实际部署奠定了基础。

表 3.7 不同天气条件下 DrivingStereo 数据集上的零样本泛化性能比较。评估指标为 $> 3\text{px}$ 误差率 (%)，数值越小越好。最优结果以**加粗**显示。

方法	晴天	多云	雨天	雾天	平均
Nerf-Stereo ^[176]	2.88	2.95	8.47	3.41	4.43
ZeroStereo ^[175]	3.15	2.69	11.71	1.70	4.81
FoundationStereo ^[141]	3.22	2.81	11.20	2.50	4.93
MonSter	2.60	2.12	3.08	2.94	2.69

3.5.6 消融实验与模型分析

为了深入剖析 MonSter 各个组件的贡献，本文在 Scene Flow^[69] 数据集上进行了详尽的消融实验。实验结果总结于表格 3.8。

(1) 视差融合机制的有效性

单目深度通常包含大量噪声，直接融合极具挑战性。本文将所提出的单目引导微调 (MGR) 模块替换为参数量相当的卷积网络 (标记为 Conv)，直接拼接单目深度与双目视差进行融合 (标记为 Mono+Conv)。结果显示，相比于 Mono+Conv，采用 MGR 模块 (Mono+MGR) 将 EPE 误差从 0.46 降低至 0.43，降低了 6.5%。这证明了 MGR 中基于条件引导的 GRU 机制能够更充分地融合单目深度和双目视差，而非简单的加权平均。

(2) 尺度与偏移校正的重要性

如图 3.1 所示，仅进行全局对齐仍会残留显著的局部尺度偏移误差。本文在 Mono+MGR 的基础上引入了立体引导对齐 (SGA) 模块。实验表明，引入 SGA 后，EPE 进一步降低了 9.3%，像素误差率降低了 10.7%。这证实了利用高置信度的立体线索对单目深度进行逐像素的尺度-偏移校正，是释放单目先验潜力的关键步骤。

(3) 特征共享的增益

表 3.8 各模块在 Scene Flow 测试集上的消融实验。

方法	单目深度	视差融合	尺度优化 & 偏移优化	特征共享	EPE (px)	>1px (%)	推理时长 (S)
Baseline (IGEV)					0.47	5.21	0.37
Mono+Conv	✓	Conv			0.46	5.12	0.64
Mono+MGR	✓	MGR			0.43	4.96	0.65
Mono+MGR+Conv	✓	MGR	Conv		0.42	4.82	0.65
Mono+MGR+SGA	✓	MGR	SGA		0.39	4.43	0.66
Full model (MonSter)	✓	MGR	SGA	✓	0.37	4.25	0.64

表 3.9 在 Scene Flow 测试集上进行的通用性以及精度效率验证性实验。

方法	单目深度估计模型	迭代次数	EPE (px)	推理时长 (s)
IGEV ^[10]		32	0.47	0.37
Full model	DepthAnythingV2 ^[25]	32	0.37	0.64
Full model-4iter	DepthAnythingV2 ^[25]	4	0.42	0.34
Full model-V1	DepthAnythingV1 ^[129]	32	0.39	0.64
Full model-midas	MiDaS ^[23]	32	0.41	0.51

单目大模型的编码器包含了丰富的语义上下文信息。本文通过特征迁移网络将单目特征映射到适合双目分支的匹配特征，并作为立体匹配分支的基础特征。如表格 3.8 最后两行所示，这一策略带来了 5.13% 的额外性能提升，证明了单目深度估计大模型的预训练特征通过特征映射之后是十分适合作为立体匹配的特征表达的。

(4) 单目深度估计模型的兼容性

为了验证 MonSter 框架的普适性，本文将单目分支 Depth Anything V2^[129] 分别替换为 Depth Anything V1^[25] 和 MiDaS^[23]。如表 3.9 所示，基于所有单目深度估计大模型的 MonSter 变体均显著优于基准 IGEV^[10]。这表明 MonSter 不依赖于特定的单目模型，且具备随着未来单目深度估计技术进步而持续进化的潜力。

(5) 高效性分析

本节讨论 MonSter 在精度与效率之间的权衡。由于引入了 ViT-Large 架构的单目分支，MonSter 的参数量达到了 356.1M（其中单目分支占 335.3M，且训练时冻结），推理时间从基准的 0.37s 增加至 0.64s。

然而，这种开销是完全值得的，MonSter 的双分支互优化机制极大地简化了视差

搜索的难度。如表格 3.9 所示, 基准模型 IGEV^[10] 通常需要 32 次迭代才能收敛到一个比较高的精度, 而 MonSter 仅需 4 次迭代 ($N_1 = N_2 = 2$) 即可达到超越基线方案 IGEV 的性能。在同为 4 次迭代的设置下, MonSter 相比 IGEV 实现了 10.6% 的精度提升, 并且推理速度快了 8.1%。这意味着在对推理时长敏感的应用中, 可以通过减少迭代次数来提升推理速度, 并能实现更好的精度-速度平衡。综上所述, MonSter 以适度的计算成本换取了突破性的精度提升和泛化能力, 特别是在解决主流方法束手无策的病态区域问题上展现出了巨大的应用价值。

3.6 本章小结

本章针对立体匹配在弱纹理、反光等病态区域匹配困难, 以及因真实训练数据稀缺导致跨域泛化受限的问题, 提出了一种基于单双目协同迭代的高泛化立体匹配方法 (MonSter)。该方法打破了仅依赖双目代价的传统范式, 将任务重构为单目结构感知与双目度量恢复的协同互补过程, 有效克服了算法对局部纹理的过度依赖。具体而言, MonSter 构建了单目与双目双分支迭代优化的网络架构。其中, 立体引导对齐 (SGA) 模块利用高置信度的双目线索, 动态校正单目预测的尺度与偏移, 克服了单目先验的度量模糊问题; 单目引导微调 (MGR) 模块则将校正后的高泛化单目结构作为几何条件注入双目分支, 有效修复了病态区域的几何缺陷。该互优化机制在保留双目物理度量精度的同时, 充分释放了单目大模型在海量数据中习得的强泛化结构先验。

广泛的实验结果表明, MonSter 在精度与泛化性上均取得了突破性进展: 在 Scene Flow^[69]、KITTI^[83,84]、Middlebury^[36] 及 ETH3D^[35] 等权威榜单上均位居榜首。特别是在细节要求极高的 ETH3D 数据集上, 误差指标较现有最优方法大幅降低了 49.5%。此外, MonSter 展现出卓越的零样本泛化能力, 仅凭合成数据训练即可稳健迁移至各类复杂真实场景。综上所述, 本章的研究不仅为高精度跨域立体匹配提供了全新范式, 更验证了借助单目基础模型提升双目几何感知能力的巨大潜力, 为构建通用的立体匹配大模型奠定了坚实基础。

4 非理想观测下单目-多视角融合的抗噪深度估计方法

4.1 引言

在前几章中,本文重点研究了基于双目立体匹配 (Stereo Matching)^[8,10,26,45] 的深度估计技术。通过引入区域分治策略 (CoAtRSNet) 和单目深度先验 (MonSter), 本文显著提升了立体匹配在视觉退化场景和跨域泛化下的精度, 在标准测试基准上取得了最先进的性能和最强的泛化能力。然而, 这些方法和主流方法一样, 都隐含了一个强假设: **系统拥有完美的几何观测条件**, 即双目相机的内参和外参经过了严格的机械校准且保持绝对稳定。在理想的实验室环境或短期测试中, 这一假设通常成立。但在真实的自动驾驶或无人机飞行的长周期运行中, 无论是双目系统还是多视角系统, 都面临着“非理想观测”的严峻挑战。对于双目相机而言, 长期的机械振动、热胀冷缩会导致基线发生微小形变, 使得标定参数失效; 对于更通用的多视角立体视觉而言, 其依赖的相机位姿通常由实时 SLAM 系统或者传感器提供, 不可避免地包含位姿漂移与噪声。这种几何参数 (标定或位姿) 的误差, 会导致极线约束的系统性偏差, 进而引发深度估计性能崩塌。

尽管都存在上述参数敏感的共性问题, 但在迈向更高级别的全场景感知时, MVS 相比于固定双目相机模组展现出了不可替代的优势。双目立体匹配在短距离、静态场景下具备较高的测量精度, 但其固有的物理形态限制, 即基线长度限制了最远探测距离, 且双目模组的视场角通常受限, 难以满足环视感知的需求。与之相比, 多视角立体视觉作为一种更为通用的三维重建范式, 突破了双目系统的结构束缚。MVS 技术不再依赖于单一的固定双目结构, 而是旨在从任意数量且视角差异化的图像集合中恢复场景几何。在自动驾驶或无人机飞行等实际应用中, 这种多视角观测主要来源于两种形式: 1) 空间多视角: 利用部署在移动端不同位置的多个相机 (如环视相机组) 在同一时刻获取的具有重叠视域的图像; 2) 时序多视角: 利用相机在运动过程中拍摄的时序图像帧, 通过运动恢复结构 (Structure from Motion, SfM) 原理构建的动态基线观测。因此 MVS 在开放场景的实际应用中具备以下独有的优势:

- 灵活的基线选择: 在视频序列中, 可以根据移动速度和帧率动态选择不同时间间隔的帧作为参考帧与源帧, 从而构建出长短不一的基线。在高速移动时, 较

长的基线能够显著提升对远距离物体的深度测量精度；而在低速或拥堵场景下，较短的基线则有助于近距离障碍物的精细重建。这种基线的自适应性突破了物理双目模组的硬件限制。

- 时序信息的累积增益：相比双目视觉只能基于同一时刻的单次观测，MVS 能够利用时序多帧图像对同一场景点进行多次观测。理论上，随着观测视角的增加，通过深度滤波等技术可以获得比单次双目匹配更稠密、更精准的三维结构。
- 硬件部署的低成本与普适性：MVS 仅需单目摄像头即可实现，这使得其能够无缝适配当前主流自动驾驶车辆或无人机的鱼眼相机及前视长焦/广角相机方案，极大降低了感知系统的硬件成本与标定维护难度。

基于上述优势，以 MVSNet^[11]、MaGNet^[138] 等为代表的深度学习 MVS 方法在 DTU^[118]、Tanks and Temples^[119] 等静态场景数据集上取得了极高的精度。然而，当本文将这些在理想实验室环境下表现优异的算法迁移至真实的自动驾驶、低空等开放场景时，却面临着极为严峻的非理想观测条件的挑战，也就是能否满足其两个核心假设：1) 相机内参与外参的绝对精确性；2) 场景必须满足静态刚体假设。这在现实世界的应用场景中往往难以成立，构成了当前基于多视角立体视觉的深度估计方法落地的最大障碍。

在 KITTI Eigen split^[177] 或 DDAD^[178] 等基准数据集中，提供的位姿真值通常经过了高精度定位技术校准及离线的全局优化。然而，在实际的车载感知系统中，位姿通常由实时运行的 SLAM 或惯性测量单元等传感器提供。受限于传感器噪声、计算资源限制及复杂场景，实时获取的位姿不可避免地存在误差。对于基于多视图几何约束的 MVS 方法而言，位姿噪声是致命的。MVS 的核心在于利用极线几何将参考图像的像素投影到源图像的极线上进行匹配：

$$p' = K(R \cdot (K^{-1}p \cdot d) + t) \quad (4.1)$$

如公式所示，若旋转矩阵 R 或平移向量 t 存在微小误差，投影点 p' 将偏离真实的极线。这种极线搜索错误会导致匹配代价体失效，深度估计性能崩塌。此外，自动驾驶等开放场景中广泛存在的动态物体（如行驶的车辆、行人）也违反了 MVS 的静态刚体假设。对于动态区域，几何一致性完全失效，强行使用 MVS 匹配会导致严重的深度错误。鉴于此，本文致力于解决上述挑战，探索一种兼具高精度与高鲁棒性的深度估计范式。该方法旨在保留 MVS 在精准相机参数下几何匹配优势的同时，大大

提升在非理想观测条件下的深度估计抗噪性能。

(1) 单目深度与多视角立体视觉的互补性

单目深度估计依赖于图像的纹理、语义和透视关系来进行深度预测。其优势在于完全不依赖位姿，对动态物体和弱纹理区域具有天然的鲁棒性；劣势在于存在尺度和偏移模糊，绝对深度精度有限。而多视角深度估计依赖于多视角几何约束恢复深度。其优势在于具备物理度量精度；劣势在于极度依赖位姿精度，且无法处理动态物体等区域。现有的研究工作通常试图将两者进行融合。然而，目前的 SOTA 融合方法（如 MaGNet^[138]、MVS2D^[15]）大多采用特征拼接或简单的概率加权。这些方法在设计时依然隐含了位姿准确的预设，倾向于让网络主要依赖高精度的 MVS 分支。实验表明，当输入位姿存在噪声时，这些融合系统的性能往往会急剧下降，甚至低于纯单目网络。这是因为错误的立体几何深度信息仍然作为主导，抗噪能力弱。

(2) 几何一致性判别

本章的研究动机在于打破当下主流融合方法对位姿的过度依赖。本文认为，一个鲁棒的系统应当具备自我判别和抗噪兜底的能力：在位姿准确、纹理丰富且符合静态刚体的区域，系统应主要依赖 MVS 分支以获得高精度绝对深度；在位姿抖动、动态物体或弱纹理区域，系统应自适应判别到几何约束的退化，并自动切换为更依赖单目深度估计分支，以保证深度感知的鲁棒性。

实现这一目标的关键在于找到一个能够实时评判多视角立体视觉分支是否可靠的依据。本文通过实验发现，重投影一致性是一个绝佳的度量标准。如果位姿准确且深度正确，将源图像根据深度和位姿变换到参考视角后，应与参考图像高度重合。任何由位姿噪声或动态物体引起的不一致，都会在重投影误差图中产生显著的信号。

基于上述思考，本章提出了一种创新的单目-多视角自适应融合网络（AFNet），旨在解决非理想观测条件下的高精度深度估计问题。不同于以往简单的特征级融合，AFNet 引入了一个显式的自适应融合模块，利用重投影误差生成的置信度图作为核心线索，在像素级别动态融合单目深度与多视角立体视觉分支的深度预测。

本章的主要贡献总结如下：

- 1) 面向非理想观测条件下鲁棒性的单目-多视角自适应融合框架：针对现有 MVS 及融合方法在位姿噪声下性能急剧下降的痛点，AFNet 通过双分支结构以及自适应融合设计，首次实现了在非理想观测条件下自动退化为单目精度的兜底机制，极大地提升了系统的抗噪能力。

- 2) **基于重投影置信度的自适应融合机制：**本文创新性地引入了第三类置信度——重投影置信度，并将其与单目分支置信度、多视角分支置信度相结合，构建了三元置信度融合策略。该机制使得网络能够智能地识别动态物体、弱纹理区域以及位姿误差区域，实现了单目结构先验与多视角几何观测的充分互补。
- 3) **构建深度估计鲁棒性评测基准：**鉴于现有数据集缺乏对位姿噪声的定量评估，本章基于 DDAD^[178] 和 KITTI Eigen split^[177] 数据集，设计了一套包含不同等级合成噪声及真实 SLAM 系统（如 ORB-SLAM2^[150]）噪声的鲁棒性测试基准。这为学术界评估深度估计模型在非理想观测条件下的性能提供了新的标准。
- 4) **最佳精度与鲁棒性的双重突破：**在标准的精确位姿测试中，AFNet 在 DDAD^[178] 和 KITTI Eigen split^[177] 数据集上均取得了目前的最高精度，证明了自适应融合并未牺牲精度上限。更重要的是，在鲁棒性基准测试中，AFNet 展现出了远超 MaGNet^[138]、IterMVS^[103] 等现有方法的稳定性，在强噪声干扰下依然能保持高精度的深度输出，验证了其在真实开放场景中的巨大潜力。

4.2 基于单目-多视角自适应融合的深度估计网络

本节将阐述本文提出的基于单目-多视角自适应融合的深度估计网络的方法原理与网络架构。针对前文分析的现有多视角深度估计方法在相机参数噪声、动态场景等非理想观测条件下存在的性能崩塌问题，AFNet 被设计为一个具备自我感知能力的双分支深度估计系统。该系统的核心设计理念在于几何一致性感知：即在保留多视角几何方法高精度的同时，利用单目深度作为鲁棒性兜底，并通过显式的几何一致性校验机制实现两者在像素级的动态切换与融合。

（1）整体架构

具体而言，AFNet 包含一个共享特征提取骨干网络、一个单目深度估计分支、一个多视角立体视觉深度估计分支以及一个核心的自适应融合模块（Adaptive Fusion Module, AF Module）。单目深度估计分支提供对位姿不敏感的绝对深度先验以及单目语义特征；多视角分支利用多视角几何关系提供绝对度量深度；自适应融合模块则基于重投影一致性自适应融合双分支深度，指引网络在非理想观测条件下自动抑

制受干扰的多视角几何分支，从而在保证精度的同时显著提升系统的鲁棒性。




图 4.1 AFNet 概述。AFNet 由单目深度估计分支、多视角深度估计分支和自适应融合模块三部分组成。两个分支共享特征提取网络，有各自的深度预测和置信图 d_s 、 M_s 、 d_m 和 M_m ，然后由自适应融合模块进行深度融合，得到最终准确、鲁棒的深度预测 d_{fuse} 。

AFNet 的整体架构如图 4.1 所示。系统的输入包括一张参考图像 $I_0 \in \mathbb{R}^{H \times W \times 3}$ ，以及 $N - 1$ 张源图像 $\{I_i\}_{i=1}^{N-1}$ 。同时，系统接收相机的内参矩阵 K 以及源图像相对于参考图像的相对位姿 $T_i = [R_i | t_i]$ ， R_i 和 t_i 分别为旋转矩阵和平移矩阵。系统的输出为参考图像的高精度稠密深度图 $d \in \mathbb{R}^{H \times W}$ 。

(2) 双分支并行处理结构

为了同时获取单目深度与多视角几何线索，系统采用了双分支结构。单目深度估计分支仅以参考图像 I_0 为输入，通过编码器解码器结构直接回归单目深度图 d_s 及其对应的单目置信度图 M_s 。该分支主要依赖图像内容的上下文信息，因此对相机位姿噪声、动态物体具有天然优势，但在绝对尺度恢复上存在局限。多视角立体视觉分支以参考图像 I_0 和源图像 $\{I_i\}$ 为输入，利用平面扫描算法构建几何代价体，并通过 3D 卷积正则化回归多视角深度图 d_m 及其对应的多视角置信度图 M_m 。该分支在理想观测条件下精度高，但对位姿误差极为敏感。

(3) 特征层与深度层多阶段融合

AFNet 的融合策略并非简单的结果加权，而是体现在特征与深度预测的多阶段融合。首先是特征层融合，在多视角分支的代价体正则化阶段，本文将单目分支提

取的高层语义特征引入到多视角分支中。这一设计旨在利用单目语义信息补充多视角代价体在弱纹理区域（如白墙、路面）的信息缺失，辅助代价体滤波过程。然后是深度预测自适应融合，这是本章的核心创新。网络利用预测的深度与相机参数进行图像重投影，计算重投影误差并生成第三类置信度——重投影置信度图 M_w 。该置信度和之前双分支的深度置信度共同作为可靠性指导，指导融合网络根据 d_s 和 d_m 的局部可靠性生成最终的融合深度 d_{fuse} 。

通过上述设计，AFNet 形成了一个由单目深度估计兜底的鲁棒感知系统：在位姿准确且纹理丰富的区域，多视角分支的高精度占主导；在位姿噪声或动态物体区域等非理想观测条件下，系统自适应退化为单目深度估计分支，从而实现了深度估计系统的鲁棒性兜底。

4.3 单目与多视角深度估计分支构建

4.3.1 特征提取器与单目深度估计分支

单目分支的目标是提供一个初始深度估计以及自身的置信度，作为系统的兜底预测，并且能够和多视角深度估计分支优势互补。为了实现高效的特征表达并减少计算冗余，单目与多视角分支共享同一个特征提取骨干网络（Backbone）。本章选用 ConvNeXt-T^[179] 作为骨干网络，因其在保持计算效率的同时具备强大的特征提取能力。骨干网络对输入图像提取四个尺度的特征金字塔 $F_l (l = 1, 2, 3, 4)$ ，其通道数分别为 $C = \{96, 192, 384, 768\}$ ，分辨率依次为原图的 $1/4, 1/8, 1/16, 1/32$ 。然后构建了一个轻量级的解码器，将骨干网络提取的多尺度特征 F_l 进行逐级上采样与融合，最终输出分辨率为 $H/4 \times W/4$ 的高维深度特征图 $D_s \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times 257}$ 。这里输出通道设为 257 是为了同时预测深度概率分布与置信度。为了提高深度预测的鲁棒性并建模不确定性，本文采用基于分类的回归策略。将深度范围 $[d_{min}, d_{max}]$ 在对数空间均匀划分为 $K = 256$ 个深度区间。特征图 D_s 的前 256 个通道经过 Softmax 操作后，构成了单目深度概率体 $P_s \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times 256}$ 。最终的单目深度 d_s 通过软加权求和计算得到：

$$d_s = \sum_{k=1}^K d_k \cdot P_s^k \quad (4.2)$$

其中 d_k 为第 k 个深度区间的中心值， P_s^k 为该区的预测概率。这种软回归方式是可微的，能够进行端到端的训练。特征图 D_s 的第 257 个通道经过 Sigmoid 激活函数

后，作为单目分支的置信度图 $M_s \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4}}$ 。该置信度的回归和深度概率体高度相关，如果概率体呈现多峰分布则置信度低，整体反映了网络对当前像素单目深度预测的不确定性估计。

4.3.2 多视角立体视觉分支

多视角立体视觉分支旨在利用多视角几何约束恢复高精度的度量深度。本章沿用了经典的 MVSNet 架构，并进行了针对性地改进以融合单目信息。首先，多视角分支与单目分支共享骨干网络特征 F_l 。为了保留更多细节，本文利用反卷积层将低分辨率特征上采样并与 $1/4$ 分辨率的特征 F_1 融合，构建用于多视角分支的特征图。

(1) 代价体构建

基于平面扫描原理，本文通过将源图像的特征图通过单应性变换投影到参考相机的视锥中来构建几何代价体。假设参考相机的深度假设为 d ，对于参考图像中的像素 p ，其在源图像 i 中的对应坐标 p'_i 由下式给出：

$$p'_i = K_i (R_{0 \rightarrow i} \cdot (K_0^{-1} p \cdot d) + t_{0 \rightarrow i}) \quad (4.3)$$

其中， K 为内参， $R_{0 \rightarrow i}, t_{0 \rightarrow i}$ 为参考相机到源相机的相对旋转和平移。本文在 $D = 128$ 个深度假设平面上执行上述投影，并将参考特征与投影后的源特征进行组合。为了平衡计算效率与匹配鲁棒性，本文保留了特征通道维度，构建了 4D 特征体。随后，通过两层 3D 卷积将特征通道压缩为 1，得到了初始的 3D 代价体 $C_{init} \in \mathbb{R}^{D \times \frac{H}{4} \times \frac{W}{4}}$ 。

(2) 代价体聚合与置信度回归

初始代价体往往含有由遮挡、弱纹理或重复纹理引起的噪声。本文采用堆叠的 2D 卷积沙漏网络对代价体进行空间正则化。注意，虽然 MVSNet 通常使用 3D 卷积，但在本章中为了与单目特征融合并降低显存占用，本文将深度维度 D 视为通道维度进行处理，最终输出正则化后的多视角代价体 $C_m \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times 256}$ 。此处将通道数上采样至 256 是为了与单目分支的深度划分保持一致。除此以外，本文还将代价体和单目分支特征进行融合，这是一个关键的改进点。主流的 MVS 方法主要依赖几何匹配，容易在弱纹理区域失效。为了解决这一问题，本文将单目分支提取的深度特征 D_s （包含丰富的语义上下文）引入多视角分支中。融合特征 F_{fuse} 的计算公式如下：

$$F_{fuse} = \text{Conv}(\text{Concat}(C_m, D_s)) + C_m \quad (4.4)$$

通过残差连接的方式，单目语义信息被显式地补充到了多视角几何特征中。实验表明，这一步特征融合显著提升了多视角分支在纹理缺失区域的精度。

融合后的特征 F_{fuse} 经过进一步的聚合处理后，采用与单目分支相同的软加权求和方式回归得到多视角深度 d_m ，并回归出多视角置信度 M_m 。

4.4 基于重投影一致性的自适应融合模块

AFNet 的核心在于如何自适应融合 d_s 和 d_m 。传统的融合方法往往采用简单的特征融合或基于静态置信度的融合，但在面对位姿噪声时，多视角分支的置信度 M_m 往往无法正确反映其误差，网络无法判别可靠性，极易对错误的匹配产生错误依赖。因此，本文需要一个独立于网络预测之外的客观指标来判别多视角几何分支的可靠性。本章提出了一种基于重投影一致性的自适应融合模块。该模块引入了第三类置信度——重投影置信度 M_w ，用于显式地检测几何约束是否成立。

4.4.1 重投影置信度 M_w 的生成机制

重投影置信度的核心思想是光度一致性假设：如果预测的深度 d_m 和输入的位姿 T 都是准确的，且场景是静态的，那么将源图像 $\{I_i\}$ 根据几何关系投影回参考视角后，合成的图像 I'_i 应当与原始参考图像 I_0 在纹理上高度一致。任何几何上的偏差（位姿噪声、深度错误、动态物体）都会导致光度误差的显著增加。具体的生成步骤是，首先通过逆向投影，利用多视角分支预测的深度 d_m 和相机位姿，将所有源图像 $\{I_i\}$ 采样变换到参考视角，得到重投影图像集 $\{I'_1, I'_2, \dots, I'_{N-1}\}$ 。然后将参考图像 I_0 与所有重投影图像 $\{I'_i\}$ 在通道维度进行拼接，形成输入张量。通过一个轻量级的卷积神经网络（包含 2D 卷积与激活函数）对该张量进行处理，直接回归出重投影置信度图 $M_w \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4}}$ ：

$$M_w = \text{Conv}(\text{Concat}(I_0, I'_1, I'_2, \dots, I'_{N-1})) \quad (4.5)$$

M_w 本质上是一个像素级的几何质量评估图，它能够敏锐地捕捉以下异常：

- 位姿噪声响应：当输入位姿存在误差时，全局或局部的极线约束被破坏，导致 I'_i 与 I_0 发生错位。卷积网络能够捕捉到这种错位产生的重影或纹理不连续，从而预测出较低的 M_w 。

- 动态物体响应：对于运动物体，静态场景假设失效，几何投影必然无法对齐。因此，在动态车辆或行人区域， M_w 会显著降低，提示系统不可信赖几何分支。
- 弱纹理区域响应：在无纹理区域，光度误差本身较小，此时 M_w 可能较高，这与多视角方法在弱纹理区失效的特性看似矛盾。但 AFNet 结合了 M_m （多视角匹配置信度），后者通过对多视角分支置信度输出进行监督，使得其在弱纹理区通常较低，二者结合可以全面评估可靠性。

4.4.2 自适应融合网络

最终的融合过程是一个基于三元置信度的非线性组合过程。本文将单目深度 d_s 、多视角深度 d_m 以及三张置信度图 M_s, M_m, M_w 同时输入到一个融合子网络中：

$$d_{fuse} = \mathcal{F}_{fuse}(d_s, d_m, M_s, M_m, M_w) \quad (4.6)$$

该融合子网络由两层 2D 卷积层组成。网络在训练过程中自动学习如何根据 M_s, M_m, M_w 动态调整 d_s 和 d_m 的权重。例如，当 M_w 较低（位姿噪声或动态物体）时，网络会倾向于输出 d_s ；当 M_w 和 M_m 都较高（理想观测条件）时，网络会倾向于输出高精度的 d_m 。这种机制赋予了 AFNet 强大的环境自适应能力。

4.4.3 损失函数设计

为了训练 AFNet，本文设计了一个包含深度监督和置信度监督的复合损失函数。

（1）深度回归损失

本文对单目分支、多视角分支以及融合后的输出同时施加 L_1 监督，以确保每个分支都能学习到正确的深度表示：

$$L_{depth} = \|d_s - d_{gt}\|_1 + \|d_m - d_{gt}\|_1 + \|d_{fuse} - d_{gt}\|_1 \quad (4.7)$$

其中 d_{gt} 为真值深度图。这种多层监督策略有助于梯度的有效反向传播，加速网络收敛。

（2）置信度监督损失

为了让预测的置信度 M_s 和 M_m 具有真实的物理意义（即反映预测的准确率），本文采用了一种显式的监督策略。本文期望置信度图能够拟合误差的逆，即误差越

小，置信度越趋近于 1。首先，根据相对误差阈值定义有效掩模 Ω_s 和 Ω_m ：

$$\Omega_k = \{p \mid |d_k(p) - d_{gt}(p)| < d_{gt}(p)\}, \quad k \in \{s, m\} \quad (4.8)$$

这用于剔除极其离谱的预测值，避免其干扰训练。然后，置信度损失定义为预测置信度与真实相对准确率之间的 L_1 距离：

$$L_{conf} = \sum_{k \in \{s, m\}} \frac{1}{|\Omega_k|} \sum_{p \in \Omega_k} \left| M_k(p) - \left(1 - \frac{|d_k(p) - d_{gt}(p)|}{d_{gt}(p)} \right) \right| \quad (4.9)$$

该损失函数强制网络学习去“预测自己的错误”。如果网络对某像素的深度预测很准（相对误差接近 0），则它必须输出接近 1 的置信度；反之则输出低置信度。这为自适应融合模块提供了可靠的判据。

（3）总损失函数

最终的训练损失为深度损失与置信度损失之和：

$$L_{total} = L_{depth} + \lambda L_{conf} \quad (4.10)$$

其中 λ 为平衡系数。

4.5 实验结果与分析

为了全面验证 AFNet 算法在应对位姿噪声、动态物体干扰及弱纹理区域等挑战时的有效性，本节在 DDAD^[178] 和 KITTI Eigen split^[177] 基准数据集上开展了系统的定量与定性实验。实验重心将围绕四个核心维度展开：首先，确立 AFNet 在标准测试条件下的精度基准，验证其是否达到当前最先进水平；其次，评估算法在非理想位姿输入（包括合成与真实噪声）下的鲁棒性，突显其相对于现有方法的优势；再次，深入剖析自适应融合模块与重投影置信度的内在机理，验证其引导作用的有效性；最后，考察模型在跨域场景下的泛化潜力。与此同时，本节还将对模型的计算效率及各组件的有效性进行详尽的消融分析。

本节的组织结构如下：4.5.1 节详细介绍所使用的数据集特性及评估指标；4.5.2 节阐述实验的具体实施细节、参数设置及训练策略；4.5.3 节在标准的 DDAD 和 KITTI 基准上与当前 SOTA 方法进行横向对比，并结合计算效率进行综合评估；4.5.4 节重点对算法在动态物体区域、合成位姿噪声环境以及真实 SLAM 位姿环境下的鲁

棒性进行深度剖析；4.5.5 节通过跨数据集测试评估模型的泛化能力；4.5.6 节通过详尽的消融实验验证各个模块的有效性；最后，4.5.7 节对本章实验进行总结。

4.5.1 数据集与评估指标

为了确保实验结果的可靠性与广泛性，本文选取了自动驾驶领域最具代表性的两个室外数据集，涵盖了从高速公路到复杂城区的多样化场景。

(1) DDAD 数据集

DDAD 是近年来推出的一个极具挑战性的自动驾驶稠密深度估计基准。该数据集由安装在自动驾驶车辆上的 6 个同步摄像头（覆盖 360° 视场）采集，包含了多样化的城市道路场景。DDAD 最大的特点是提供了由高密度长距离激光雷达生成的精确并且较为稠密的深度真值，能够更精准地评估算法在图像边缘、细微结构和远距离处的性能。DDAD 包含 12 650 个训练样本和 3 950 个验证样本，图像分辨率为 1936×1216 。在本章实验中，为了验证算法的全场景感知能力，本文使用所有 6 个摄像头（包括前视、后视及侧视）的图像进行训练和测试，深度评估范围设定为 0 到 200 米。

(2) KITTI 数据集

KITTI 是深度估计领域最经典的自驾场景数据集，提供了在行驶车辆上采集的图像序列及对应的稀疏 LiDAR 点云真值。图像分辨率约为 1241×376 。为了与现有方法进行公平对比，本文遵循标准的 Eigen split 划分方式，该划分包含 23 488 对训练图像和 697 对测试图像。深度评估范围遵循通用标准设定为 0 到 80 米。

(3) 评估指标

本文采用深度估计领域通用的评估指标来量化算法性能。对于预测深度 d_i 和真值深度 d_i^* ，具体的指标定义如下：

- 绝对相对误差 (AbsRel): $\frac{1}{N} \sum_i \frac{|d_i - d_i^*|}{d_i^*}$ ，反映预测值相对于真实值的平均偏差比例。
- 平方相对误差 (SqRel): $\frac{1}{N} \sum_i \frac{(d_i - d_i^*)^2}{d_i^{*2}}$ ，对大误差更加敏感。
- 均方根误差 (RMSE): $\sqrt{\frac{1}{N} \sum_i (d_i - d_i^*)^2}$ ，衡量误差的整体分布情况。
- 均方根对数误差 (RMSE log): $\sqrt{\frac{1}{N} \sum_i (\log d_i - \log d_i^*)^2}$ ，衡量对数空间下的误差分布。

- 阈值精度 ($\delta < 1.25^n$): 预测深度与真值比率的最大值 $\max(\frac{d_i}{d_i^*}, \frac{d_i^*}{d_i})$ 小于阈值的像素百分比, 其中 $n \in \{1, 2, 3\}$ 。该指标反映了算法在不同精度要求下的准确率分布。

此外, 为了综合评估模型在不同噪声水平下的抗干扰能力, 本文还引入了本章提出的鲁棒性相对误差 (R-Rel)。R-Rel 定义为模型在所有测试噪声等级 ($\delta = 0, 0.01, 0.025, 0.05$) 下的 AbsRel 平均值与标准差之和。该指标能够同时反映模型在理想条件下的精度上限以及在恶劣条件下的性能下限, 是衡量系统综合鲁棒性的关键依据。

4.5.2 主要实验设置

(1) 软硬件环境与优化策略

AFNet 基于 PyTorch 深度学习框架实现, 所有实验均在搭载 NVIDIA RTX 3090 GPU 的高性能工作站上完成。网络训练采用 AdamW^[168] 优化器, 通过 One-Cycle 学习率调整策略进行优化, 最大初始学习率设为 1.0×10^{-4} 。在 DDAD^[178] 数据集上, 由于数据量较大且场景复杂, 本文训练 30 个 Epoch; 在 KITTI^[177] 数据集上, 本文训练 40 个 Epoch。为了防止梯度爆炸, 本文将梯度裁剪范围设为 $[-1.0, 1.0]$ 。

(2) 多视角设置与代价体构建

在训练和推理阶段, AFNet 均接受 N 帧图像作为输入, 即包含 1 张参考图像和 $N - 1$ 张源图像。对于多视角分支的平面扫描步骤, 本文在深度范围内均匀采样 128 个深度假设平面来构建代价体。为了平衡计算效率与性能, 本文保留了特征通道维度构建 4D 代价体, 并通过两层 3D 卷积将通道数压缩为 1, 随后进行正则化。这种设计既保留了丰富的特征匹配信息, 又避免了过大的显存开销。

(3) 图像预处理

为了增强模型的泛化能力并防止过拟合, 训练阶段输入图像在送入网络前进行了标准的数据增强操作, 包括随机色彩抖动、随机裁剪和水平翻转。对于 KITTI 数据集, 输入图像被调整至 1216×352 ; 对于 DDAD 数据集, 图像被下采样至 640×384 进行处理。

表 4.1 基准数据集 DDAD 和 KITTI 的定量结果。* 标记使用开源代码复现的结果，其他数字来自原始论文。

算法类型	方法	DDAD ^[178]			KITTI ^[177]		
		AbsRel↓	SqRel↓	RMSE↓	AbsRel↓	SqRel↓	RMSE↓
单视角	Monodepth2 ^[178]	0.194*	3.52*	13.32*	0.106	0.806	4.630
	FeatDepth ^[180]	0.189*	3.21*	12.45*	0.099	0.697	4.427
	DORN ^[20]	-	-	-	0.088	0.806	3.138
	BTS ^[181]	0.169*	2.81*	11.85*	0.059	0.245	2.756
	AdaBins ^[21]	0.164*	2.66*	11.08*	0.058	0.190	2.360
	Metric3D ^[24]	0.183*	2.92*	12.15*	0.053	0.174	2.243
多视角	PMNet ^[182]	0.141*	2.23*	10.56*	-	-	-
	Deepv2d ^[183]	-	-	-	0.091	0.582	3.644
	CasMVS ^[14]	0.129*	2.01*	9.87*	0.066*	0.228*	2.567*
	MVSNet ^[11]	0.109*	1.62*	8.21*	-	-	-
	IterMVS ^[103]	0.104*	1.59*	7.95*	0.057*	0.178*	2.234*
	MVS2D ^[15]	0.132*	2.05*	9.82*	0.058*	0.176*	2.277*
	SC-GAN ^[184]	-	-	-	0.063	0.178	2.129
	MaGNet ^[138]	0.112*	1.74*	9.23*	0.054	0.162	2.158
	AFNet	0.088	1.41	7.23	0.039	0.121	1.743

4.5.3 基准数据集上的实验结果

为了验证 AFNet 的综合性能，本文将其与当前最先进的单目深度估计方法（如 Monodepth2^[178], DORN^[20], AdaBins^[21], Metric3D^[24]）以及多视角深度估计方法（如 MVSNet^[11], CasMVS^[14], IterMVS^[103], MVS2D^[15], MaGNet^[138]）进行了全方位的对比。定量对比结果如表格 4.1 所示。AFNet 在两个数据集的各项核心指标上均取得了显著的领先优势，全面超越了现有的单目、多视角以及融合类方法，达到了新的 SOTA 水平。

（1）DDAD 数据集上的深度评估与分析

DDAD 数据集包含复杂的城市道路场景和覆盖 360° 的环视影像，且提供了高精度的 LiDAR 真值，是检验自驾场景算法综合性能的试金石。但由于许多经典方法（如 MVSNet^[11], IterMVS^[103], MVS2D^[15] 等）未在 DDAD 上发布官方结果，为了确保对比的公平性，本文基于其开源代码，采用了完全一致的训练策略（包括优化器、

学习率调度及训练周期)进行了训练和测试,确保所有模型均达到收敛状态。

相较于 SOTA 融合方法,AFNet 具有显著优势,如表格 4.1 所示 AFNet 的 AbsRel 误差仅为 0.088,相比于此前最先进的融合方法 MaGNet^[138] (0.112) 和 MVS2D^[15] (0.132),AFNet 分别实现了 21.4% 和 33.3% 的性能提升。这一结果有力地证明了,简单的特征拼接或基于注意力机制的隐式融合并不足以充分利用双分支的互补性。相反,AFNet 通过提出的特征融合以及自适应融合模块充分结合单目深度估计的优势,并且引入显式的重投影置信度作为引导融合依据,能够自适应地摒弃多视角分支中的错误匹配信息,提升多视角深度估计鲁棒性。

相较于纯多视角方法,AFNet 也实现了全面超越。相比于经典的迭代式多视角方法 IterMVS^[103] (AbsRel 0.104) 和基础方法 MVSNet^[11] (AbsRel 0.109),AFNet 在精度上具有明显优势。多视角方法虽然具备几何测量能力,但在面对 DDAD 中频繁出现的动态车辆、行人以及路面等弱纹理区域时,极易因极线约束失效导致深度估计精度差。AFNet 通过在这些区域自适应地融合单目分支深度,有效填补了纯几何方法的性能短板。从 SqRel 指标来看,AFNet (1.41) 相比 IterMVS (1.59) 降低了 11.3%,进一步佐证了其在抑制大误差(如匹配飞点)方面的鲁棒性。

尽管最新的单目深度估计方法(如 Metric3D^[24], AdaBins^[21]) 在特征提取和深度分布建模上取得了巨大进展,但其 AbsRel 误差(Metric3D 为 0.183) 仍显著高于 AFNet。这揭示了纯单目方法在缺乏几何约束时面临的固有尺度模糊问题。AFNet 通过引入多视角几何分支,成功恢复了具有物理意义的绝对度量深度,同时保留了单目方法对语义场景的理解能力。




图 4.2 DDAD 测试集定性结果。黑色椭圆突出了本文的方法所取得的明显改进。

为了更直观地验证算法在复杂真实场景下的感知能力,图 4.2 展示了 AFNet 与

代表性的多视角方法 IterMVS^[103] 在 DDAD 测试集上的定性对比结果。可视化结果表明，在多视角几何约束容易失效的挑战性区域，AFNet 展现出了显著的鲁棒性优势：

针对动态物体区域，如图中第三列所示，对于行驶中的车辆，由于违反了静态刚体假设，IterMVS^[103] 在物体边缘和内部出现了严重的深度空洞与伪影（如黑色椭圆标记所示）。相比之下，AFNet 凭借自适应融合模块，能够识别出几何不一致区域并切换至单目分支，从而准确恢复出运动车辆的完整几何轮廓，深度预测更加精准可靠。针对细微结构，如图所示，在面对交通信号灯杆、树木枝叶等细微结构时，多视角立体视觉方法往往因匹配代价发散而产生模糊现象。AFNet 则通过融合单目深度，成功保留了这些细小物体的高频细节，生成了边缘锐利、层次分明的深度图。

这些定性结果与前文的定量数据高度一致，有力地证明了 AFNet 在真实场景下性能的优越性。

（2）KITTI 数据集性能评估

KITTI Eigen split 是深度估计领域最为经典的基准。尽管该榜单的性能指标已趋于饱和，AFNet 依然取得了突破性的进展。

如表格 4.1 所示，AFNet 取得了 0.039 的 AbsRel 误差，大幅度超越之前最好的方法。与同样采用融合策略的 MaGNet^[138] (0.054) 和 MVS2D^[15] (0.058) 相比，AFNet 将绝对相对误差大幅降低了 27.8% 和 32.8%。这一改进幅度在 KITTI 这样一个高度成熟的基准上是极具分量的。此外，在 RMSE 和 SqRel 等指标上，AFNet 也保持了全面领先（例如 RMSE 从 MaGNet 的 2.158 降至 1.743）。这表明，无论是在复杂的城市动态场景（DDAD）还是在相对开阔的道路场景（KITTI），AFNet 的自适应融合机制都能保持极高的普适性和稳定性，能够在复杂开放场景下提供高精度、可靠性高的深度感知。

4.5.4 鲁棒性与抗噪能力深度分析

本章的核心研究动机是解决现有方法在非理想观测条件下的脆弱性。因此，本节将重点分析 AFNet 在动态物体区域、合成位姿噪声以及真实 SLAM 位姿噪声下的表现。

（1）动态物体区域的性能表现

动态物体（如行驶的车辆、行人）违反了多视角几何的静态刚体假设，是 MVS

方法的主要挑战之一。AFNet 的自适应融合模块能够通过重投影一致性识别出这些区域并融合单目分支深度。为了精准评估算法在动态场景下的表现，本文制定了一套严谨的动态物体区域掩模生成策略。具体而言，本文首先利用实例分割网络提取潜在动态类别（如汽车、行人、自行车等）的初始掩模。随后，利用光流一致性原理进行时序校验：将前一帧 I_{t-1} 和后一帧 I_{t+1} 的掩模区域投影至当前帧 I_t ，并计算结构相似性评分（Structure Similarity Index Measure, SSIM）。本文将 SSIM 评分低于 0.7 的区域判定为存在显著运动的动态物体区域。基于这一掩模划分的动态物体区域的评测结果更能真实反映算法克服动态干扰的能力。

表 4.2 DDAD 上动态物体区域的性能比较。AFNet (d_m) 表示多视角立体视觉分支，AFNet (d_{fuse}) 表示最终融合结果。**加粗**代表最好的结果。

方法	AbsRel↓	SqRel↓	RMSE↓
MVS2D ^[15]	0.163	2.362	7.325
MaGNet ^[138]	0.169	2.500	7.783
AFNet(d_m)	0.158	1.879	6.024
AFNet(d_{fuse})	0.145	1.484	5.675

为了验证这一点，本文专门评估了 DDAD 数据集中动态物体区域的深度误差。如表格 4.2 所示，AFNet 的最终融合结果 $AFNet(d_{fuse})$ 在动态区域的 SqRel 误差为 1.484，相比于仅使用多视角分支 $AFNet(d_m)$ 的结果（1.879），误差降低了 21.0%。这直接证明了自适应融合模块成功地引入了单目分支在动态区域的鲁棒性预测。相比于同样融合了单目和多视角的 MVS2D^[15]（SqRel = 2.362）和 MaGNet^[138]（SqRel = 2.500），AFNet 在动态区域的表现有显著优势。这是因为 MVS2D 和 MaGNet 缺乏显式的判别机制，容易受到多视角分支错误几何信息的干扰。

为了进一步从直观上验证算法在动态场景下的几何重建能力，图 4.3 展示了 AFNet 在 DDAD 场景中的稠密点云重建效果。通过融合连续 10 帧的深度预测结果，本文可以观察到：即便是对于正在行驶的车辆（图中红框及放大区域所示），AFNet 依然能够重建出结构完整、边缘清晰的三维点云。这得益于自适应融合模块在动态区域充分结合单目分支的优势，有效避免了传统多视角方法因违反静态刚体假设而产生的拖影或空洞现象。这种高质量的定性重建结果与表格 4.2 中的定量误差指标高度吻合，充分证明了 AFNet 在处理高动态场景时的可靠性与优越性。



图 4.3 DDAD 数据集场景点云可视化。本文融合了 10 帧的结果（包括动态物体汽车），并放大了一些细节以实现可视化。结果表明，该方法在静态和动态物体上均能获得高质量的结果。

（2）合成噪声位姿下的鲁棒性评估

为了系统地量化抗噪能力，本文构建了一个包含不同等级合成位姿噪声的测试基准。本文对输入的相对位姿（欧拉角和平移向量）施加不同强度的扰动系数 δ ($\delta = 0, 0.01, 0.025, 0.05$) 以及直接将多帧之间的相对位姿置为单位矩阵，用以模拟自动驾驶场景中常见的多视角之间时序静止状态（车辆静止）。实验结果如表格 4.3 所示，随着噪声强度 δ 的增加，传统多视角方法（如 MVSNet^[11], CasMVS^[14], IterMVS^[103]）的性能急剧下降。例如，IterMVS 的 AbsRel 误差从 $\delta = 0$ 时的 0.107 飙升至 $\delta = 0.05$ 时的 0.187，衰减幅度巨大。这证实了纯几何方法对位姿精度的极端依赖。相比之下，AFNet 展现出了极佳的稳定性。即使在最大噪声 $\delta = 0.05$ 下，AFNet 的 AbsRel 误差仅为 0.164，而主流的多视角方案 CasMVS^[14] 和 MVSNet^[11] 在同等噪声强度下性能衰退，甚至远低于单目深度估计的精度。这表明在几何约束严重失效时，相比主流的多视角几何算法的剧烈衰退，AFNet 成功切换为单目深度估计，守住了鲁棒性底线。

本文提出的鲁棒性感知误差指标（R-Rel）能够综合评估 MVS 算法在不同位姿噪声强度下的综合性能，如表格 4.3 所示，AFNet（0.168）显著优于 MaGNet^[138]（0.195）和 IterMVS^[103]（0.189），证明了其相比其他单目、多视角融合方案具有更强

表 4.3 DDAD 数据集上噪声姿态下的性能比较。表格中的数据表示 AbsRel 误差指标。 δ 表示噪声强度。“ID”代表将单位矩阵作为相对位姿输入。R-Rel 是本文定义的鲁棒感知相对误差，衡量在不同噪声位姿下的综合表现。**加粗**表示最优结果。

方法	$\delta = 0$	$\delta = 0.01$	$\delta = 0.025$	$\delta = 0.05$	ID	R-Rel
PMNet ^[182]	0.144	0.235	0.354	0.382	0.246	0.359
CasMVS ^[14]	0.131	0.165	0.195	0.215	0.181	0.206
MVSNet ^[11]	0.112	0.160	0.189	0.208	0.177	0.202
MVS2D ^[15]	0.133	0.159	0.179	0.184	0.173	0.184
IterMVS ^[103]	0.107	0.154	0.178	0.187	0.175	0.189
MaGNet ^[138]	0.115	0.162	0.185	0.191	0.183	0.195
AFNet(d_m)	0.095	0.137	0.163	0.175	0.170	0.178
AFNet	0.092	0.125	0.155	0.164	0.165	0.168

的综合可靠性。

为了更直观地展示算法在恶劣工况下的稳定性，图 4.4 提供了 AFNet 与 IterMVS 在不同合成噪声强度 δ 下的深度预测可视化对比。从图中可以清晰地观察到性能演变的显著差异。对于主要依赖多视角几何匹配的 IterMVS^[103]，随着位姿噪声从 $\delta = 0$ 逐渐增加至 0.05，其深度图质量出现了显著衰退。在 $\delta = 0.05$ 的高噪声水平下，几何约束被严重破坏，导致深度图中出现了大面积的错误估计（如黑色方框区域所示），场景结构几乎无法辨认。相比之下，AFNet 展现出了很高的鲁棒性，无论噪声强度如何增加，AFNet 生成的深度图始终保持结构清晰、边缘锐利，且未出现明显的伪影。这是因为自适应融合模块敏锐地感知到了几何置信度的下降，并自适应融合了对位姿不敏感的单目分支深度。这种位姿噪声强度下的稳定性，充分证明了 AFNet 更加适合作为开放场景下的安全冗余算法，提供更强的可靠性。

（3）真实 SLAM 位姿下的鲁棒性评估

为了模拟真实的自动驾驶场景，本文在 KITTI Odometry^[177] 数据集上使用 ORB-SLAM2^[150] 生成的位姿进行测试。本文分别使用了单目版 ORB-SLAM2（ORB-Mono，噪声较大）和双目版 ORB-SLAM2（ORB-Stereo，噪声较小）生成的位姿，作为 MVS 算法的相机位姿输入。结果如表格 4.4 所示，在 ORB-Mono 生成的高噪声位姿下（序列 04，绝对轨迹误差为 0.98 米），AFNet 的 AbsRel 误差为 0.064，而对比方法 IterMVS^[103] 的误差高达 0.182。这表明 AFNet 更能适应实际 SLAM 系统产生的漂移和误差。并且，无论是在高精度的真值位姿下，还是在不同质量的 SLAM 位姿下，




图 4.4 DDAD 数据集可视化比较结果。黑框中显著突出了 AFNet 的鲁棒性。随着姿态噪声的逐渐增大，以多视角匹配为主的算法的精度急剧下降，但 AFNet 保持稳定。

表 4.4 在 KITTI 数据集上位姿真值和 SLAM 位姿下的性能比较。本文比较使用位姿真值，ORB-SLAM2 双目模式和 ORB-SLAM2 单目模式下的位姿作为 MVS 算法的位姿输入。ATE 表示位姿的绝对轨迹误差。报告的指标是 AbsRel 误差。

方法	04 序列			05 序列		
	GT	ORB-Stereo	ORB-Mono	GT	ORB-Stereo	ORB-Mono
		(ATE=0.15)	(ATE=0.98)		(ATE=0.40)	(ATE=5.60)
MoRec ^[185]	0.075	0.088	0.345	0.068	0.085	0.381
IterMVS ^[103]	0.068	0.078	0.182	0.073	0.080	0.169
MaGNet ^[138]	0.066	0.071	0.077	0.069	0.077	0.082
AFNet	0.059	0.061	0.064	0.063	0.066	0.070

AFNet 均保持了最低的误差，证明了其在实际工程部署中的潜力以及可靠性。

4.5.5 零样本泛化能力评估

为了评估模型的泛化性，本文将仅在 DDAD 上训练的 AFNet 模型直接在未见过的室内数据集 ScanNet^[186] 上进行测试。ScanNet^[186] 与 DDAD^[178] 在场景结构（分别为室内和室外）、光照条件和纹理分布上均存在巨大差异，且位姿分布区别显著，这对模型的适应能力提出了严峻挑战。

表 4.5 ScanNet 数据集上的零样本泛化性能比较。模型在 DDAD 上进行训练，并直接在 ScanNet 上进行测试。**加粗**表示最优结果。

方法	AbsRel↓	SqRel↓	RMSE↓
IterMVS ^[103]	0.123	0.056	0.332
MVS2D ^[15]	0.098	0.044	0.276
MaGNet ^[138]	0.112	0.051	0.314
AFNet	0.091	0.039	0.253

如表格 4.5 所示，AFNet 在 ScanNet^[186] 上取得了 0.091 的 AbsRel 误差。相比之下，MaGNet^[138] 的误差为 0.112，IterMVS^[103] 的误差为 0.123。这一结果表明，AFNet 不仅在同分布数据上表现优异，其学到的自适应融合策略也具有良好的跨域迁移能力。具体而言，AFNet 能够有效地在多视角几何信息和单目深度之间进行动态切换，从而不过度依赖于特定的训练数据分布，展现出了作为通用深度估计框架的潜力。

4.5.6 消融实验与模型分析

为了深入探究 AFNet 各个设计模块的贡献，本文在 DDAD 数据集上进行了详尽的消融实验。实验主要围绕融合策略、特征融合以及置信度模块展开。

表 4.6 各策略在 DDAD 上的消融实验，报告的指标为 SqRel 误差。**加粗**代表最优结果。

方法	结果融合策略	特征融合	单目分支	多视角分支	融合结果
Base	-	-	-	1.90	-
Base-RF	卷积融合	-	2.68	1.78	1.99
Base-FF	卷积融合	✓	2.66	1.59	1.79
Base-AF	自适应融合	✓	2.66	1.59	1.55

(1) 融合策略

本文构建了几个变体模型来验证自适应融合的必要性，如表格 4.6 所示：

- **Base**: 仅包含多视角分支的基准模型。其 SqRel 误差为 1.90。
- **Base-RF**: 简单的卷积结果融合。虽然引入了单目分支，但由于缺乏自适应选择机制，简单的融合反而引入了单目的尺度噪声，导致性能下降（SqRel 误差上升至 1.99），这说明简单的深度融合并不奏效。

- **Base-AF**: 引入本文提出的自适应融合模块。SqRel 误差从 1.79 显著降低至 1.55。这证明了基于置信度的选择机制是融合成功的关键，它避免了简单融合带来的负效应，实现了充分的优势互补。

(2) 特征级融合

本文验证了将单目语义特征注入多视角代价体的重要性。对比 Base-RF (1.99) 和 Base-FF (1.79)，特征级融合带来了约 10% 的性能提升。这说明单目语义特征有效地辅助了多视角分支在弱纹理区域的匹配，提高了多视角分支本身的深度质量，为后续的结果级融合提供了更好的基础。

表 4.7 置信度机制的消融实验。Base-FF 是该消融实验的基线模型，没有任何置信度相关操作。“监督”表示对 M_m 和 M_s 置信度使用置信度 loss 进行监督约束。

方法	M_m 置信度	M_s 置信度	监督	M_w 置信度	融合结果
Base-FF	-	-	-	-	1.79
Base-m	✓	-	-	-	1.76
Base-ms	✓	✓	-	-	1.72
Base-ms-S	✓	✓	✓	-	1.67
Base-AF	✓	✓	✓	✓	1.55

(3) 置信度机制

AFNet 的核心在于三个置信度图：单目置信度 M_s 、多视角置信度 M_m 和重投影置信度 M_w 。本文详细分析了它们的作用，如表格 4.7 所示：

- 重投影置信度 M_w ：如果在融合时移除重投影置信度 M_w ，模型误差从 1.55 上升至 1.67。这直接证明了 M_w 其作为几何一致性判别的关键作用。没有它，网络无法敏锐地感知由位姿噪声或动态物体引起的光度不一致，从而无法正确地在单目和多视角分支间进行切换。
- 置信度监督：如果不对单目深度估计分支 M_s 和多视角深度估计分支 M_m 的置信度分别施加监督，误差也会从 1.55 上升至 1.72。这说明强制网络学习预测各分支的不确定性有助于整体的融合模块做出更准确的决策。

(4) 特征提取与其他关键策略

为了确定最优的网络架构，本文以集成了自适应融合模块的 Base-AF 模型作为基准（记为 BASE），进一步验证了以下两种关键设计策略的有效性，如表格 4.8 所

表 4.8 特征提取与其他关键策略的消融。“BASE-PS”表示参数共享。“BASE-PS-cost”代表使用几何代价体作为匹配代价度量。报告的指标是 SqRel 误差。

方法	Single	Multi	Fuse
BASE	2.66	1.59	1.55
BASE-PS	2.62	1.53	1.49
AFNet (BASE-PS-cost)	2.62	1.44	1.41

表 4.9 位姿校正模块的消融结果。评估基于 DDAD 上的 AbsRel 误差。“AFNet-Pose”表示增加位姿校正模块的模型。

方法	$\delta = 0$	$\delta = 0.01$	$\delta = 0.025$	$\delta = 0.05$	ID	R-Rel
AFNet	0.092	0.125	0.155	0.164	0.165	0.168
AFNet-Pose	0.093	0.123	0.142	0.154	0.164	0.160

示：

- 特征提取网络的参数共享：本文首先探索了让单目分支和多视角分支共享同一个特征提取骨干网络（记为 BASE-PS）。实验数据显示，这一策略不仅大幅减少了模型的参数冗余，还带来了性能的提升，其 SqRel 误差从基准的 1.55 降低至 1.49。这表明共享骨干网络有助于促进两个分支在底层特征空间的隐式对齐，从而使得后续的特征融合更加高效。
- 多视角几何信息构建机制：本文进一步对比了不同的多视角几何信息构建方式。本文将 MVS2D^[15] 中使用的极线注意力模块替换为本章所述的几何代价体结构，以更显式地提取匹配信息（记为 BASE-PS-cost）。实验结果表明，相比于基准模型 BASE，采用代价体构建的最终模型（即 AFNet）实现了 9.0% 的显著性能提升（SqRel 误差进一步降至 1.41）。这充分证明了相比于隐式的注意力机制，显式的几何代价体能够提供更鲁棒、更精准的匹配线索，从而提升了整个系统的深度估计上限。

（5）位姿校正模块

考虑到多视角分支的精度上限受限于位姿质量，本文进一步探索了一种位姿校正模块（AFNet-Pose）以应对极端位姿噪声。该模块利用 PoseNet^[153] 从特征图中预测相对位姿 $[R_{pred}|t_{pred}]$ ，并利用单目深度（因其独立于位姿）作为几何依据，通过

计算重投影后的 SSIM 相似分数，在输入位姿与预测位姿之间进行动态选择。

消融实验如表格 4.9 所示，在合成噪声 $\delta = 0.025$ 的中等噪声水平下，引入位姿校正模块能将 AbsRel 误差进一步降低 8.4%（从 0.155 降至 0.142）。这一结果揭示了 AFNet 框架具有良好的扩展性，能够通过集成位姿估计器形成进一步的性能提升。

（6）计算效率与参数量分析

表 4.10 KITTI Eigen split 基准数据集的比较。推理时长是控制在相同分辨率下，同一台 Nvidia RTX 3090 上测量得到的。

方法	骨干网络	AbsRel↓	SqRel↓	RMSE↓	参数 (M)	推理时长 (ms)
MVS2D ^[15]	EfficientNetB5 ^[187]	0.058	0.176	2.277	24.4	28
DynamicDepth ^[188]	EfficientNetB5 ^[187]	0.044	0.139	2.082	36.9	142
MaGNet ^[138]	EfficientNetB5 ^[187]	0.054	0.162	2.158	76.4	87
AFNet	EfficientNetB5 ^[187]	0.042	0.128	1.833	56.7	56
AFNet	MobileNetV2 ^[189]	0.040	0.124	1.751	13.9	41
AFNet	ConvNeXt ^[179]	0.039	0.121	1.743	46.1	54

除了精度之外，计算效率也是自动驾驶系统关注的重点。为了公平比较，本文还进行了和 SOTA 方案在相同骨干网络（EfficientNetB5^[187]）配置下的参数量与运行时间对比实验。如表格 4.10 所示，在使用相同骨干网络的情况下，AFNet 的参数量为 56.7M，运行时间为 56ms。相比之下，MaGNet 的参数量高达 76.4M，运行时间为 87ms。DynamicDepth^[188] 方法虽然参数量较小（36.9M），但其运行时间长达 142ms。AFNet 在保持更高精度的同时，参数量比 MaGNet^[138] 减少了 25.8%，推理速度提升了 35.6%。这主要得益于本文共享骨干网络的设计以及轻量化的融合模块，避免了冗余的特征提取计算。当使用更轻量的 MobileNet V2^[189] 作为骨干时，AFNet 依然能保持极高的精度（AbsRel 为 0.040），且参数量仅为 13.9M，推理时间进一步缩短至 41ms。这证明了 AFNet 架构的高效性，使其更适合部署在资源受限的移动端计算平台上，满足实时性需求。

4.6 本章小结

本章针对复杂开放场景中非理想观测条件下，多视角深度估计鲁棒性差且极易在动态及弱纹理区域失效的痛点，提出了一种基于重投影一致性的自适应抗噪融合框架（AFNet）。现有纯多视角方法在面临位姿噪声时往往性能崩塌，而传统的融合

策略因缺乏智能判别机制，难以在噪声干扰下真正发挥单目与多视角的互补优势。为此，AFNet 构建了单目与多视角异构深度估计双分支，并创新性地设计了自适应融合模块。该模块引入显式的重投影置信度作为几何一致性判别，能够在像素级敏锐感知由位姿噪声或动态物体引发的几何约束失效，并动态调整两分支的信任权重。该机制使得系统在几何条件良好时能够输出高精度的度量深度，而在几何失效时平滑退化为单目深度预测，从而实现了深度感知的鲁棒性兜底。

广泛的实验充分验证了所提框架的先进性。本章不仅在 DDAD^[178] 和 KITTI^[177] 标准基准上取得了当前最优精度，更针对抗噪声性评估的空白，构建了包含多级合成噪声与真实 SLAM 系统噪声的鲁棒性评测基准。实验表明，AFNet 在应对剧烈位姿抖动及动态场景时展现出远超现有方法的稳定性；此外，优异的零样本跨域泛化表现进一步证实了其可靠性。综上所述，本章有效突破了非理想观测下多视角深度估计的鲁棒性瓶颈，为构建复杂开放场景下的高可靠视觉感知系统提供了坚实的技术支撑

5 深度先验赋能的视觉里程计

5.1 引言

在前序章节的研究中，本文致力于攻克立体视觉深度估计在复杂开放场景下的核心瓶颈。从基于区域分治的特征增强（CoAtRSNet）以应对视觉退化，到利用单目-双目迭代互优化机制（MonSter）解决跨域泛化难题，再到构建自适应抗噪框架（AFNet）以突破非理想观测的限制，本文逐步建立了一套能够在复杂、动态及未知环境下获取高精度、高鲁棒性深度信息的感知体系。然而，深度信息的获取并非终点，而是智能系统实现自主行为的起点。作为三维空间的基础几何表征，高质量的深度图不应止步于场景重建，更应成为动态状态估计的强力支撑。在自动驾驶、机器人以及无人机等系统中，感知与定位耦合紧密。精准的感知依赖于准确的位姿，而鲁棒的位姿估计又极度依赖于对环境几何的正确理解。

因此，本章将研究视角从上游的静态深度感知拓展至下游的动态位姿估计，聚焦于计算机视觉领域的另一核心问题——视觉里程计。本文将探讨如何将前序章节积累的高质量深度先验转化为对单目 VO 系统尺度模糊与累积漂移的有效约束，实现从鲁棒感知向精准定位的技术跨越。

视觉里程计旨在通过解析连续的图像序列，恢复相机在三维空间中的六自由度运动轨迹。作为一种被动式、低功耗且富含语义信息的定位手段，VO 已成为自动驾驶、无人机、增强现实及移动机器人实现自主导航的关键支撑技术。相较于依赖卫星信号的定位系统，VO 能够在隧道、室内或城市峡谷等卫星信号拒止环境下提供连续可靠的状态估计；相较于激光雷达里程计，VO 则凭借显著的成本优势与紧凑的体积优势，更具备大规模商业化部署的潜力。

在各类 VO 方案中，单目视觉里程计因其极致简化的硬件配置（仅需单目摄像头）和极低的标定维护成本而备受学术界与工业界关注。然而，这种极简的传感器配置也带来了根本性的挑战：由于缺乏物理基线或绝对尺度参考，单目 VO 本质上存在尺度模糊与尺度漂移问题。即系统无法获知真实世界的物理尺寸，且随着时间推移，这种尺度误差会不断累积，导致轨迹严重偏离真实路径。这一缺陷长期制约了单目 VO 在智能驾驶、机器人导航等对绝对尺度精度有严格要求的任务中的直接应

用。为了阐明本章所提方法（RoMeO）的设计初衷，本节将深入剖析视觉里程计领域的主流范式，特别是各类算法在解决尺度恢复与跨场景泛化方面存在的共性瓶颈。

（1）传统单目视觉里程计的鲁棒性与尺度瓶颈

以 ORB-SLAM^[40] 和 DSO^[39] 为代表的经典几何范式，建立在严谨的多视图几何理论（如对极约束、PnP 求解及光束法平差）之上。尽管此类方法具备计算高效与理论完备的优势，但在实际应用中仍受制于两大核心缺陷：1）手工特征的脆弱性：无论是基于描述子的特征点法，还是基于光度一致性的直接法，其前端追踪均高度依赖于环境纹理的质量。在弱纹理、重复纹理或由快速运动引发的运动模糊场景下，有效的底层视觉线索（特征点或高梯度像素）极难提取与匹配，从而导致系统约束不足甚至发生跟踪丢失；2）单目尺度的不可观测性与漂移：单目视觉里程计本质上是一个尺度不适定问题。根据透视投影模型，任意非零尺度因子 λ 作用下的场景深度 λd 与相机平移 λt 会产生完全一致的图像投影，导致绝对物理尺度在纯视觉观测中不可解。尽管系统可依赖初始化阶段的先验假设运行，但在缺乏回环检测或惯性测量单元等外部绝对约束时，状态估计中的尺度误差将随时间单调累积。这种尺度漂移现象会导致估计的轨迹在空间中发生形变，使得单目 VO 难以满足长距离导航的高精度要求。

（2）端到端学习型视觉里程计的泛化困境

为突破传统方法对底层视觉特征的依赖，学术界探索了以 DeepVO^[147] 和 TartanVO^[151] 为代表的端到端学习型范式。此类方法利用卷积神经网络或循环神经网络构建从图像序列到相机位姿的直接映射，将视觉里程计简化为数据驱动的监督回归任务。然而，这种策略摒弃了显式的几何建模与物理约束，导致网络极易对训练集特定的运动模式或场景纹理产生过拟合。例如，在无人机视角的 TartanAir 数据集上训练的模型，因存在显著的域差异，通常难以直接迁移至车载视角的 KITTI 数据集。此外，端到端模型的“黑盒”特性使其难以保证长时序的轨迹几何一致性，且在预测失效时缺乏可解释的调试手段，难以满足自动驾驶等安全攸关应用对系统可靠性的严苛要求。

（3）混合式视觉里程计的不足

近期，以 DROID-SLAM^[154] 为代表的结合深度学习和传统方法的混合式架构成为了新的 SOTA。DROID-SLAM 结合了深度学习的稠密光流估计和传统的后端优化，利用 GRU^[78] 迭代更新光流用作多帧之间的匹配，展现出了极强的鲁棒性。然

而，即便如此强大的基准模型，在实际应用中仍存在明显缺陷。首先是绝对尺度的缺失，DROID-SLAM 内部维护的是逆深度，且该深度是相对于第一帧的相对值。这意味着它输出的轨迹仍然是尺度不确定的，无法直接输出绝对尺度位姿。其次是室外场景的零样本泛化差，本文的实验发现，仅在合成数据（TartanAir）上训练的 DROID-SLAM，直接迁移到室外真实场景（如 KITTI^[177], DDAD^[178]）时，性能会出现剧烈下降。这是因为室外场景的景深范围极大，导致简单的固定深度初始化策略出现极大偏差，进而影响位姿优化，定位精度大幅降低。

面对上述挑战，本章的研究动机源于一个关键的观察：随着基础模型的发展，单目深度估计已经取得了质的飞跃。在前几章中，本文验证了如 Depth Anything^[129]、Metric3D^[24] 等在海量数据上预训练的单目模型，具备了惊人的零样本泛化能力。既然本文已经能够从单张图像中获取相对可靠的深度先验，是否可以直接将其和 VO 系统进行结合用以解决尺度问题？遗憾的是，答案是否定的。正如本文在第三章中所分析的，即便是单目绝对深度估计领域的最新模型（如 Metric3D V2^[128]），在跨域迁移时依然存在严重的尺度模糊和偏移问题。这种深度如果直接简单地用于约束 VO，不仅无法提供正确的尺度，反而会引入严重的噪声，导致负优化。

因此，本文需要一种机制，既能利用单目绝对深度模型的大致尺度感知能力，又要适应其必然存在的尺度偏移问题。这自然引导本文引入多视角立体几何作为中间桥梁。本章的核心动机在于构建一个“单目先验 → 位姿初始化 → MVS 几何校正 → 深度/位姿联合优化”的正向循环框架。

（1）单目先验的局限与 MVS 的必要性

单目深度先验提供了极佳的稠密结构和相对几何关系，能够很好地处理弱纹理和动态区域，但其绝对数值是不准的。相比之下，MVS 遵循严格的几何投影约束。虽然 MVS 依赖于位姿，但它对场景的几何一致性极其敏感。如果本文能利用光束法平差（Bundle Adjustment, BA）优化得到的位姿作为输入然后通过 MVS 来更新深度，就能得到几何一致性更高的深度。

（2）构建深度-位姿的迭代优化框架

本章的核心思想是在于通过迭代光流作为中间桥梁，构建一个深度——位姿联合优化的正向循环框架。首先是先验引导初始化，利用含噪声的单目绝对深度先验，为 VO 提供一个具有大致物理尺度的初始化猜测。这避免了 VO 在纯相对空间中进行优化，解决了尺度不可观的问题。然后通过几何约束修正先验。当系统将初始单目

绝对深度作为先验，经过几轮 BA 优化后获取了一个相对准确的位姿。这个位姿是和单目深度在一个尺度下的，这时就可以通过时序多帧之间的多视角几何约束（即 MVS 约束）来修正单目先验中的偏移误差，进一步提高深度精度。修正后的 MVS 深度精度更高，将其通过重投影可以获得初始光流，然后通过一个基于 GRU 迭代的光流网络进一步更新光流。当获得了一个更准的匹配关系（光流）之后，就可以用于光束法平差构建能量函数，来对位姿进行进一步的非线性优化求解；而更准的位姿又反过来促进 MVS 对深度的进一步精细化，循环往复，这样就形成了一个完整的正向循环优化空间。

基于上述思考，本章提出了一种名为 RoMeO 的单目视觉里程计框架。该框架旨在通过深度融合单目深度先验与多视角几何优化，形成正向循环，大幅改善单目 VO 在真实复杂场景下的尺度恢复与泛化难题。本章的主要贡献总结如下：

- 1) **基于深度-位姿循环迭代优化的单目视觉里程计框架：**针对单目深度先验存在尺度偏移、纯几何 VO 缺乏尺度约束的问题，RoMeO 创新性地构建了一个深度-位姿联合优化系统。该系统利用单目先验提供初始深度，通过非线性优化获取同尺度下的位姿，然后根据这个位姿利用多视角几何（MVS）约束来优化深度。这一设计不仅实现了单目 VO 的绝对尺度感知，还大幅提升了视觉里程计在未知场景的泛化性能。
- 2) **深度引导的几何感知优化层：**不同于以往仅将深度作为额外输入的粗糙做法，RoMeO 深入到了 VO 的优化内核。本文改进了基于 GRU 的光流迭代更新算子，利用深度先验引导帧间相关性的查找，利用 3D 几何投影缩小匹配搜索空间，获得了更加准确的帧间匹配，用于优化位姿。同时，在通过 BA 优化得到不错的位姿后，能够通过重投影进一步提升帧间匹配关系，通过这种循环迭代的方式实现了深度与位姿的联合优化。
- 3) **抗噪训练策略与自适应门控机制：**为了防止系统过度依赖可能存在误差的深度先验，本文设计了一种抗噪训练策略。在训练阶段，本文主动向输入的深度先验中注入大幅度的随机尺度抖动和偏移噪声，强制网络学习如何利用多视角几何线索从充满噪声的先验中恢复正确的几何关系。这赋予了 RoMeO 极强的鲁棒性，使其在测试时能够适应各种质量不一的深度输入。同时，通过提出的自适应门控机制，本文只利用高置信度的先验来构建非线性优化的

残差项，避免噪声先验影响系统的鲁棒性。

- 4) **最优跨域泛化性能与定位精度**：在仅使用合成数据 TartanAir^[169] 进行训练的情况下，RoMeO 在真实世界的 KITTI Odometry^[83] 和 TUM-RGBD^[190] 数据集上展现出了强大的零样本迁移能力。实验结果表明，RoMeO 的轨迹误差显著低于 DROID-SLAM^[154] 等 SOTA 方法，且成功恢复了高精度的绝对尺度。

5.2 基于深度先验增强与几何迭代的单目视觉里程计框架

本节将阐述本文提出的基于深度先验增强与几何迭代的单目视觉里程计的方法原理与网络架构。针对前文分析的单目视觉里程计存在的尺度模糊、尺度漂移以及定位泛化性能差等问题，RoMeO 被设计为一个耦合的先验-几何优化的迭代系统。该系统的核心设计在于先验引导与几何迭代优化：即利用预训练的深度基础模型提供具备绝对尺度的几何初值与结构约束，同时通过基于多视角几何以及后端优化来动态校正先验中的尺度偏差与局部噪声，并通过迭代光流机制形成了深度-位姿的联合优化。




图 5.1 RoMeO 框架整体流程示意图。系统采用迭代优化策略：首先利用单目深度基础模型提供具备绝对尺度的深度初值；随后进入基于 GRU 的稠密光束法平差迭代优化。经过 6 轮迭代后，引入 MVS 深度作为几何观测约束更新深度，并通过迭代光流实现深度与位姿的联合优化。

RoMeO 的整体架构如图 5.1 所示。给定一段单目 RGB 视频流序列 $I = \{I_0, I_1, \dots, I_T\}$ ，其中 $I_t \in \mathbb{R}^{H \times W \times 3}$ 表示时刻 t 的图像帧。视觉里程计的核心任务是联合估计每一帧的相机位姿 $G = \{G_0, G_1, \dots, G_T\}$ 以及场景的稠密几何结构。在 RoMeO 中，为了数值稳定性，本文将场景几何参数化为逆深度图 $D = \{d_0, d_1, \dots, d_T\}$ ，其中 $d = 1/z$ 。相机位姿 $G_t \in SE(3)$ 定义为从相机坐标系到世界坐标系的刚体变换。在优化过程中，所有的位姿更新均在李代数空间 $\mathfrak{se}(3)$ 上进行，以保证流形约束。

RoMeO 旨在通过基于循环神经网络的迭代优化架构，最小化重投影误差与单目先验项的加权和：

$$E(G, D) = \sum_{(i,j) \in \mathcal{E}} \|r_{flow}(i, j)\|_{\Sigma}^2 + \lambda \sum_i \|r_{prior}(i)\|_{\Omega}^2 \quad (5.1)$$

其中， $\mathcal{E}$ 表示关键帧之间的可视关系图； r_{flow} 为由几何投影诱导的光流残差，代表了多视图几何的一致性约束； r_{prior} 为当前估计深度与输入的绝对深度先验之间的差异残差。 Σ 和 Ω 分别为网络预测的光流置信度与先验置信度权重矩阵。RoMeO 的具体工作流如图 5.1 所示，主要包含三个关键模块。

(1) 单目绝对深度初始化

为了解决单目 VO 固有的尺度缺失问题，RoMeO 在 $t = 0$ 时刻并非从零开始，而是利用预训练的深度基础模型^[19] 为当前帧注入具有绝对尺度的深度初值 D_{init} 。这种策略为非线性优化提供了处于凸域附近的初始解，极大地规避了优化陷入局部极值的风险。

(2) 几何引导的循环迭代优化

系统的核心是一个基于卷积 GRU 的迭代更新器。在每一次迭代 k 中，系统利用当前估计的位姿 G_k 和深度 D_k ，通过刚体变换与投影函数构建几何引导的初始光流，并在相关性金字塔中检索当前帧与参考帧之间的匹配特征。卷积 GRU 单元以匹配残差与上下文特征作为条件输入，输出位姿与深度的增量更新量 $(\Delta G, \Delta D)$ 。这一过程实质上是在李代数流形上执行的最小二乘迭代，逐步减小重投影光度误差。

(3) 多视角深度优化与自适应门控机制

随着迭代进行，当位姿估计逐渐收敛至可信范围时，系统引入多视角立体视觉模块作为几何修正。系统利用当前优化的位姿构建局部代价体，解算出符合多视角几何一致性的 MVS 深度。RoMeO 并非简单地替换深度，而是将单目语义先验与多视角深度同时作为正则化项注入后端优化图。并且通过提出的自适应门控机制，只利用高置信度的匹配关系来构建 BA 的残差项，避免噪声先验影响系统的鲁棒性。

5.3 单目深度先验初始化

在基于梯度的非线性优化系统中，初值的选择是决定系统收敛性与鲁棒性的关键因素。因此本节将关于初始化敏感性进行分析以及对不同单目模型的深度测评。

5.3.1 非凸优化与初始化的敏感性分析

视觉里程计的后端优化本质上是一个高维非凸优化问题。由于透视投影过程的高度非线性以及图像内容的复杂性，其优化能量函数的曲面充满了局部极小值。这意味着优化的最终结果对初始化状态表现出极高的敏感性。

现有的最先进方法（如 DROID-SLAM^[154]）通常采用一种简单的恒定深度初始化策略，即将新帧中所有像素的逆深度初始化为一个固定的常数（例如 1.0 米）。这种策略在景深变化较小的室内场景中能大致满足，但对于复杂的室外场景，存在两个致命缺陷。首先是深度动态范围巨大，室外场景中近处路面与远处的深度差异巨大。统一初始化会导致远处像素的初始残差极大，非线性优化难以收敛。其次是绝对尺度缺失，恒定初始化无法提供物理尺度信息，导致单目 VO 无法恢复绝对尺度的位姿，且容易产生尺度漂移。

5.3.2 基于单目绝对深度模型的初始化方案

为了解决上述问题，RoMeO 提出利用预训练的单目绝对深度估计模型的输出对每一帧进行像素级初始化。具体而言，本文将单目模型输出的绝对深度 D_{mono} 转换为逆深度，作为优化变量的起点：

$$d_t^{(0)} = \frac{1}{D_{mono,t} + \epsilon} \quad (5.2)$$

ϵ 为极小值防止求逆时出现异常极值。初始化策略不仅为系统提供了合理的场景深度初值，更重要的是引入了绝对物理尺度信息。

为了在单帧先验精度与系统整体效率之间寻找平衡，本文在室内（TUM-RGBD^[190]）和室外（KITTI Odometry^[83]）数据集上对比了多种单目深度模型，包括 DepthAnything V2^[25]（Small/Large）、Metric3D V2^[128]（Small/Large）以及 DPT-Hybrid^[19]。实验表明，相比于无先验的基准方法，引入任何一种深度先验，都能将 KITTI 上的轨迹误差从 137.33m 降低至 20m 以内。这证明了深度初始化是单目 VO 在室外场景的关键步骤之一。

尽管 Metric3DV2-Large^[128] 等大模型在单帧精度上极高，但在 VO 系统中，它们并未带来显著优于轻量级模型 DPT-Hybrid^[19] 的性能。例如，在 KITTI^[83] 上，Metric3D V2-Large 的 ATE（5.73m）相比 DPT-Hybrid（8.54m）虽然有提升，但其推理速度下降了近 60%，严重阻碍了实用性。本文推测，这种现象的原因在于后端优化具备深

表 5.1 不同单目深度估计模型用于初始化和深度引导的 BA 的性能对比。“无深度先验”作为基准。RTE 和 ATE 是误差指标（数值越小精度越高），而 FPS 表示帧率（数值越大越好）。**最佳**结果用粗体标注，次优结果用下划线标注。

单目深度估计模型	KITTI Odometry ^[83]			TUM-RGBD ^[190]		
	RTE (m)↓	ATE (m)↓	FPS↑	RTE (m)↓	ATE (m)↓	FPS↑
无深度先验	47.53	137.33	5.33	0.116	0.551	10.77
DepthAnythingV2-Small ^[25]	11.15	18.78	<u>4.19</u>	<u>0.104</u>	0.273	7.56
DepthAnythingV2-Large ^[25]	7.97	13.47	1.59	0.107	0.456	4.20
Metric3DV2-Small ^[128]	5.71	8.74	4.08	<u>0.104</u>	<u>0.235</u>	6.41
Metric3DV2-Large ^[128]	4.08	5.73	1.70	0.105	0.247	2.39
DPT-Hybrid ^[19]	<u>4.25</u>	<u>8.54</u>	3.96	0.098	0.205	<u>8.55</u>

度自修正能力，它能够利用多帧几何约束来优化深度。因此，深度初始化并不需要像 Metric3D V2^[128]、DepthAnything V2^[25] 这种单帧精度高并且锐利的深度，而更需要的是多帧一致性好和鲁棒的深度预测，便于多帧之间进行几何一致性约束。这也证明了对于 VO 系统来说，只需要先验提供一个相对粗糙但鲁棒的绝对尺度框架。

基于上述分析，为了最小化系统开销，本文最终选择采用轻量级的 DPT-Hybrid^[19] 并结合其提供的尺度和偏移参数来获取绝对深度。

5.4 基于光流的几何感知的迭代更新算子

在完成了深度先验初始化后，RoMeO 进入迭代优化阶段。这一阶段是利用多视角立体视觉的几何原理，通过多帧光流约束来对位姿进行非线性优化。为了实现这一目标，本文设计了包含深度引导相关性查找和几何感知稠密 BA 层的新型算子。

5.4.1 深度引导的相关性查找

现有的基于深度学习的视觉里程计方法通常依赖于在 4D 相关性体中进行全局搜索来建立帧间对应关系，这种策略不仅计算复杂度高而且在弱纹理区域极易产生歧义。为此，RoMeO 利用深度先验与几何投影约束，将搜索范围锁定在极线附近的局部空间内，从而显著提升了匹配的效率与鲁棒性。

具体而言，对于参考帧 i 中的任意像素坐标 p_i ，结合当前的深度估计值 d_i 与帧间相对位姿 $T_{ij} = \{R_{ij}, t_{ij}\}$ ，本文首先根据刚体变换模型计算其在目标帧 j 上的重投

影坐标 p'_{ij} :

$$p'_{ij} = \pi(R_{ij} \cdot \pi^{-1}(p_i, d_i) + t_{ij}) \quad (5.3)$$

其中, $\pi(\cdot)$ 和 $\pi^{-1}(\cdot)$ 分别表示相机投影函数及其逆函数, R_{ij} 和 t_{ij} 分别表示从帧 i 到帧 j 的旋转矩阵与平移向量。

基于该投影关系, 本文构建了一个以 p'_{ij} 为中心的局部邻域网格 Ω_r , 并从金字塔多尺度相关性体 C_{ij} 中通过双线性插值提取相关性特征向量 f_{corr} :

$$f_{corr}(p_i) = \text{Concat}_{\delta \in \Omega_r}(\mathcal{L}(C_{ij}, p_i, p'_{ij} + \delta)) \quad (5.4)$$

其中, $\Omega_r = \{\delta \in \mathbb{Z}^2 \mid \|\delta\|_\infty \leq r\}$ 表示半径为 r 的整数偏移网格; $\mathcal{L}(\cdot)$ 表示在连续坐标空间下的双线性采样算子; **Concat** 表示将采样得到的相关性值沿通道维度拼接。这一机制充分利用了深度先验与极线几何约束, 将搜索空间限制在投影点邻域的极小范围内, 有效地从物理层面剔除了大量误匹配, 显著提升了帧间特征对齐的精度, 进而为位姿优化提供了高质量的梯度流。

5.4.2 残差光流与优化收敛性分析




图 5.2 不同 BA 迭代阶段的光流残差幅值对比。相比于采用恒定初始化的基准方法, 引入绝对深度先验的 RoMeO 展现出了更低的初始误差和更快的收敛速度。RoMeO 在第 2 次迭代时的精度已超越基准方法的最终精度, 证明了先验对优化过程的显著引导作用。

为了深入验证绝对深度先验对非凸优化过程的具体影响, 本文对几何感知更新算子在迭代过程中的光流残差演变进行了定量分析。每一轮次的光流残差 Δr 直观

地反映了匹配的收敛程度，是衡量优化收敛质量的核心指标。

如图 5.2 所示，本文对比了 RoMeO 与未采用深度先验的基准方法（基线方案采用恒定深度初始化）在 KITTI 数据集上的残差收敛曲线。从图中可以观察到，在迭代初期第 0 步，RoMeO 的初始残差为 3.2 像素显著低于基准方法的 4.6 像素。这表明，单目绝对深度先验为非线性优化提供了一个更接近全局最优解的初始状态。在非凸优化理论中，这意味着系统更有可能落在正确解的吸引域内，从而避免陷入错误的局部极小值。并且随着 BA 的迭代次数增加，RoMeO 的残差值下降速度远快于基准方法。值得注意的是，RoMeO 在第 2 次迭代时的残差水平（约 1.2 像素）已经低于基准方法在第 10 次迭代时的最终水平。这一现象具有重要的工程意义：它意味着 RoMeO 能够以极少的时间开销快速优化出高精度位姿。

基于上述观察，本文不仅验证了深度先验引导 BA 优化的有效性，还为后续引入 MVS 模块提供了支撑：由于位姿在早期迭代（如第 6–8 次）已趋于稳定且精确，本文可以在优化后期安全地利用这些中间位姿进行多视角立体匹配，而无需担心位姿误差过大导致 MVS 匹配发散。

5.4.3 几何感知的稠密光束法平差层

这是 RoMeO 实现 MVS 优化的核心前提。不同于之前的主流深度学习方法直接通过卷积层回归位姿增量，RoMeO 结合传统方法的优势，引入了可微的稠密 BA 层来将几何优化问题嵌入到网络中。为了联合优化相机位姿与场景深度，本文将该问题建模为非线性最小二乘问题。对于每一个像素，定义如下两项残差：

- 光流重投影残差： $r_{flow} = f_{geo} - f_{net}$ 。其中 f_{geo} 是由当前几何状态（位姿 + 深度）投影诱导出的几何光流， f_{net} 是基于卷积 GRU 的光流网络利用相关性特征预测的修正光流。该项施加了多视图几何的一致性约束。
- 深度先验残差： $r_{prior} = d - d_{prior}$ 。该项作为正则化约束，防止优化结果过度偏离单目深度先验。在纯视觉 BA 优化中，由于缺乏绝对尺度信息，几何结构容易发生退化或尺度漂移，引入先验约束能有效提升优化的数值稳定性。

为了求解该非线性最小二乘问题，本文采用列文伯格-马夸特算法（Levenberg-Marquardt, LM）进行迭代优化。首先，计算残差关于位姿增量 $\Delta\xi$ 和深度增量 Δd 的雅可比矩阵 J 。随后，构建增量正规方程：

$$(J^T W J + \lambda D_{amp}) \begin{pmatrix} \Delta \xi \\ \Delta d \end{pmatrix} = -J^T W r \quad (5.5)$$

其中 W 为网络预测的置信度权重对角矩阵, λD_{amp} 为 LM 算法的阻尼项, 用于保证海森矩阵的正定性并调节步长。为了高效求解, 本文利用舒尔补技术对高维度的深度变量进行边缘化: 先求解低维度的位姿增量, 再代回求解深度增量。最终优化得到的当前轮次深度和位姿, 将继续作为 MVS 优化的输入并用于构建重投影光流, 形成“单目初始化 $\rightarrow$ MVS 几何修正”的闭环: 单目先验提供良好的初值, 而 MVS 优化层利用多帧几何一致性来校正先验的尺度漂移与局部误差。

5.5 噪声增强训练与自适应筛选策略

5.5.1 面向噪声先验的训练策略

为了防止网络在训练过程中过度依赖精准的深度先验, 从而导致在测试时面对有噪先验失效, RoMeO 设计了一套抗噪训练策略。核心思想是在训练阶段主动破坏深度先验, 迫使网络学习如何适应有误差的先验并且利用多视角几何线索去纠正它。本文在训练数据加载时, 对真值深度 d_{gt} 施加三种扰动作为输入:

- 全局尺度抖动: $d_{noisy} = d_{gt} \cdot \exp(\delta_s)$ 。模拟单目模型的尺度不确定性。
- 全局偏移噪声: $d_{noisy} = d_{noisy} + \delta_t$ 。模拟基准面漂移。
- 局部高斯噪声: 模拟局部预测误差。

通过这种训练, RoMeO 能够更加适应真实应用场景, 即模拟初始化深度在尺度和偏移上均含有噪声的真实应用模式。

5.5.2 自适应门控机制

在推理阶段, 单目深度先验的质量在空间分布上呈现非均匀性。为了在优化过程中智能判别先验信息的可靠性, 网络预测一个像素级的置信度门控图 $M_{gate} \in [0, 1]^{H \times W}$, 用于对 BA 优化中的先验残差项进行自适应加权:

$$E_{prior} = \sum_{p \in \Omega} M_{gate}(p) \cdot \|d(p) - d_{prior}(p)\|^2 \quad (5.6)$$

其中 p 表示像素坐标, Ω 为图像域。该门控机制实质上充当了软开关作用, 根据先验与多视图几何的一致性动态调节约束强度:

- 高置信度区域 ($M_{gate} \rightarrow 1$): 当单目先验与多视图几何约束高度一致时, 门控值趋近于 1。此时, 残差项作为一个强正则化约束, 强制优化后的深度保持在单目预测的邻域内。这不仅能提升位姿求解在弱纹理区域的鲁棒性, 还能利用先验良好的全局一致性加速优化收敛。
- 低置信度区域 ($M_{gate} \rightarrow 0$): 当区域存在显著的几何冲突时, 门控值趋近于 0。此时, 网络自动阻断先验梯度, 解除对深度变量的强制约束。这一机制使得系统在识别到错误的先验信息后退化为纯粹基于多视图光流投影残差进行状态更新, 从而避免了错误的先验拉偏最终的位姿估计。

5.5.3 监督损失函数

RoMeO 采用端到端的监督学习进行训练, 损失函数设计旨在同时约束序列的光流一致性和相对位姿的几何精度。

(1) 序列化光流损失

为了监督整个优化过程的收敛轨迹, 本文对 GRU 的每一次迭代输出都计算光流误差。对于帧图中的每一条边 (即每一对具有共视关系的关键帧) $(i, j) \in \mathcal{E}$, 本文利用预测的位姿和深度计算重投影光流 f_{ij}^{pred} , 并与真值光流 f_{ij}^{gt} 进行对比:

$$\mathcal{L}_{flow} = \sum_{(i,j) \in \mathcal{E}} \sum_{k=1}^K \gamma^{K-k} \|f_{ij}^{pred,(k)} - f_{ij}^{gt}\|_1 \quad (5.7)$$

其中 K 为 GRU 的总迭代次数, $\gamma = 0.8$ 是序列衰减因子, 用于给予后期迭代更高的权重。本文采用 L_1 范数以增强对光流异常值的鲁棒性。

(2) 相对位姿回归损失

为了确保系统能够恢复出准确的绝对尺度并保持局部轨迹的几何一致性, 本文直接在李代数 $\mathfrak{se}(3)$ 空间对帧间的相对位姿进行监督。定义 $T_{ij} = G_i^{-1}G_j$ 为从帧 i 到帧 j 的相对位姿变换, 损失函数定义为预测相对位姿 T_{ij}^{pred} 与真值相对位姿 T_{ij}^{gt} 之间的李代数残差范数:

$$\mathcal{L}_{pose} = \sum_{(i,j) \in \mathcal{E}} \sum_{k=1}^K \gamma^{K-k} \|\text{Log} \left((T_{ij}^{gt})^{-1} \cdot T_{ij}^{pred,(k)} \right)\|_2 \quad (5.8)$$

其中 $\text{Log}(\cdot)$ 为从李群 $SE(3)$ 到李代数 $\mathfrak{se}(3)$ 的对数映射, 该损失项强制网络在优化光流的同时, 显式地学习符合绝对尺度的几何运动关系。

最终的总损失为 $\mathcal{L}_{total} = \mathcal{L}_{flow} + \alpha \mathcal{L}_{pose}$, 其中 α 用于平衡两项的量级 (实验中设为 10.0)。这种基于图结构的序列化监督策略, 使得网络能够学习到逐渐优化出最佳位姿的预测模式。

5.6 实验结果与分析

为了全面验证 RoMeO 框架在解决单目视觉里程计中绝对尺度恢复以及跨域泛化能力等核心挑战上的有效性, 本节在包含室外自动驾驶、室外手持定位、室内微型飞行器以及室内手持设备等多种场景下的 6 个公开基准数据集上进行了广泛的零样本实验评估。

实验设计的核心原则是合成域训练, 真实域泛化。本章的所有模型仅在合成数据集 TartanAir^[169] 上进行训练, 随后直接部署到真实世界的 6 个测试数据集中, 且不进行任何形式的微调。这种严苛的测试设置最能反映算法在开放世界中面对未知场景、光照和运动模式时的真实泛化性能以及域迁移潜力。

本节内容安排如下: 5.6.1 节详细介绍实验数据集特性、评估指标及训练细节; 5.6.2 节展示与 SOTA 方法在 VO 和 SLAM 任务上的总体对比, 在 6 个最通用的视觉里程计数据集上进行对比和剖析; 5.6.3 节通过消融实验验证核心模块贡献; 最后 5.6.4 节分析系统运行效率。

5.6.1 实验设置与数据集

(1) 训练数据集

为了避免数据驱动方法对特定真实场景产生过拟合, 本文仅使用 TartanAir^[169] 数据集进行训练。TartanAir 是一个基于高保真物理引擎构建的三维场景数据集, 包含室内、室外、水下、科幻等多样化场景, 提供了完美的位姿真值和稠密深度图。使用合成数据训练旨在令网络学习通用的几何理解能力, 而非过拟合于环境纹理。

(2) 测试数据集

为了全方位评估泛化性, 本文选取了 3 个室外数据集和 3 个室内数据集, 涵盖了从自动驾驶到无人机等多个场景下的基准数据集, 域变化范围广

- KITTI Odometry^[83] (室外车载): 自动驾驶领域的最权威基准数据集。场景特征为高速运动、长距离行驶。主要挑战在于长时序的尺度保持能力。
- 4Seasons^[191] (室外车载): 一个跨季节、跨天气的自动驾驶数据集。相比 KITTI, 它包含了更剧烈的光照变化 (如直射阳光、阴影) 和多变的天气条件, 对算法的鲁棒性提出了极高要求。
- Cambridge Landmarks^[153] (室外手持): 一个在剑桥大学周围采集的大规模室外视觉定位数据集。其特点是轨迹复杂、建筑物纹理重复且尺度巨大, 考验算法在大尺度场景下的定位能力。
- EuRoC MAV^[192] (室内飞行器): 由微型飞行器在工厂大厅和普通房间内采集。特点为剧烈的六自由度运动 (快速旋转、平移) 和运动模糊, 是检验算法定位跟踪鲁棒性的经典数据集。
- TUM-RGBD^[190] (室内手持): 包含办公室、大厅等场景, 特征为纹理弱、运动模糊多。主要挑战在于近距离物体的快速运动跟踪和弱纹理区域的处理。
- ETH3D^[193] (室内高精度): 使用高精度 LiDAR 获取真值的室内 SLAM 基准。其场景包含了复杂的室内结构, 用于精细评估几何重建与定位的准确性。

(3) 评估指标

本文遵循 VO 领域的标准评估协议, 采用以下两个核心指标:

- 绝对轨迹误差 (Absolute Trajectory Error, ATE): 衡量全局轨迹的一致性。传统的单目方法通常使用 Sim(3) 对齐 (允许 7 自由度, 包含尺度缩放) 来掩盖尺度缺陷。然而, 由于 RoMeO 旨在恢复绝对尺度, 本文在所有实验中均采用严格的 SE(3) 对齐 (仅允许 6 自由度, 即旋转和平移, 禁止尺度缩放)。这实际上是对单目 VO 最严苛的考验。
- 相对轨迹误差 (Relative Trajectory Error, RTE): 为了解耦尺度误差和轨迹形状误差, 本文额外测试 RTE 指标。RTE 在计算轨迹误差前会将预测轨迹与真值进行尺度对齐。如果一个方法的 RTE 很低但 ATE 很高, 说明其轨迹形状正确但尺度错误; 如果两者都低, 说明实现了高精度的绝对尺度定位。

5.6.2 在基准数据集上的实验结果

(1) 视觉里程计 (VO) 性能对比

表格 5.2 和表格 5.3 展示了 RoMeO 与当前最先进方法 (包括传统方法 ORB-

表 5.2 室外场景视觉里程计评估结果。报告指标为：RTE (m) / ATE (m)。缺失值 (–) 表示方法定位失败。

方法	室外数据集 (RTE / ATE)			
	KITTI ^[83]	4Seasons ^[191]	Cambridge ^[153]	平均误差
ORB-SLAM3 (VO) ^[194]	29.10 / 163.25	–	–	–
DSO ^[39]	47.23 / 154.25	–	–	–
DeepV2d ^[183]	22.20 / 154.52	74.70 / 344.75	27.21 / 34.50	41.37 / 177.92
TrianFlow ^[195]	42.07 / 168.17	40.44 / 150.46	27.35 / 34.60	36.62 / 117.74
TartanVO ^[151]	32.25 / 45.30	59.25 / <u>81.70</u>	19.40 / <u>24.23</u>	36.97 / <u>50.41</u>
DROID-VO ^[154]	47.53 / 137.33	58.87 / 149.54	13.56 / 33.67	39.99 / 106.85
DROID-Metric3d ^[24]	<u>3.95</u> / 5.57	125.44 / 140.32	<u>13.55</u> / 47.68	47.64 / 64.52
DPVO ^[155]	46.04 / 140.28	9.95 / 141.36	15.89 / 36.03	<u>23.96</u> / 105.89
RoMeO	2.71 / 3.81	<u>19.59</u> / 42.56	9.96 / 23.47	10.75 / 23.28

表 5.3 室内场景视觉里程计评估结果。报告指标为：RTE (m) / ATE (m)。缺失值 (–) 表示方法定位失败。

方法	室内数据集 (RTE / ATE)			
	EuRoC ^[192]	ETH3D ^[193]	TUM-RGBD ^[190]	平均误差
ORB-SLAM3 (VO) ^[194]	0.488 / 1.677	–	–	–
DSO ^[39]	0.404 / 1.532	–	–	–
DeepV2d ^[183]	1.173 / 3.452	0.324 / 0.582	0.225 / 0.415	0.574 / 1.483
TrianFlow ^[195]	1.731 / 1.848	0.706 / 0.868	0.444 / 0.565	0.960 / 1.094
TartanVO ^[151]	0.632 / 4.135	0.421 / 26.273	0.320 / 16.692	0.458 / 15.70
DROID-VO ^[154]	0.141 / <u>1.307</u>	0.367 / <u>0.628</u>	0.116 / 0.551	0.208 / <u>0.829</u>
DROID-Metric3d ^[24]	0.109 / 1.310	0.420 / 1.077	0.190 / 0.330	0.240 / 0.906
DPVO ^[155]	<u>0.101</u> / 1.865	<u>0.203</u> / 0.646	<u>0.107</u> / <u>0.324</u>	<u>0.137</u> / 0.945
RoMeO	0.098 / 1.126	0.022 / 0.238	0.067 / 0.091	0.062 / 0.485

SLAM3^[194], DSO^[39] 和基于深度学习的方案 DeepV2d^[183], TartanVO^[151], DROID-SLAM^[154], DPVO^[155] 等) 在 6 个测试数据集上的综合对比分析。首先是绝对尺度感知能力, 在单目视觉里程计领域, 恢复绝对物理尺度一直是痛点难点。现有的学习型 SOTA 方法如 DPVO^[155] 和 DROID-VO^[154], 由于本质上缺乏物理尺度的约束, 无法获取真实尺度下的轨迹。当采用严格的 SE(3) 对齐进行评估时, DPVO^[155] 在

KITTI^[83] 上的 ATE 高达 140.28m，这表明其预测轨迹虽然形状可能相似，但在物理距离上与真实世界完全脱节。相比之下，RoMeO 凭借单目深度先验提供的初始尺度和 MVS 的几何校正，在 SE(3) 对齐下取得了 3.81m 的 ATE，将误差降低了约 97.3%。这意味着 RoMeO 生成的轨迹基本实现了与真实世界 1:1 的绝对尺度对应，无需借助 IMU 或双目相机即可直接用于导航控制。此外，RoMeO 的相对轨迹误差也降低至 2.71m，说明其在恢复尺度的同时也优化了轨迹的局部几何形状。

其次是 RoMeO 具有显著的跨域泛化优势。为了验证系统架构的优越性，本文将其与基准组合 DROID-Metric3D（即将 Metric3D^[24] 的预测深度简单嵌入 DROID-SLAM^[154] 的初始化与 BA 环节）进行了对比。实验结果显示，简单的深度注入策略在面对未见过的测试域时往往适得其反。例如在环境复杂的 4Seasons^[191] 数据集上，DROID-Metric3D 的 ATE 高达 140.32m，甚至劣于原始 DROID-VO^[154]。这是因为跨域场景下的深度先验不可避免地包含噪声和伪影，盲目信任这些先验会破坏后端优化的收敛方向。相反，RoMeO 凭借设计的抗噪训练策略和自适应门控机制，能够智能地识别并过滤不可靠的先验区域，仅利用高置信度的几何线索。这使得 RoMeO 在 4Seasons 上的 ATE 显著降低，在 Cambridge^[153] 上也取得了优于 DROID-Metric3D 两倍以上精度（23.47m vs 47.68m），充分证明了 RoMeO 在处理域偏移时的鲁棒性。相比传统几何方法（如 ORB-SLAM3^[194], DSO^[39]）高度依赖底层特征点的稳定性。在 4Seasons^[191] 和 Cambridge^[153] 等室外场景中，由于剧烈的光照变化（如过曝、阴影）和纹理缺失，这些方法在多个序列上频繁发生跟踪丢失，导致无法输出完整轨迹（如表 5.2 中以“-”标记所示）。RoMeO 则展现出了惊人的稳定性，在所有 6 个数据集的所有测试序列中均保持了 100% 的定位跟踪成功率。这归功于 RoMeO 引入的深度先验不仅提供了几何约束，还隐式地包含了场景的语义结构信息，这些高层语义特征对光照变化具有天然的不变性，从而引导系统在匹配特征失效的极端情况下依然能维持稳定的位姿估计。

为了更直观地验证算法在真实场景中的定位性能，图 5.4 展示了 RoMeO 与当前主流方法（DeepV2d^[183], DROID-VO^[154], DPVO^[155]）在 KITTI^[83] 00、08 序列（室外长距离）和 TUM-RGBD^[190] room 序列（室内手持）的轨迹可视化对比。为了全面评估尺度恢复能力与轨迹几何形状的准确性，本文分别展示了无对齐操作和进行尺度对齐两种情形下的结果。

从可视化结果中如图中第一行和第三行所示，在未进行 Sim(3) 尺度对齐的原始




图 5.3 点云可视化。前两列：在 KITTI 数据集上的测试结果。后两列：在 TUM-RGBD 数据集上的测试结果。RoMeO 能提供更精确的点云重建结果，证明了 RoMeO 的位姿和深度精度的优越性。

输出中，对比方法（如 DPVO^[155]、DROID-VO^[154]）由于缺乏物理尺度约束，其预测轨迹呈现出严重的尺度模糊现象。例如在 KITTI-00 序列中，DPVO 的轨迹尺度远小于真实值；而 DeepV2d^[183] 则表现出巨大的尺度漂移。相比之下，RoMeO 的原始输出轨迹与真值在物理尺寸和轨迹上均高度重合。这直观地证明了单目深度先验成功赋予了 VO 系统绝对的度量感知能力，使其无需后处理即可直接输出绝对位姿。如图中第二行和第四行所示，即使使用对齐尺度的操作变换修正了对比方法的全局尺度，RoMeO 依然展现出更优的轨迹几何形态。在 KITTI-00 的多次转弯处，以及 TUM-room 的复杂运动中，DPVO 和 DROID-VO 均出现了明显的累积漂移，导致轨迹末端无法闭合。而 RoMeO 凭借几何感知更新算子对中间位姿的精细化约束，在没有使用回环检测和全局 BA 优化的纯 VO 模式下，依然实现了极高的轨迹闭合度。这一现象充分表明，RoMeO 不仅尺度准，其基于深度先验与几何迭代的优化策略也显著提升了位姿估计的精度与稳定性。

为了直观验证算法在真实场景中的感知性能，图 5.3 展示了稠密点云重建的定性对比结果。在几何重建方面，相比于出现很多点云重影以及边缘噪点较多的 DROID-VO^[154]，RoMeO 在室外 KITTI^[83] 和室内 TUM-RGBD^[190] 场景中均重建出了结构准确的三维点云。这些定性结果与前文的定量指标高度一致，充分展示了该方法在位姿与建图上的综合优势。

（2）SLAM 系统性能对比

本文将 RoMeO 扩展为全功能的 SLAM 系统（RoMeO-SLAM），引入了后端全局




图 5.4 KITTI Odometry 与 TUM-RGBD 数据集上的轨迹可视化对比。图中对比了 RoMeO 与 SOTA 方法在有/无尺度对齐情况下的表现。RoMeO (橙色线) 在两种设置下均能紧密跟随真值 (虚线), 展现了卓越的绝对尺度恢复能力和长时序跟踪鲁棒性, 而对比较方法在无对齐时尺度完全失效, 在有对齐时仍存在显著的轨迹漂移。

表 5.4 室外场景 SLAM 系统评估结果。报告指标为：RTE (m) / ATE (m)。缺失值 (–) 表示方法定位失败。

方法	室外数据集 (RTE / ATE)			
	KITTI ^[83]	4Seasons ^[191]	Cambridge ^[153]	平均误差
ORB-SLAM3 ^[194]	16.42 / 165.28	–	–	–
Droid-SLAM ^[154]	39.12 / 155.89	58.12 / 144.20	12.37 / 33.13	36.54 / 111.07
RoMeO-SLAM	2.64 / 3.72	20.39 / 44.20	9.90 / 23.23	10.98 / 23.72

表 5.5 室内场景 SLAM 系统评估结果。报告指标为：RTE (m) / ATE (m)。缺失值 (–) 表示方法定位失败。

方法	室内数据集 (RTE / ATE)			
	EuRoC ^[192]	ETH3D ^[193]	TUM-RGBD ^[190]	平均误差
ORB-SLAM3	0.214 / 1.437	–	–	–
Droid-SLAM	0.019 / 1.238	0.010 / 0.011	0.028 / 0.168	0.019 / 0.472
RoMeO-SLAM	0.016 / 1.100	0.008 / 0.060	0.021 / 0.071	0.015 / 0.410

光束法平差以进一步消除长时序漂移。如表格 5.4 和表格 5.5 所示，RoMeO-SLAM 在各项指标上均取得了突破性进展，特别是在 KITTI odometry^[83] 数据集上，其性能优势尤为显著。在 KITTI Odometry^[83] 基准上，RoMeO-SLAM 的绝对轨迹误差 (ATE) 降低至 3.72m，而对比方法 Droid-SLAM 的 ATE 高达 144.20m。这一巨大的性能鸿沟深刻揭示了传统单目 SLAM 与 RoMeO 在底层原理上的本质区别。Droid-SLAM^[154] 及其它单目方法（如 ORB-SLAM3^[194]）在本质上无法恢复绝对物理尺度。RoMeO-SLAM 的低 ATE 证明了其输出的轨迹在物理尺度上与真实世界高度一致，这得益于前端引入的绝对深度先验为系统提供了一个大致的深度尺度初始化，使得系统无需依赖外部传感器即可感知真实世界的距离。

实验结果有力地证明了高质量的前端度量初始化是后端全局优化成功的先决条件。全局 BA 本质上是一个非凸优化问题，极度依赖初值。如果前端提供的轨迹尺度是错误的或漂移的（如 Droid-SLAM^[154]），全局 BA 也很难修复，往往会陷入错误的局部极小值。RoMeO-SLAM 在引入全局 BA 后，ATE 从 VO 阶段的 3.81m 进一步优化至 3.72m。这一稳健的提升表明，RoMeO 前端生成的轨迹已经具备了极

高的精度和尺度一致性，这种前后端的高度耦合与互补，正是 RoMeO 框架鲁棒性的核心来源。除 KITTI odometry^[83] 外，RoMeO-SLAM 在室内数据集（如 EuRoC^[192]，TUM-RGBD^[190]）上也保持了同样的性能优势。例如在 EuRoC^[192] 上，ATE 仅为 0.016m，优于 Droid-SLAM^[154] 的 0.019m。这进一步验证了，无论是在大尺度的室外驾驶场景，还是小尺度的室内飞行场景，RoMeO 基于深度先验的初始化策略都能为 SLAM 后端提供可靠的几何约束，从而实现全场景的高精度定位。

5.6.3 消融实验

表 5.6 消融实验，通过移除或替换 RoMeO 的核心模块来进行对比实验（指标为 RTE/ATE）。NAT 代表噪声增强训练。

方法	单目深度模型	NAT	MVS	轨迹精度 (RTE / ATE)			
				KITTI ^[83]	4Seasons ^[191]	TUM-RGBD ^[190]	平均误差
RoMeO-VO	DPT	✓	✓	2.71 / 3.81	19.59 / 42.56	0.067 / 0.091	7.45 / 15.49
Always regularize	DPT	✓	✓	2.48 / 3.63	117.95 / 154.78	0.136 / 0.158	40.20 / 52.86
No regularization	DPT	✓	✓	11.25 / 47.91	16.99 / 39.63	0.058 / 0.088	9.44 / 29.21
Replace w/ Metric3D	Metric3D	✓	✓	3.23 / 4.67	53.43 / 89.28	0.135 / 0.288	18.94 / 31.41
No MVS	DPT	✓	-	3.35 / 5.14	23.49 / 55.38	0.075 / 0.121	8.96 / 20.21
No NAT & No MVS	DPT	-	-	4.25 / 8.54	34.32 / 121.65	0.098 / 0.205	12.89 / 43.47
No depth prior	-	-	-	47.53 / 137.33	58.87 / 149.54	0.116 / 0.551	35.52 / 95.79

为了量化各个设计模块的贡献，本文在 KITTI Odometry^[83]、4Seasons^[191] 和 TUM-RGBD^[190] 上进行了充分的消融实验，结果如表格 5.6 所示。

(1) 深度先验与 MVS 优化

- 解决尺度模糊的决定性因素：对比 “No depth prior”，即移除深度初始化，KITTI 上的 ATE 飙升至 137.33m，且在所有数据集上的精度均表现最差。这一灾难性的性能衰退再次证实了：在缺乏先验约束的情况下，单目 VO 极易陷入非凸优化的局部极小值。相比之下，即使是仅引入初始化（No NAT & No MVS），KITTI 的 ATE 也骤降至 8.54m。这表明单目绝对深度先验为优化过程提供了一个关键的初始起点。
- MVS 的几何优化能力：在保留深度初始化的基础上，进一步引入 MVS 模块（RoMeO-VO vs. No MVS）使平均 ATE 从 20.21m 降低至 15.49m。这种提升揭示了 MVS 与单目先验的互补性：单目先验虽然结构完整但存在几何一致性误差，而 MVS 利用多视角提供的几何约束，有效地修正了单目先验中的局部尺

度漂移，促进了定位精度的再次提升。

(2) 抗噪训练策略 (NAT)

如果不进行噪声增强训练 (对比 No NAT & No MVS 与 No MVS)，系统在复杂场景 4Seasons^[191] 上的 ATE 从 55.38m 降低至 121.65m。这一显著差距揭示了抗噪训练策略的有效性：如果训练时总是提供完美的深度先验，网络会倾向于完全依赖先验而忽略图像光流等几何信息。NAT 策略通过在训练时注入强噪声，令网络学习如何利用视频流中的多视图几何线索去自适应判别输入先验的噪声，从而赋予了系统在测试时应对真实先验误差的鲁棒能力。

(3) 自适应门控机制

实验中最具启发性的对比来自 “Always regularize” 变体。当强制系统在所有区域都接受深度先验约束时，虽然在 KITTI (深度先验在这个数据集上很准) 上略有提升，但在先验噪声较大的 4Seasons^[191] 数据集上，ATE 剧烈上升到了 154.78m。这说明在跨域场景下，盲目信任单目先验会将错误的几何信息强加给 VO，导致轨迹彻底崩坏。反之，如果完全移除深度正则化项 (No regularization)，KITTI 上的 ATE 退化至 47.91m，说明失去了先验的持续约束，长时序轨迹容易发生尺度漂移。RoMeO 凭借自适应门控机制，能够在是否依赖深度先验之间进行动态权衡：在先验可靠时利用其约束轨迹的优化，在先验失效时自动切断约束，从而在所有测试场景中保持了最优的综合性能。

5.6.4 系统效率分析

表 5.7 RoMeO 及其快速版的精度效率分析。速度均在同一块 RTX-3090 GPU 上测得。RTE 和 ATE 为误差指标，FPS 为推理帧率指标。

方法	KITTI Odometry ^[83]			TUM-RGBD ^[190]		
	RTE (m)↓	ATE (m)↓	FPS↑	RTE (m)↓	ATE (m)↓	FPS↑
DROID-SLAM ^[154] (基线)	47.53	137.33	<u>5.33</u>	0.116	0.551	<u>10.77</u>
RoMeO-VO	2.71	3.81	3.54	0.067	0.091	7.65
RoMeO-VO-Fast	<u>4.23</u>	<u>6.89</u>	6.28	<u>0.077</u>	<u>0.140</u>	20.57

(1) 引入先验的成本与收益

如表格 5.7 所示，标准的 RoMeO-VO 版本在引入 DPT-Hybrid^[19] 进行深度初始

化和 MVS 几何引导后, 相比于无先验的基线方法^[154], 其运行速度虽然有所下降 (例如在 KITTI 上从 5.33 FPS 降至 3.54 FPS), 但这种计算成本的增加换来了性能的质变。在 KITTI 上, ATE 误差从完全不可用的 137.33m 降低到了 3.81m (降低了 97%)。这表明, 通过轻量级模型引入几何先验是性价比极高的策略: 以微小的计算延迟为代价, 显著提升了单目 VO 的性能。

(2) RoMeO-VO-Fast 的效率优化

为了满足高帧率应用需求, 本文通过两项策略构建了快速版本 RoMeO-VO-Fast: 1) 降低输入分辨率, 例如在 TUM-RGBD^[104] 上从 240×320 降至 192×256 ; 2) 稀疏化深度初始化, 即仅对关键帧运行单目深度预测, 非关键帧复用最近关键帧的深度进行重投影初始化。如表格 5.7 所示, RoMeO-VO-Fast 在 TUM-RGBD^[104] 上的速度高达 20.57 FPS, 不仅远超标准版 (7.65 FPS), 甚至比不需要运行深度模型的基线方案 (10.77 FPS) 还要快一倍。这是因为高质量的深度初值加速了后端光流优化的收敛, 且低分辨率输入大幅减少了相关性代价体的计算量。同时, 其精度 (ATE 0.140m) 虽然略低于标准版, 但仍显著优于基线方法 (0.551m)。这一结果证明了 RoMeO 框架具有极强的弹性, 能够根据算力预算灵活调整配置。

5.7 本章小结

本章针对单目视觉里程计在复杂开放场景中面临的尺度缺失、初始化敏感及跨域泛化能力弱等核心瓶颈, 提出了一种基于深度先验增强的鲁棒单目视觉里程计框架——RoMeO。区别于传统几何方法对底层特征质量的高度依赖, 以及现有端到端学习方法在未见场景下的泛化瓶颈, 本章构建了深度先验引导下的几何迭代优化新范式。为了解决单目尺度模糊的本质难题, 本章引入了轻量级单目绝对深度模型作为系统的深度初值, 为非凸优化过程提供了具备物理尺度的全局收敛域。针对先验数据在跨域场景下不可避免的噪声干扰问题, 本章设计了包含几何感知更新算子、噪声增强训练策略及自适应门控机制在内的一整套鲁棒性方案。该方案通过模拟先验误差强制网络学习利用多视图几何线索对深度先验进行自适应判别, 并通过迭代光流机制使得深度和位姿进行联合优化, 互相促进。

在实验验证方面, RoMeO 在涵盖室外自动驾驶 (KITTI Odometry^[83], 4Seasons^[191], Cambridge^[153]) 及室内复杂运动 (EuRoC^[192], TUM-RGBD^[190], ETH3D^[193]) 的 6

个基准数据集上，均取得了超越当前最先进方法的零样本泛化性能。特别是在最具挑战的 KITTI Odometry^[83] 基准上，系统在无 IMU 或双目辅助的情况下，成功恢复了真实世界的绝对尺度。本章的研究不仅证实了深度估计与视觉里程计紧密耦合的有效性，更为构建低成本、全天候、高可靠的通用型自主导航系统提供了坚实的理论支撑与技术路径。

6 总结与展望

随着人工智能技术的飞速发展，三维视觉作为连接数字世界与物理世界的桥梁，其重要性日益凸显。其中，基于立体视觉深度估计凭借其利用多视图几何原理恢复绝对度量的特性，成为自动驾驶、机器人导航及增强现实等领域获取高精度三维信息的基石。然而，面对非受控开放场景中纹理特征的复杂性、场景分布的多样性以及观测条件的不可控性，传统方法与现有深度学习模型在特征表示、跨域泛化及系统鲁棒性方面仍面临严峻挑战。

本文紧扣“高精度、强泛化、抗干扰”这一核心目标，针对立体几何深度估计中存在的视觉退化场景匹配难导致精度低、未见场景泛化性能差、非理想观测条件下抗噪能力弱这三大瓶颈问题，展开了系统深入的研究。本文构建了一套由特征表达增强、先验增强泛化到几何融合抗噪构成的递进式深度估计理论框架，并将研究成果成功赋能于视觉里程计应用中。

6.1 本文主要内容及结论

本文围绕基于立体视觉深度估计及其应用，按照“基础特征表示优化（精度）→跨域泛化性能提升（广度）→非理想条件鲁棒增强（稳定性）→定位应用转化（下游应用）”的逻辑主线，层层递进地开展了相关研究工作。主要研究内容及得出的结论归纳如下：

6.1.1 视觉退化场景下区域分治的高精度立体匹配方法

针对视觉退化场景下匹配难导致精度低的问题，本文深入分析了卷积神经网络与 Transformer 在处理不同频率图像特征时的优劣，基于区域分治和注意力机制的特征增强立体匹配网络（CoAtRSNet）。

（1）本部分主要研究工作

- 提出了一种内容自适应的区域分治策略。不同于传统方法对全图采用均一的处理范式，本研究根据图像内容的频率特性与几何结构，将图像划分为边缘区域与平滑区域，并设计了差异化的特征提取与聚合路径。

- 设计了局部注意力与卷积神经网络协同的混合架构。在边缘区域，引入局部注意力机制，利用其高频保持特性捕捉细微的几何结构，解决了卷积操作导致的边缘模糊问题；在平滑区域，利用多尺度金字塔池化高效聚合上下文信息，提升了弱纹理区域的匹配多义性。
- 构建了视差维度的全局注意力代价聚合模块。突破了传统 3D 卷积在代价体聚合时感受野受限的局限性，通过沿视差方向的全局交互，显著提升了算法在重复纹理与遮挡区域的判别能力。

(2) 本部分获取的结果与结论

- 实验结果表明，该方法在 Scene Flow^[69]、KITTI^[83] 等基准数据集上的边缘误差与全图异常值率均显著低于现有 SOTA 方法。特别是在细长物体（如栏杆、树枝）的深度恢复上，保持了极高的锐度与连续性。
- 研究结论显示，区域分治的特征表示策略能有效打破单一网络架构在处理复杂场景时的局限性。局部注意力机制对于高频信息的敏感性，使其成为解决物体边界过度平滑问题的关键；而全局上下文信息的引入，则显著提升了病态区域匹配歧义的性能。

6.1.2 跨域场景下单目-双目协同迭代的高泛化立体匹配方法

针对纯几何立体匹配算法高度依赖光度一致性，导致在弱纹理、反光等病态区域失效，以及深度学习模型在未见场景中因域偏差导致泛化性能急剧下降的瓶颈，本文提出了一种基于单目-双目双分支迭代优化的立体匹配网络（MonSter）。

(1) 本部分主要研究工作

- 揭示了单目深度与立体匹配的深层互补机制。本文深入剖析了两种模态的内在特性：单目深度估计具备强大的语义结构感知能力，对纹理依赖低，但缺乏绝对物理尺度；而立体匹配具备精确的度量恢复能力，但对纹理质量依赖极高。并且单目深度估计具有海量训练数据，相比双目立体匹配具有更强的泛化性能，因此本文提出了一种基于互补特性的融合新范式。
- 构建了单目-双目双分支交互优化架构。为了实现双分支深度的充分融合，本文设计了双向引导机制：立体引导对齐模块，利用高置信度的立体几何线索动态修正单目深度的尺度因子与偏移量，使其具备物理尺度；单目引导微调模块，将校正后具备精确度量的单目深度引入立体匹配网络，在立体匹配失效的区域

提供强有力的结构引导，约束优化收敛。

(2) 本部分获取的结果与结论

- 显著提升了零样本泛化性能。实验结果表明，该方法不仅有效改善了弱纹理、遮挡等病态区域的匹配难题，更在 Middlebury、ETH3D 等跨域数据集的零样本评估中展现出优异性能。该架构成功实现了算法从特定场景模型向通用场景模型的跨越，证明了引入单目结构先验能够大幅提升立体匹配的泛化性能。
- 验证了双分支协同优化的有效性。研究结论证实，通过显式的几何对齐与隐式的结构引导，可以有效克服单目估计的尺度模糊与立体匹配的纹理依赖。MonSter 架构证明了在缺乏大规模双目真值数据的情况下，仅利用现有的单目大模型先验即可大幅提升立体匹配系统在复杂开放场景中的适应能力。

6.1.3 非理想观测下单目-多视角融合的抗噪深度估计方法

针对多视角立体视觉深度估计算法在非理想观测条件下抗噪能力弱，当存在相机参数噪声或不满足静态刚体假设时深度估计精度崩塌的问题，本文第四章提出了一种基于单目-多视角自适应融合的深度估计网络（AFNet）。

(1) 本部分主要研究工作

- 提出了一种单目与多视角深度的自适应融合机制。针对实际应用中相机内外参往往伴随噪声导致立体几何约束失效的痛点，本研究构建了一个双分支融合网络。该网络并不强行依赖几何约束，而是根据当前的观测条件，动态整合单目分支的语义结构优势与多视角分支的几何精度优势。
- 设计了基于重投影一致性的置信度评估模块。通过计算多视角特征在重投影过程中的一致性误差，实时生成像素级的几何置信度图。该置信度图充当门控角色，能够精确感知几何约束在当前区域的可靠性。使得在参数准确且纹理丰富区域，系统主要利用多视角几何恢复高精度细节；而在参数噪声较大、存在动态物体干扰或弱纹理区域，系统通过置信度引导，自适应切换至鲁棒的单目深度分支。这一机制有效克服了主流 MVS 方法对参数精度的过度依赖。

(2) 本部分获取的结果与结论

- 实验结果表明，该方法在 DDAD^[178]、KITTI Eigen split^[177] 等数据集上，展现了显著优于纯多视角方法和纯单目方法的精度。说明在理想观测条件下，AFNet 也具有了最佳性能。而在非理想观测条件下，特别是在人为引入不同等级的位

姿噪声测试中, AFNet 仍能保持深度估计的高精度和高鲁棒。

- 研究结论显示, 基于置信度与多视角一致性的几何约束是提升系统抗噪能力的关键。通过引入单目深度作为鲁棒性兜底, 并利用自适应融合机制动态分配权重, 可以有效解耦深度估计精度对相机位姿精度的强依赖关系, 实现了系统在非理想观测条件下的鲁棒感知。

6.1.4 深度先验赋能的视觉里程计

针对深度估计的下游应用赋能, 以及主流单目视觉里程计存在的尺度缺失与泛化性能差的问题, 本文第五章提出了一种基于深度先验增强与几何迭代的视觉里程计框架 (RoMeO)。

(1) 本部分主要研究工作

- 提出了一种深度先验增强与几何迭代的视觉里程计框架。该方法将高质量度量深度和多视角几何先验, 显式地引入到里程计的前端初始化与后端的光束法平差法中, 直接解决了单目 VO 固有的尺度模糊问题, 大幅提升了定位精度。
- 研发了噪声增强训练策略与自适应深度门控机制。为了应对先验深度本身可能存在的误差, 本研究在训练阶段设计了针对性的噪声注入策略, 提高了网络对低质量输入的容忍度。同时, 设计了自适应门控机制, 能够在线判别不可靠的深度先验, 防止错误先验导致位姿负优化, 提升系统鲁棒性。
- 构建了基于迭代光流的位姿估计算法。结合深度先验与迭代光流的优势, 通过在特征金字塔上的多层级迭代, 实现了对相机位姿的精细化求解, 即使在剧烈运动下也能保证定位精度。

(2) 本部分获取的结果与结论

- 在 KITTI Odometry^[83] 等真实采集的剧烈运动场景数据测试中, 该方法的绝对轨迹误差和相对轨迹误差均优于现有的学习型视觉里程计 (如 DROID-SLAM^[154]) 及传统视觉里程计算法。特别是在动态物体密集和纹理缺失的复杂场景下, 仍能保持稳健的定位与建图。
- 研究结论表明, 深度估计与视觉里程计并非单向依赖, 而是互为支撑。高质量的度量深度先验能显著提升 VO 的初始化质量与尺度一致性, 而位姿求解模块利用输出位姿通过 MVS 也能进一步优化深度质量, 进而形成正向循环的联合优化。

6.2 本文主要创新点

通过对立体几何视觉深度估计任务的深入剖析与系统研究，本文在特征表示、泛化机制、抗噪性能及系统应用四个层面取得了若干创新性成果，主要概括为以下四点：

1. 提出了基于“频域-空间”双域耦合的区域分治立体匹配特征表示理论

针对传统卷积网络在处理高频边缘与低频平滑区域时的性能悖论，本文创新性地提出了一种内容自适应的区域分治特征表示框架。该创新点的核心在于突破了单一算子处理全图的固有思维定式，首次从频域与空间域耦合的视角，构建了“边缘区域-局部注意力”与“平滑区域-多尺度卷积”的异构处理范式。相比于现有的全局注意力方法（如 STTR^[51]）或纯 CNN 方法（如 PSMNet^[7]），该理论的优势在于：既保留了大范围感受野赖以消除歧义的能力，又利用局部注意力机制完美恢复了亚像素级的边缘细节。这为解决普遍存在的边缘区域与平滑区域之间的矛盾提供了新的解决思路，显著提升了算法在视觉退化场景下的特征表征能力。

2. 建立了单目深度-双目立体匹配迭代优化的新范式

针对深度学习立体匹配模型在跨域场景下泛化能力差的痛点，本文创新性地建立了 MonSter 统一立体匹配与单目深度估计的迭代优化框架。不同于传统方法仅将单目特征作为辅助通道进行简单拼接，本研究通过构建双分支迭代优化的结构充分结合单目深度和立体视觉的优势，成功搭建了数据驱动的语义理解与物理驱动的几何测量之间的桥梁。它证明了在缺乏真实三维标签的开放世界中，可以利用大规模预训练的单目基础模型来赋予立体匹配模型泛化能力。MonSter 极大地降低了算法对特定场景训练数据的依赖，跨域泛化性能强，具有重要的工程应用价值。

3. 提出了单目与多视角自适应融合的鲁棒深度估计方法

针对实际应用中相机标定误差、机械振动、位姿漂移以及不满足非静态刚体假设导致立体几何约束失效的非理想观测难题，本文设计了基于重投影一致性的自适应融合机制。研究表明，通过实时评估几何约束的可靠性并动态融合单目深度与多视角深度，可以使系统在相机参数精确时享受几何高精度，在参数有噪时自动回退至单目深度。该研究结论揭示了软几何约束的重要性，即在非理想观测条件下，不再强求严格的极线对齐，而是通过置信度融合实现系统的抗噪性能提升，极大地提升了算法在真实环境中的鲁棒性。

4. 实现了基于深度先验赋能的鲁棒单目视觉里程计

针对单目视觉里程计固有的尺度缺失及跨域泛化问题, 本文提出了 RoMeO 框架, 将前述研究中获取的高质量度量深度和多视角几何先验深度植入到里程计的前端初始化与后端优化中。实验结果证实, 引入绝对深度先验可以大幅降低单目 VO 的绝对轨迹误差, 并实现与真实世界 1:1 的绝对尺度定位。这一结论表明, 高质量的深度感知是高精度定位的先决条件, 通过抗噪训练和自适应门控策略, 可以有效解决深度感知噪声对定位系统的负优化, 打通了从感知到定位的应用转化。

6.3 展望

尽管本文在基于立体几何的视觉深度估计及其应用方面取得了一定的研究成果, 解决了一些制约行业发展的关键技术瓶颈, 但受限于研究时间、计算资源及当前理论发展的阶段性, 本研究仍存在一些不足之处。随着具身智能与空间计算技术的飞速发展, 未来的研究工作可从以下几个维度进一步深化与拓展:

1. 复杂极端环境下的多模态融合感知: 目前的立体匹配算法虽然通过单目先验缓解了弱纹理问题, 但在面对暴雨、大雾、强逆光或全黑夜间等极端光学环境时, 纯视觉方案仍存在物理极限。未来的研究应跳出纯视觉的范畴, 探索视觉与激光雷达、红外热成像或事件相机的多模态融合方案。通过引入其他模态的互补信息 (如事件相机的高动态范围、红外相机的透雾能力), 构建全天候、全天时的鲁棒感知系统, 进一步提升算法在开放世界中的生存能力。

2. 统一的时空一致性建模: 目前的研究主要聚焦于单帧或短时序的深度估计, 对视频序列中长时序的时间一致性挖掘尚显不足。未来可以探索利用视频中的时序相关性, 引入循环神经网络或时空 Transformer, 构建统一的时空立体匹配框架。这不仅有助于消除单帧估计的闪烁问题, 还能利用历史信息进一步提升在动态遮挡区域的估计稳定性。

3. 迈向通用物理世界大模型: 当前的深度估计模型大多仍属于判别式模型, 即从图像到深度的映射。随着生成式人工智能的爆发, 如何利用视频生成模型所蕴含的物理规律来反哺三维视觉任务, 是一个极具潜力的方向。未来的研究可以尝试构建通用的物理世界模型, 利用海量未标注视频数据进行自监督学习, 使模型不仅能估计深度, 还能预测场景的未来演变。通过将几何感知能力融入世界模型, 最终实

现具备人类水平空间认知能力的通用视觉系统，为通用人工智能的落地贡献力量。

综上所述，立体几何视觉深度估计是一个充满挑战但也极具生命力的研究领域。本文的研究仅是漫漫征途中的一步，期待未来的研究者能在此基础上，不断突破感知边界，让智能机器看清、看懂这个精彩纷呈的三维世界。

致 谢

时光荏苒，白驹过隙。从初入喻家山下的青涩少年，到如今即将完成博士学业，我在华中科技大学度过了整整十个春秋。这十年，是我人生中最宝贵的青春年华，也是我从懵懂向成熟蜕变的关键阶段。回首漫漫求学路，这一路走来，并非我独自前行，而是无数师长、同窗与亲友的关爱与托举，才让我得以在其间坚定跋涉。值此论文付梓之际，心中涌动着无限的感激，谨以此文，向所有给予我指导、帮助与陪伴的人们致以最崇高的敬意。

饮水思源，首先要致以最深切谢意的是我的恩师杨欣教授。早在本科三年级，我有幸进入实验室，是杨老师引领我推开了科研的大门。从最初的选题方向到最终的论文成稿，杨老师始终给予我最专业的指导和最真诚的建议。治学严谨、精益求精是杨老师的学术底色，我至今难忘那一篇篇被老师密密麻麻批注修改过的论文草稿。在我科研生涯遭遇低谷、论文惨遭“reject”而心灰意冷时，是杨老师并没有责备，而是耐心地陪我一遍遍分析审稿意见，鼓励我不要气馁，帮我重新梳理逻辑、打磨实验，直到最终收获“accept”。杨老师不仅教会了我如何做学问，更以其宽厚的长者风范教会了我面对挫折的勇气与坚韧，这份师恩，学生将铭记终生。

特别感谢尹炜博士和蔡志鹏博士。在我前往大疆（DJI）和英特尔（Intel）实习期间，是你们不仅在业务上给予了无私的帮助，更让我快速适应了高强度的企业研发节奏。在与你们的共事中，我学会了如何高效利用资源、如何以工业界的视角审视学术问题，更掌握了业界最前沿的技术技能。这段宝贵的“产研结合”经历，极大地拓宽了我的视野，为我后续研究成果的转化与落地打下了最坚实的基础。

同门情谊，弥足珍贵。特别感谢袁子康、贾奇增、陈靖宇、蒲粤川四位师兄，你们是我科研道路上最早的“领路人”。回想我还是一个科研“小白”时，是你们手把手地教我配置环境、指导我如何跑通代码、如何设计消融实验、如何分析 Bug。从大三起，我的每一步成长背后都有你们的身影。特别是袁子康师兄，不仅在学术上倾囊相授，在生活中更给予我兄长般的关怀。在我读博期间感到迷茫和气馁的时刻，是你一次次的加油打气，让我重拾信心，坚定地走完了这段艰难的旅程。

科研绝非一座孤岛，我深知这一路走来的成果，离不开团队的智慧与协作。特

别感谢与我并肩作战的师弟师妹及合作伙伴们：许刚伟、冯淼杰、张肇星、刘粤诚、廖文静、王禹舟、刘龙亮、徐其谦等。在与你们共同攻克一个个技术难关、调试一行行代码的过程中，我不仅分享了经验，更在思维的激烈碰撞中从你们身上学到了许多新颖的视角与知识。是你们的辛勤付出与高效协作，极大地提升了我们团队的科研产出效率；也是你们的朝气与活力，让枯燥的实验室生活充满了欢声笑语。看着实验室团队在我们的共同努力下日益壮大，我深感自豪。愿你们在未来的科研道路上青出于蓝，继续书写实验室的辉煌。

最后，我要将心中最柔软的谢意留给我的至亲和我的女朋友。感谢我的父母。二十余载养育之恩，昊天罔极。虽然你们可能并不完全理解我博士课题的艰深，但你们永远是最坚实的后盾。是你们在背后的默默支持与无私奉献，为我挡住了生活的风雨，让我能心无旁骛地投身于学业。每当我疲惫时，家永远是我温暖的避风港，是你们的鼓励让我有了坚持到底的底气。感谢我的女朋友。科研之路漫长且时常伴随着孤独与枯燥，因为有你的陪伴，这段旅程才有了色彩与温度。在我论文被拒、实验受挫的低谷时刻，是你的陪伴让我能够快速走出困境；在我因压力而焦虑时，是你的包容与理解抚平了我的情绪。你是我生活中的光，感谢你愿与我共担风雨，共赴未来。

十年华科路，一生喻园情。博士学位的授予并非终点，而是新征程的起点。带着师长的教诲与同窗的情谊，我将怀揣感恩之心，在未来的道路上脚踏实地，砥砺前行。

参考文献

- [1] 李晓理, 张博, 王康, 余攀. 人工智能的发展及应用. 北京工业大学学报, 2020, 46(6):583–590
- [2] J. Aulinas, Y. Petillot, J. Salvi, X. Llado. The SLAM problem: a survey. Artificial Intelligence Research and Development, 2008, 184:363–371
- [3] 陶于金, 李沛峰. 无人机系统发展与关键技术综述. 航空制造技术, 2014, 464(20):34–39
- [4] 杨明. 无人自动驾驶车辆研究综述与展望. 哈尔滨工业大学学报, 2006, 38(8):1259–1262
- [5] 林惊, 杨珂, 王涌天, 刘越. 移动增强现实系统的关键技术研究. 中国图象图形学报, 2009, 14(3):560–564
- [6] 李清泉, 李必军, 陈静. 激光雷达测量技术及其应用研究. 武汉大学学报, 2000, 25(5):387–392
- [7] J. Chang, Y. Chen. Pyramid stereo matching network. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:5410–5418
- [8] G. Xu, J. Cheng, P. Guo, X. Yang. Attention Concatenation Volume for Accurate and Efficient Stereo Matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:12981–12990
- [9] L. Lipson, Z. Teed, J. Deng. Raft-stereo: Multilevel recurrent field transforms for stereo matching. in: International Conference on 3D Vision. IEEE, 2021:218–227
- [10] G. Xu, X. Wang, X. Ding, X. Yang. Iterative geometry encoding volume for stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023:21919–21928
- [11] Y. Yao, Z. Luo, S. Li, T. Fang, L. Quan. Mvsnet: Depth inference for unstructured multi-view stereo. in: Proceedings of the European Conference on Computer Vision, 2018:767–783
- [12] K. Luo, T. Guan, L. Ju, H. Huang, Y. Luo. P-mvsnet: Learning patch-wise matching confidence aggregation for multi-view stereo. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019:10452–10461

- [13] X. Ma, Y. Gong, Q. Wang, J. Huang, L. Chen, F. Yu. Epp-mvsnet: Epipolar-assembling based depth prediction for multi-view stereo. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:5732–5740
- [14] X. Gu, Z. Fan, S. Zhu, Z. Dai, F. Tan, P. Tan. Cascade cost volume for high-resolution multi-view stereo and stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:2495–2504
- [15] Z. Yang, Z. Ren, Q. Shan, Q. Huang. Mvs2d: Efficient multi-view stereo via attention-driven 2d convolutions. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:8574–8584
- [16] C. Cao, X. Ren, Y. Fu. MVSFormer: Multi-view stereo by learning robust image features and temperature-based depth. arXiv preprint arXiv:2208.02541, 2022
- [17] D. Eigen, C. Puhrsch, R. Fergus. Depth map prediction from a single image using a multi-scale deep network. Advances in Neural Information Processing Systems, 2014, 27:2366–2374
- [18] V. Guizilini, I. Vasiljevic, D. Chen, R. Ambrus, A. Gaidon. Towards zero-shot scale-aware monocular depth estimation. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023:9233–9243
- [19] R. Ranftl, A. Bochkovskiy, V. Koltun. Vision transformers for dense prediction. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:12179–12188
- [20] H. Fu, M. Gong, C. Wang, K. Batmanghelich, D. Tao. Deep ordinal regression network for monocular depth estimation. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:2002–2011
- [21] S. F. Bhat, I. Alhashim, P. Wonka. Adabins: Depth estimation using adaptive bins. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:4009–4018
- [22] S. F. Bhat, R. Birkel, D. Wofk, P. Wonka, M. Müller. Zoedepth: Zero-shot transfer by combining relative and metric depth. arXiv preprint arXiv:2302.12288, 2023
- [23] R. Birkel, D. Wofk, M. Müller. Midas v3. 1—a model zoo for robust monocular relative depth estimation. arXiv preprint arXiv:2307.14460, 2023
- [24] W. Yin, C. Zhang, H. Chen, Z. Cai, G. Yu, K. Wang, et al. Metric3d: Towards zero-shot metric 3d prediction from a single image. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023:9043–9053
- [25] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, et al. Depth anything v2. Advances in Neural Information Processing Systems, 2024, 37:21875–21911

- [26] X. Guo, K. Yang, W. Yang, X. Wang, H. Li. Group-wise correlation stereo network. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:3273–3282
- [27] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, et al. Attention is all you need. Advances in Neural Information Processing Systems, 2017, 30:5998–6008
- [28] G. Huang, Z. Liu, L. Van Der Maaten, K. Q. Weinberger. Densely connected convolutional networks. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:4700–4708
- [29] S. Ji, W. Xu, M. Yang, K. Yu. 3D convolutional neural networks for human action recognition. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 35(1):221–231
- [30] D. Maturana, S. Scherer. Voxnet: A 3d convolutional neural network for real-time object recognition. in: IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2015:922–928
- [31] Q. Wang, B. Wu, P. Zhu, P. Li, W. Zuo, Q. Hu. ECA-Net: Efficient channel attention for deep convolutional neural networks. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:11534–11542
- [32] Y. Zhang, K. Li, K. Li, B. Zhong, Y. Fu. Residual non-local attention networks for image restoration. arXiv preprint arXiv:1903.10082, 2019
- [33] Z. Qin, P. Zhang, F. Wu, X. Li. Fcanet: Frequency channel attention networks. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:783–792
- [34] P. Shaw, J. Uszkoreit, A. Vaswani. Self-attention with relative position representations. arXiv preprint arXiv:1803.02155, 2018
- [35] T. Schops, J. L. Schonberger, S. Galliani, T. Sattler, K. Schindler, M. Pollefeys, et al. A multi-view stereo benchmark with high-resolution images and multi-camera videos. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:3260–3269
- [36] D. Scharstein, H. Hirschmuller, Y. Kitajima, G. Krathwohl, N. Nesić, X. Wang, et al. High-resolution stereo datasets with subpixel-accurate ground truth. in: German Conference on Pattern Recognition. Springer, 2014:31–42
- [37] J. Engel, J. Sturm, D. Cremers. Semi-dense visual odometry for a monocular camera. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2013:1449–1456

- [38] J. Engel, T. Schops, D. Cremers. LSD-SLAM: Large-scale direct monocular SLAM. in: Proceedings of the European Conference on Computer Vision, 2014:834–849
- [39] J. Engel, V. Koltun, D. Cremers. Direct sparse odometry. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(3):611–625
- [40] A. R. Mur, J. M. Montiel, J. D. Tardos. ORB-SLAM: A versatile and accurate monocular SLAM system. IEEE Transactions on Robotics, 2015, 31(5):1147–1163
- [41] T. Qin, P. Li, S. Shen. Vins-mono: A robust and versatile monocular visual-inertial state estimator. IEEE Transactions on Robotics, 2018, 34(4):1004–1020
- [42] Q. Yang. A non-local cost aggregation method for stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2012:1402–1409
- [43] H. Hirschmuller. Accurate and efficient stereo processing by semi-global matching and mutual information. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2005:807–814
- [44] X. Mei, X. Sun, W. Dong, H. Wang, X. Zhang. Segment-tree based cost aggregation for stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2013:313–320
- [45] J. Cheng, L. Liu, G. Xu, X. Wang, Z. Zhang, Y. Deng, et al. Monster: Marry monodepth to stereo unleashes power. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025:6273–6282
- [46] J. Cheng, W. Liao, Z. Cai, L. Liu, G. Xu, X. Wang, et al. MonSter++: Unified Stereo Matching, Multi-view Stereo, and Real-time Stereo with Monodepth Priors. arXiv preprint arXiv:2501.08643, 2025
- [47] 韩慧妍. 基于双目立体视觉的三维模型重建方法研究. [博士学位论文]. 太原: 中北大学, 2014
- [48] 马源. 基于双目立体视觉的深度感知技术研究. [博士学位论文]. 北京: 北京理工大学, 2015
- [49] 张展. 基于双目视觉的三维重建关键技术研究. [博士学位论文]. 沈阳: 中国科学院沈阳计算技术研究所, 2019
- [50] X. Wang, G. Xu, H. Jia, X. Yang. Selective-stereo: Adaptive frequency information selection for stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:19701–19710

- [51] Z. Li, X. Liu, N. Drenkow, A. Ding, F. X. Creighton, R. H. Taylor, et al. Revisiting stereo depth estimation from a sequence-to-sequence perspective with transformers. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:6197–6206
- [52] P. Weinzaepfel, T. Lucas, V. Leroy, Y. Cabon, V. Arora, R. Bregier, et al. Croco v2: Improved cross-view completion pre-training for stereo matching and optical flow. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023:17969–17980
- [53] J. Min, Y. Jeon, J. Kim, M. Choi. S2M2: Scalable Stereo Matching Model for Reliable Depth Estimation. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2025:26729–26739
- [54] D. Jia, P. Cai, Q. Wang, N. Yang. A transformer-based architecture for high-resolution stereo matching. IEEE Transactions on Computational Imaging, 2024, 10:83–92
- [55] W. Gaoping, L. Xun, J. Xuefang, L. Zhewen, W. Wenjie. STransMNet: a stereo matching method with swin transformer fusion. Opto-Electronic Engineering, 2025, 50(4):220246–1
- [56] D. Scharstein, R. Szeliski. A taxonomy and evaluation of dense two-frame stereo correspondence algorithms. International Journal of Computer Vision, 2002, 47(1):7–42
- [57] R. Zabih, J. Woodfill. Non-parametric local transforms for computing visual correspondence. in: Proceedings of the European Conference on Computer Vision, 1994:151–158
- [58] D. G. Lowe. Distinctive image features from scale-invariant keypoints. International Journal of Computer Vision, 2004, 60(2):91–110
- [59] E. Tola, V. Lepetit, P. Fua. Daisy: An efficient dense descriptor applied to wide-baseline stereo. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2009, 32(5):815–830
- [60] J. Cheng, W. Yin, K. Wang, X. Chen, S. Wang, X. Yang. Adaptive fusion of single-view and multi-view depth for autonomous driving. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:10138–10147
- [61] X. Song, X. Zhao, L. Fang, H. Hu, Y. Yu. Edgestereo: An effective multi-task learning network for stereo matching and edge detection. International Journal of Computer Vision, 2020, 128(4):910–930
- [62] A. Sherstinsky. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. Physica D: Nonlinear Phenomena, 2020, 404:132306

- [63] Y. Yu, X. Si, C. Hu, J. Zhang. A review of recurrent neural networks: LSTM cells and network architectures. *Neural Computation*, 2019, 31(7):1235–1270
- [64] K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014
- [65] K. Zhang, J. Lu, G. Lafruit. Cross-based local stereo matching using orthogonal integral images. *IEEE Transactions on Circuits and Systems for Video Technology*, 2009, 19(7):1073–1079
- [66] J. Sun, N. Zheng, H. Shum. Stereo matching using belief propagation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2003, 25(7):787–800
- [67] A. Klaus, M. Sormann, K. Karner. Segment-based stereo matching using belief propagation and a self-adapting dissimilarity measure. in: *International Conference on Pattern Recognition*. IEEE, 2006:15–18
- [68] V. Kolmogorov, R. Zabih. Computing visual correspondence with occlusions using graph cuts. in: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2001:508–515
- [69] N. Mayer, E. Ilg, P. Hausser, P. Fischer, D. Cremers, A. Dosovitskiy, et al. A large dataset to train convolutional networks for disparity, optical flow, and scene flow estimation. in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2016:4040–4048
- [70] A. Kendall, H. Martirosyan, S. Dasgupta, P. Henry, R. Kennedy, A. Bachrach, et al. End-to-end learning of geometry and context for deep stereo regression. in: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2017:66–75
- [71] K. He, X. Zhang, S. Ren, J. Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2015, 37(9):1904–1916
- [72] H. Zhao, J. Shi, X. Qi, X. Wang, J. Jia. Pyramid scene parsing network. in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2017:2881–2890
- [73] A. Newell, K. Yang, J. Deng. Stacked hourglass networks for human pose estimation. in: *Proceedings of the European Conference on Computer Vision*, 2016:483–499
- [74] J. Yang, Q. Liu, K. Zhang. Stacked hourglass network for robust facial landmark localisation. in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2017:79–87

- [75] F. Zhang, V. Prisacariu, R. Yang, P. H. Torr. Ga-net: Guided aggregation net for end-to-end stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:185–194
- [76] Z. Shen, Y. Dai, Z. Rao. CFNet: Cascade and Fused Cost Volume for Robust Stereo Matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:13906–13915
- [77] G. Yang, H. Zhao, J. Shi, Z. Deng, J. Jia. Segstereo: Exploiting semantic information for disparity estimation. in: Proceedings of the European Conference on Computer Vision, 2018:636–651
- [78] Z. Teed, J. Deng. Raft: Recurrent all-pairs field transforms for optical flow. in: Proceedings of the European Conference on Computer Vision, 2020:402–419
- [79] D. Jia, K. Wang, S. Luo, T. Liu, Y. Liu. BRAFT: Recurrent all-pairs field transforms for optical flow based on correlation blocks. IEEE Signal Processing Letters, 2021, 28:1575–1579
- [80] H. Xu, D. Hao, S. Chen. Video-based vehicle speed measurement using recurrent all-pairs field transforms for optical flow. IEEE Sensors Journal, 2024, 24(14):22945–22957
- [81] J. Li, P. Wang, P. Xiong, T. Cai, Z. Yan, L. Yang, et al. Practical stereo matching via cascaded recurrent network with adaptive correlation. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:16263–16272
- [82] J. Dai, H. Qi, Y. Xiong, Y. Li, G. Zhang, H. Hu, et al. Deformable convolutional networks. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2017:764–773
- [83] A. Geiger, P. Lenz, R. Urtasun. Are we ready for autonomous driving? the kitti vision benchmark suite. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2012:3354–3361
- [84] M. Menze, A. Geiger. Object scene flow for autonomous vehicles. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2015:3061–3070
- [85] F. Yu, V. Koltun. Multi-scale context aggregation by dilated convolutions. arXiv preprint arXiv:1511.07122, 2015
- [86] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, et al. Swin transformer: Hierarchical vision transformer using shifted windows. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:10012–10022

- [87] Z. Tu, H. Talebi, H. Zhang, F. Yang, P. Milanfar, A. Bovik, et al. Maxvit: Multi-axis vision transformer. in: Proceedings of the European Conference on Computer Vision, 2022:459–479
- [88] C. Chen, Q. Fan, R. Panda. Crossvit: Cross-attention multi-scale vision transformer for image classification. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:357–366
- [89] Z. Huang, X. Wang, L. Huang, C. Huang, Y. Wei, W. Liu. Ccnet: Criss-cross attention for semantic segmentation. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019:603–612
- [90] H. Lin, X. Cheng, X. Wu, D. Shen. Cat: Cross attention in vision transformer. in: IEEE International Conference on Multimedia and Expo. IEEE, 2022:1–6
- [91] Devlin, C. Mingwei, K. Lee, K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. in: Proceedings of Naacl-HLT. Minneapolis, Minnesota, 2019:4171–4186
- [92] K. He, X. Chen, S. Xie, Y. Li, P. Dollar, R. Girshick. Masked autoencoders are scalable vision learners. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:16000–16009
- [93] P. Weinzaepfel, V. Leroy, T. Lucas, R. Bregier, Y. Cabon, V. Arora, et al. Croco: Self-supervised pre-training for 3d vision tasks by cross-view completion. Advances in Neural Information Processing Systems, 2022, 35:3502–3516
- [94] X. Su, S. Liu, R. Li, Z. Bing, A. Knoll. Efficient Stereo Matching Using Swin Transformer and Multilevel Feature Consistency in Autonomous Mobile Systems. IEEE Transactions on Industrial Informatics, 2024, 20(5):7957–7965
- [95] J. Zhang, L. Huang, X. Bai, J. Zheng, L. Gu, E. Hancock. Exploring the usage of pre-trained features for stereo matching. International Journal of Computer Vision, 2024, 132(10):4305–4326
- [96] M. Ji, J. Gall, H. Zheng, Y. Liu, L. Fang. Surfacenet: An end-to-end 3d neural network for multiview stereopsis. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2017:2307–2315
- [97] A. Kar, C. Hane, J. Malik. Learning a multi-view stereo machine. Advances in Neural Information Processing Systems, 2017, 30:365–374
- [98] R. Peng, R. Wang, Z. Wang, Y. Lai, R. Wang. Rethinking depth estimation for multi-view stereo: A unified representation. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:8645–8654

- [99] X. Long, L. Liu, W. Li, C. Theobalt, W. Wang. Multi-view depth estimation using epipolar spatio-temporal networks. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021
- [100] Y. Yao, Z. Luo, S. Li, T. Shen, T. Fang, L. Quan. Recurrent mvsnets for high-resolution multi-view stereo depth inference. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:5525–5534
- [101] J. Yan, Z. Wei, H. Yi, M. Ding, R. Zhang, Y. Chen, et al. Dense hybrid recurrent multi-view stereo net with dynamic consistency checking. in: Proceedings of the European Conference on Computer Vision, 2020:674–689
- [102] C. Cai, P. Ji, Q. Yan, Y. Xu. Riav-mvs: Recurrent-indexing an asymmetric volume for multi-view stereo. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023:919–928
- [103] F. Wang, S. Galliani, C. Vogel, M. Pollefeys. IterMVS: Iterative Probability Estimation for Efficient Multi-View Stereo. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:8606–8615
- [104] J. Yang, W. Mao, J. M. Alvarez, M. Liu. Cost volume pyramid based depth inference for multi-view stereo. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:4877–4886
- [105] S. Cheng, Z. Xu, S. Zhu, Z. Li, L. E. Li, R. Ramamoorthi, et al. Deep stereo using adaptive thin volume representation with uncertainty awareness. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:2524–2534
- [106] V. K. Vats, S. Joshi, D. J. Crandall, M. A. Reza, S.-h. Jung. GC-MVSNet: Multi-view, multi-scale, geometrically-consistent multi-view stereo. in: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2024:3242–3252
- [107] S. Wang, X. Ding, Y. Mao, Y. Dai. ETV-MVS: Robust Visibility-Aware Multi-View Stereo with Epipolar Line-Based Transformer. Big Data Mining and Analytics, 2025, 8(3):520–533
- [108] S. Wang, H. Jiang, L. Xiang. Ct-mvsnet: Efficient multi-view stereo with cross-scale transformer. in: International Conference on Multimedia Modeling. Springer, 2024:394–408
- [109] Z. Wei, Q. Zhu, C. Min, Y. Chen, G. Wang. Aa-rmvsnet: Adaptive aggregation recurrent multi-view stereo network. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021:6187–6196

- [110] S. Khan, M. Naseer, M. Hayat, S. W. Zamir, F. S. Khan, M. Shah. Transformers in vision: A survey. *ACM Computing Surveys*, 2022, 54(10s):1–41
- [111] Y. Ding, W. Yuan, Q. Zhu, H. Zhang, X. Liu, Y. Wang, et al. Transmvsnet: Global context-aware multi-view stereo network with transformers. in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022:8585–8594
- [112] X. Wang, Z. Zhu, G. Huang, F. Qin, Y. Ye, Y. He, et al. MVSTER: Epipolar transformer for efficient multi-view stereo. in: *Proceedings of the European Conference on Computer Vision*, 2022:573–591
- [113] J. Liao, Y. Ding, Y. Shavit, D. Huang, S. Ren, J. Guo, et al. WT-MVSNet: Window-based transformers for multi-view stereo. *arXiv*. arXiv preprint arXiv:2205.14319, 2022
- [114] J. Zhu, B. Peng, W. Li, H. Shen, Z. Zhang, J. Lei. Multi-view stereo with transformer. *arXiv preprint arXiv:2112.00336*, 2021
- [115] W. Chen, H. Xu, Z. Zhou, Y. Liu, B. Sun, W. Kang, et al. CostFormer: Cost transformer for cost aggregation in multi-view stereo. *arXiv preprint arXiv:2305.10320*, 2023
- [116] X. Chu, Z. Tian, Y. Wang, B. Zhang, H. Ren, X. Wei, et al. Twins: Revisiting the design of spatial attention in vision transformers. *Advances in Neural Information Processing Systems*, 2021, 34:9355–9366
- [117] C. Cao, X. Ren, Y. Fu. Mvsformer++: Revealing the devil in transformer’s details for multi-view stereo. *arXiv preprint arXiv:2401.11673*, 2024
- [118] H. Aanæs, R. R. Jensen, G. Vogiatzis, E. Tola, A. B. Dahl. Large-scale data for multiple-view stereopsis. *International Journal of Computer Vision*, 2016, 120(2):153–168
- [119] A. Knapitsch, J. Park, Q. Zhou, V. Koltun. Tanks and temples: Benchmarking large-scale scene reconstruction. *ACM Transactions on Graphics*, 2017, 36(4):1–13
- [120] Y. Zhou, K. Han, C. Luo, J. Wang. Svo-pl: Stereo visual odometry with fusion of points and line segments. in: *IEEE International Conference on Mechatronics and Automation*. IEEE, 2018:900–905
- [121] K. Yamaguchi, D. Mcallester, R. Urtasun. Efficient joint segmentation, occlusion labeling, stereo and flow estimation. in: *Proceedings of the European Conference on Computer Vision*, 2014:756–771
- [122] M. Bleyer, C. Rhemann, C. Rother. Patchmatch stereo-stereo matching with slanted support windows. in: *British Machine Vision Conference*, 2011:1–11

- [123] S. Chen, Z. Xiang, C. Qiao, Y. Chen, T. Bai. SGNet: Semantics guided deep stereo matching. in: Proceedings of the Asian Conference on Computer Vision, 2020
- [124] P. L. Dovesi, M. Poggi, L. Andraghetti, M. Marti, H. Kjellstrom, A. Pieropan, et al. Real-time semantic stereo matching. in: IEEE International Conference on Robotics and Automation. IEEE, 2020:10780–10787
- [125] Z. Yuan, J. Cao, Z. Wang, Z. Li. Tsar-mvs: Textureless-aware segmentation and correlative refinement guided multi-view stereo. Pattern Recognition, 2024, 154:110565
- [126] Z. Yuan, C. Liu, F. Shen, Z. Li, J. Luo, T. Mao, et al. MSP-MVS: Multi-granularity segmentation prior guided multi-view stereo. in: Proceedings of the AAAI Conference on Artificial Intelligence, 2025:9753–9762
- [127] H. Xu, Z. Zhou, Y. Qiao, W. Kang, Q. Wu. Self-supervised multi-view stereo via effective co-segmentation and data-augmentation. in: Proceedings of the AAAI Conference on Artificial Intelligence, 2021:3030–3038
- [128] M. Hu, W. Yin, C. Zhang, Z. Cai, X. Long, H. Chen, et al. Metric3d v2: A versatile monocular geometric foundation model for zero-shot metric depth and surface normal estimation. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12):10579-10596
- [129] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, H. Zhao. Depth anything: Unleashing the power of large-scale unlabeled data. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:10371–10381
- [130] L. Piccinelli, Y. H. Yang, C. Sakaridis, M. Segu, S. Li, L. Van Gool, et al. UniDepth: Universal monocular metric depth estimation. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:10106–10116
- [131] L. Piccinelli, C. Sakaridis, Y. Yang, M. Segu, S. Li, W. Abbeloos, et al. Unidepthv2: Universal monocular metric depth estimation made simpler. arXiv preprint arXiv:2502.20110, 2025
- [132] A. Bochkovskii, A. Delaunoy, H. Germain, M. Santos, Y. Zhou, S. R. Richter, et al. Depth pro: Sharp monocular metric depth in less than a second. arXiv preprint arXiv:2410.02073, 2024
- [133] R. Wang, S. Xu, C. Dai, J. Xiang, Y. Deng, X. Tong, et al. Moge: Unlocking accurate monocular geometry estimation for open-domain images with optimal training supervision. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025:5261–5271

- [134] R. Wang, S. Xu, Y. Dong, Y. Deng, J. Xiang, Z. Lv, et al. MoGe-2: Accurate Monocular Geometry with Metric Scale and Sharp Details. arXiv preprint arXiv:2507.02546, 2025
- [135] Y. Luo, J. Ren, M. Lin, J. Pang, W. Sun, H. Li, et al. Single view stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:155–163
- [136] C. Zhang, G. Meng, B. Su, S. Xiang, C. Pan. Monocular contextual constraint for stereo matching with adaptive weights assignment. Image and Vision Computing, 2022, 121:104424
- [137] J. Facil, A. Concha, L. Montesano, J. Civera. Single-view and multi-view depth fusion. IEEE Robotics and Automation Letters, 2017, 2(4):1994–2001
- [138] G. Bae, I. Budvytis, R. Cipolla. Multi-View Depth Estimation by Fusing Single-View Depth Probability with Multi-View Geometry. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022:2842–2851
- [139] J. Jiang, Q. Liu, H. Yu, H. Liu, L. Wang, J. Chen, et al. Monomvsnet: Monocular priors guided multi-view stereo network. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2025:27806–27816
- [140] K. Li, L. Wang, Y. Zhang, K. Xue, S. Zhou, Y. Guo. LoS: Local Structure-Guided Stereo Matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:19746–19756
- [141] B. Wen, M. Trepte, J. Aribido, J. Kautz, O. Gallo, S. Birchfield. Foundationstereo: Zero-shot stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025:5249–5260
- [142] S. Wang, V. Leroy, Y. Cabon, B. Chidlovskii, J. Revaud. Dust3r: Geometric 3d vision made easy. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:20697–20709
- [143] J. Wang, M. Chen, N. Karaev, A. Vedaldi, C. Rupprecht, D. Novotny. Vggt: Visual geometry grounded transformer. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025:5294–5306
- [144] K. Deng, Z. Ti, J. Xu, J. Yang, J. Xie. VGGT-Long: Chunk it, Loop it, Align it—Pushing VGGT’s Limits on Kilometer-scale Long RGB Sequences. arXiv preprint arXiv:2507.16443, 2025
- [145] D. Nister, O. Naroditsky, J. Bergen. Visual odometry. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2004:652–659

- [146] C. Forster, M. Pizzoli, D. Scaramuzza. SVO: Fast semi-direct monocular visual odometry. in: IEEE International Conference on Robotics and Automation. IEEE, 2014:15–22
- [147] S. Wang, R. Clark, H. Wen, N. Trigoni. Deepvo: Towards end-to-end visual odometry with deep recurrent convolutional neural networks. in: IEEE International Conference on Robotics and Automation. IEEE, 2017:2043–2050
- [148] J. Engel, J. Sturm, D. Cremers. Semi-dense visual odometry for a monocular camera. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2013:1449–1456
- [149] G. Klein, D. Murray. Parallel tracking and mapping for small AR workspaces. in: IEEE and ACM International Symposium on Mixed and Augmented Reality. IEEE, 2007:225–234
- [150] R. Murartal, J. D. Tardos. Orb-slam2: An open-source slam system for monocular, stereo, and rgb-d cameras. IEEE Transactions on Robotics, 2017, 33(5):1255–1262
- [151] W. Wang, Y. Hu, S. Scherer. Tartanvo: A generalizable learning-based vo. in: Conference on Robot Learning. PMLR, 2021:1761–1772
- [152] T. Zhou, M. Brown, N. Snavely, D. G. Lowe. Unsupervised learning of depth and ego-motion from video. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:1851–1858
- [153] A. Kendall, M. Grimes, R. Cipolla. Posenet: A convolutional network for real-time 6-dof camera relocalization. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2015:2938–2946
- [154] Z. Teed, J. Deng. Droid-slam: Deep visual slam for monocular, stereo, and rgb-d cameras. Advances in Neural Information Processing Systems, 2021, 34:16558–16569
- [155] Z. Teed, L. Lipson, J. Deng. Deep patch visual odometry. Advances in Neural Information Processing Systems, 2023, 36:39033–39051
- [156] Y. Zhang, F. Tosi, S. Mattoccia, M. Poggi. Go-slam: Global optimization for consistent 3d instant reconstruction. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023:3727–3737
- [157] K. Tateno, F. Tombari, I. Laina, N. Navab. Cnn-slam: Real-time dense monocular slam with learned depth prediction. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:6243–6252

- [158] N. Yang, R. Wang, J. Stuckler, D. Cremers. Deep virtual stereo odometry: Leveraging deep depth prediction for monocular direct sparse odometry. in: Proceedings of the European Conference on Computer Vision, 2018:817–833
- [159] N. Yang, L. Stumberg, R. Wang, D. Cremers. D3vo: Deep depth, deep pose and deep uncertainty for monocular visual odometry. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:1281–1292
- [160] D. P. Kingma. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2014
- [161] A. Seki, M. Pollefeys. Sgm-nets: Semi-global matching with neural networks. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:231–240
- [162] H. Xu, J. Zhang. Aanet: Adaptive aggregation network for efficient stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:1959–1968
- [163] X. Cheng, Y. Zhong, M. Harandi, Y. Dai, X. Chang, H. Li, et al. Hierarchical neural architecture search for deep stereo matching. Advances in Neural Information Processing Systems, 2020, 33:22158–22169
- [164] V. Tankovich, C. Hane, Y. Zhang, A. Kowdle, S. Fanello, S. Bouaziz. Hitnet: Hierarchical iterative tile refinement network for real-time stereo matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:14362–14372
- [165] J. Cheng, G. Xu, P. Guo, X. Yang. Coatsrnet: Fully exploiting convolution and attention for stereo matching by region separation. International Journal of Computer Vision, 2024, 132(1):56–73
- [166] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, et al. Dinov2: Learning robust visual features without supervision. arXiv preprint arXiv:2304.07193, 2023
- [167] G. Yang, X. Song, C. Huang, Z. Deng, J. Shi, B. Zhou. Drivingstereo: A large-scale dataset for stereo matching in autonomous driving scenarios. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:899–908
- [168] I. Loshchilov, F. Hutter. Decoupled weight decay regularization. arXiv preprint arXiv:1711.05101, 2017
- [169] W. Wang, D. Zhu, X. Wang, Y. Hu, Y. Qiu, C. Wang, et al. Tartanair: A dataset to push the limits of visual slam. in: IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2020:4909–4916

- [170] D. J. Butler, J. Wulff, G. B. Stanley, M. J. Black. A naturalistic open source movie for optical flow evaluation. in: Proceedings of the European Conference on Computer Vision, 2012:611–625
- [171] J. Tremblay, T. To, S. Birchfield. Falling things: A synthetic dataset for 3d object detection and pose estimation. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 2018:2038–2041
- [172] W. Bao, W. Wang, Y. Xu, Y. Guo, S. Hong, X. Zhang. Instereo2k: a large real dataset for stereo matching in indoor scenes. Science China Information Sciences, 2020, 63:1–11
- [173] H. Zhao, H. Zhou, Y. Zhang, J. Chen, Y. Yang, Y. Zhao. High-frequency stereo matching network. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023:1327–1336
- [174] T. Guan, C. Wang, Y. Liu. Neural Markov Random Field for Stereo Matching. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024:5459–5469
- [175] X. Wang, H. Yang, G. Xu, J. Cheng, M. Lin, Y. Deng, et al. Zerostereo: Zero-shot stereo matching from single images. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2025:28177–28187
- [176] F. Tosi, A. Tonioni, D. De Gregorio, M. Poggi. NeRF-Supervised Deep Stereo. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023:855–866
- [177] A. Geiger, P. Lenz, C. Stiller, R. Urtasun. Vision meets robotics: The kitti dataset. The International Journal of Robotics Research, 2013, 32(11):1231–1237
- [178] C. Godard, O. Mac Aodha, M. Firman, G. Brostow. Digging into self-supervised monocular depth estimation. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019:3828–3838
- [179] Z. Liu, H. Mao, C. Y. Wu, C. Feichtenhofer, T. Darrell, S. Xie. A convnet for the 2020s. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022
- [180] C. Shu, K. Yu, Z. Duan, K. Yang. Feature-metric loss for self-supervised learning of depth and egomotion. in: Proceedings of the European Conference on Computer Vision, 2020:572–588
- [181] J. H. Lee, M. K. Han, D. W. Ko, I. H. Suh. From big to small: Multi-scale local planar guidance for monocular depth estimation. arXiv:1907.10326, 2019

- [182] F. Wang, S. Galliani, C. Vogel, P. Speciale, M. Pollefeys. Patchmatchnet: Learned multi-view patchmatch stereo. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021
- [183] Z. Teed, J. Deng. Deepv2d: Video to depth with differentiable structure from motion. arXiv preprint arXiv:1812.04605, 2018
- [184] Z. Wu, X. Wu, X. Zhang, S. Wang, L. Ju. Spatial correspondence with generative adversarial network: Learning depth from monocular videos. in: Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019:7494–7504
- [185] F. Wimbauer, N. Yang, L. Von Stumberg, N. Zeller, D. Cremers. MonoRec: Semi-supervised dense reconstruction in dynamic environments from a single moving camera. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:6112–6122
- [186] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, M. Niener. Scan-net: Richly-annotated 3d reconstructions of indoor scenes. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2017:5828–5839
- [187] M. Tan, Q. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. in: International Conference on Machine Learning. PMLR, 2019:6105–6114
- [188] R. Li, D. Gong, W. Yin, H. Chen, Y. Zhu, K. Wang, et al. Learning to fuse monocular and multi-view cues for multi-frame depth estimation in dynamic scenes. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023:21539–21548
- [189] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L. Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:4510–4520
- [190] J. Sturm, N. Engelhard, F. Endres, W. Burgard, D. Cremers. A benchmark for the evaluation of RGB-D SLAM systems. in: IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2012:573–580
- [191] P. Wenzel, R. Wang, N. Yang, Q. Cheng, Q. Khan, L. Stumberg, et al. 4Seasons: A cross-season dataset for multi-weather SLAM in autonomous driving. in: German Conference on Pattern Recognition. Springer, 2021:404–417
- [192] M. Burri, J. Nikolic, P. Gohl, T. Schneider, J. Rehder, S. Omari, et al. The EuRoC micro aerial vehicle datasets. The International Journal of Robotics Research, 2016

- [193] T. Schops, T. Sattler, M. Pollefeys. Bad slam: Bundle adjusted direct rgb-d slam. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:134–144
- [194] C. Campos, R. Elvira, J. G. Rodriguez, J. Montiel, J. Tardos. Orb-slam3: An accurate open-source library for visual, visual–inertial, and multimap slam. IEEE Transactions on Robotics, 2021, 37(6):1874–1890
- [195] W. Zhao, S. Liu, Y. Shu, Y. Liu. Towards better generalization: Joint depth-pose learning without posenet. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020:9151–9161

附录 1 答辩委员会决议

该博士学位论文围绕立体几何的视觉深度估计及其应用展开研究，选题属于计算机视觉领域的前沿和热点课题，具有重要的理论研究价值和广泛的应用前景。论文主要工作及创新点如下：

(1) 针对开放场景中病态区域的匹配难题，提出了一种基于区域分治和注意力机制的特征增强立体匹配方法和视差维全局注意力机制，提升了病态区域的深度估计精度。

(2) 针对模型跨域泛化性差的问题，构建了单目与立体双分支交互优化架构，提出了一种基于单目先验和双分支迭代优化的高泛化立体匹配算法，提升了模型的泛化性。

(3) 针对立体几何算法对相机参数精度高度依赖的问题，提出了一种基于单目、多视角自适应融合的抗噪增强深度估计框架，设计了基于重投影一致性的自适应融合机制，增强了系统的鲁棒性。

(4) 针对深度估计的应用挑战，提出了一种基于深度先验赋能的鲁棒单目视觉里程计算法，解决了单目里程计尺度缺失及环境适应性差的难题，实现了鲁棒的定位与建图。

该论文结构合理，层次分明，逻辑性强，内容充实，写作规范。研究工作表明，该生已扎实地掌握本学科坚实宽广的基础理论和系统深入的专门知识，具备很强的独立从事创新性科研工作的能力。在答辩过程中，该生思路清晰，重点突出，回答问题正确。经答辩委员会全体成员讨论并以无记名投票方式表决，一致同意通过程俊达博士学位论文答辩，建议授予工学博士学位。

附录 2 攻读博士学位期间取得的研究成果

已发表论文

- [1] **Junda Cheng**, Gangwei Xu, Peng Guo, Xin Yang. Coatsnet: Fully Exploiting Convolution and Attention for Stereo Matching by Region Separation. International Journal of Computer Vision, 2024, 132(1): 56-73. (CCF A; IF:19.5; 署名单位: 华中科技大学)
- [2] **Junda Cheng**, Xin Yang, Yuechuan Pu, Peng Guo. Region Separable Stereo Matching. IEEE Transactions on Multimedia, 2022, 25: 4880-4893. (中科院一区; IF:9.7; 署名单位: 华中科技大学)
- [3] **Junda Cheng**, Wei Yin, Kaixuan Wang, Xiaozhi Chen, Shijie Wang, Xin Yang. Adaptive Fusion of Single-View and Multi-View Depth for Autonomous Driving. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 10138-10147. (CCF A; 署名单位: 华中科技大学)
- [4] **Junda Cheng**, Longliang Liu, Gangwei Xu, Xianqi Wang, Zhaoxing Zhang, Yong Deng, Jinliang Zang, Yurui Chen, Zhipeng Cai, Xin Yang. Monster: Marry monodepth to stereo unleashes power. Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 6273-6282. (CCF A; 署名单位: 华中科技大学)
- [5] Gangwei Xu*, **Junda Cheng***, Peng Guo, Xin Yang. Attention Concatenation Volume for Accurate and Efficient Stereo Matching. Proceedings of the Computer Vision and Pattern Recognition Conference. 2022: 12981-12990. (共同第一作者; CCF A; 署名单位: 华中科技大学)
- [6] Zhaoxing Zhang*, **Junda Cheng***, Gangwei Xu, Xiaoxiang Wang, Can Zhang, Xin Yang. Leveraging Consistent Spatio-Temporal Correspondence for Robust Visual Odometry. Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(10): 10367-10375. (共同第一作者; CCF A; 署名单位: 华中科技大学)
- [7] Miaojie Feng*, **Junda Cheng***, Hao Jia, Longliang Liu, Gangwei Xu, Xin Yang. MC-Stereo: Multi-peak Lookup and Cascade Search Range for Stereo Matching.

2024 International Conference on 3D Vision (3DV), Davos, Switzerland, 2024, pp. 344-353, doi: 10.1109/3DV62453.2024.00083. (共同第一作者; CCF C; 署名单位: 华中科技大学)

- [8] Zikang Yuan, **Junda Cheng**, Xin Yang. CR-LDSO: direct sparse LiDAR-assisted visual odometry with cloud reusing. IEEE Transactions on Multimedia, 2023, 25: 9397-9409. (中科院一区; IF:9.7; 署名单位: 华中科技大学)
- [9] Gangwei Xu, Yun Wang, **Junda Cheng**, Jinhui Tang, Xin Yang. Accurate and efficient stereo matching via attention concatenation volume. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 46(4): 2461-2474. (SCI 一区; IF:19.5; 署名单位: 华中科技大学)
- [10] Longliang Liu, Miaojie Feng, **Junda Cheng**, Jijun Xiang, Xuan Zhu, Xin Yang. PriOr-Flow: Enhancing Primitive Panoramic Optical Flow with Orthogonal View. Proceedings of the IEEE/CVF international conference on computer vision. 2025: 4999-5008. (CCF A; 署名单位: 华中科技大学)

已投稿论文

- [1] MonSter++: Unified Stereo Matching, Multi-view Stereo, and Real-time Stereo with Monodepth Priors. IEEE Transactions on Pattern Analysis and Machine Intelligence. (SCI 一区; IF:20.8; 二审: 小修)
- [2] RoMeO: Robust Metric Visual Odometry. IEEE Transactions on Pattern Analysis and Machine Intelligence. (SCI 一区; IF:20.8; 一审)
- [3] Geo-Omni: Global Context-Awareness for Geometrically Consistent Omnidirectional Stereo Matching. Proceedings of the Computer Vision and Pattern Recognition Conference. (CCF A; 在投)
- [4] OmniSphereMVS: UAV-Oriented Full-Sphere Omnidirectional Stereo Matching with Adaptive View Attention. Proceedings of the Computer Vision and Pattern Recognition Conference.(CCF A; 在投)

科技奖励

- [1] 第六届中国图象图形学学会三维重建挑战赛冠军, 2025 年, 排名第一。
- [2] 第六届中国图象图形学学会图像图形技术挑战赛全国总冠军, 2025 年, 排名第一。

- [3] 面向穿戴式空间计算的空间感知算法研发。中国国际大学生创新大赛国赛银奖（互联网+），2023 年，排名第二。
- [4] 鲁棒实时的无人机视觉自主导航系统。第十九届“挑战杯”国赛特等奖，2025 年，排名第七。

附录 3 公开发表的学术论文与博士学位论文的关系

序号	成果名称	成果形式	成果主要内容	与学位论文对应的关系
1	Coatrsnet: Fully Exploiting Convolution and Attention for Stereo Matching by Region Separation	第一作者论文; IJCV 2023; CCF-A 类期刊; IF:19.5; 已发表	提出基于区域分治和注意力机制的特征增强立体匹配算法, 解决视觉退化场景特征表示问题	第二章
2	Monster: Marry monodepth to stereo unleashes power	第一作者论文; CVPR 2025; CCF-A 类会议; 已发表	提出基于单目先验和双分支迭代优化的高泛化立体匹配算法, 解决深度估计泛化性难题	第三章
3	MonSter++: Unified Stereo Matching, Multi-view Stereo, and Real-time Stereo with Monodepth Priors	第一作者论文; TPAMI; CCF-A 类期刊; 二审 (小修)	提出统一的单目先验和立体视觉融合互补范式, 并扩充实时高精的移动端深度估计	第三章
4	Adaptive Fusion of Single-View and Multi-View Depth for Autonomous Driving	第一作者论文; CVPR 2024; CCF-A 类会议; 已发表	提出单目、多视角自适应融合的深度估计框架, 提升噪声相机参数下的鲁棒性难题	第四章
5	RoMeO: Robust Metric Visual Odometry	第一作者论文; TPAMI; CCF-A 类期刊; 一审	提出基于深度先验增强与迭代的单目视觉里程计, 大大提升定位鲁棒性	第五章

附录 4 攻读博士学位期间参与的科研项目

1. 国家自然科学基金优秀青年基金项目

项目名称：图像特征计算

项目编号：No. 62122029

起止时间：2022 年 1 月至 2024 年 12 月

担任角色：视觉深度估计算法研发

2. 国家自然科学基金联合基金重点项目

项目名称：大小模型融合的联邦持续学习方法

项目编号：No. U25B2045

起止时间：2025 年 1 月至今

担任角色：深度估计大模型研发

3. 深圳市科技重大专项

项目名称：基于复杂环境下的无人机全天候自主精准导航技术研发

项目编号：No. KJZD20240903100801003

起止时间：2025 年 1 月至今

担任角色：无人机移动端深度估计小模型研发

附录 5 中英文缩写对照表

UAVs	Unmanned Aerial Vehicles (无人机)
MVS	Multi-View Stereo (多视角立体视觉)
CNN	Convolutional Neural Network (卷积神经网络)
NLP	Natural Language Processing (自然语言处理)
NCC	Normalized Cross-Correlation (归一化互相关)
SAD	Sum of Absolute Differences (绝对差值之和)
MRF	Markov Random Field (马尔可夫随机场)
SGM	Semi-Global Matching (半全局匹配)
SPP	Spatial Pyramid Pooling (空间金字塔池化)
SOTA	State-of-the-art (最先进)
MAE	Masked Autoencoders (掩蔽自编码器)
ViT	Vision Transformer (视觉转换器)
SFM	Structure from Motion (运动恢复结构)
MDE	Monocular Depth Estimation (单目深度估计)
BA	Bundle Adjustment (光束法平差)
RVC	Regional Volume Construction (区域代价体构建)
RAA	Regional Attention Aggregation (区域注意力聚合)
EPE	End-Point Error (端点误差)
RMSE	Root-Mean-Square Error (均方根误差)
FLOPs	Floating-point Operations (浮点运算数)
Gwc	Group-wise Correlation Volume (组相关代价体)
GEV	Geometry Encoding Volume (几何编码体)
AbsRel	Absolute Relative Error (绝对相对误差)
SqRel	Square Relative Error (平方相对误差)
SSIM	Structure Similarity Index Measure (结构相似指标)

IMU	Inertial Measurement Unit (惯性测量单元)
GNSS	Global Navigation Satellite System (全球导航卫星系统)
ATE	Absolute Trajectory Error (绝对轨迹误差)
RTE	Relative Trajectory Error (相对轨迹误差)
FPS	Frames Per Second (帧率)